



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



TFG del Grado en Ingeniería
Informática

Aprendizaje semisupervisado
y ciberseguridad: detección
automática de ataques en
sistemas de recomendación y
phishing
Documentación técnica.



Presentado por Patricia Hernando Fernández
en Universidad de Burgos — 16 de marzo
de 2023

Tutor: Álvaro Arnaiz González

Índice general

Índice general	i
Índice de figuras	iii
Índice de tablas	iv
Apéndice A Plan de Proyecto Software	1
A.1. Introducción	1
A.2. Scrum	1
A.3. Planificación temporal	4
A.4. Estudio de viabilidad	27
Apéndice B Especificación de Requisitos	29
B.1. Introducción	29
B.2. Objetivos generales	29
B.3. Catálogo de requisitos	29
B.4. Especificación de requisitos	29
Apéndice C Especificación de diseño	31
C.1. Introducción	31
C.2. Diseño de datos	31
C.3. Diseño procedimental	34
C.4. Diseño arquitectónico	34
Apéndice D Documentación técnica de programación	37
D.1. Introducción	37
D.2. Estructura de directorios	37

D.3. Manual del programador	37
D.4. Compilación, instalación y ejecución del proyecto	37
D.5. Compilación, instalación y ejecución de herramientas auxiliares	37
D.6. Pruebas del sistema	38
Apéndice E Documentación de usuario	39
E.1. Introducción	39
E.2. Requisitos de usuarios	39
E.3. Instalación	39
E.4. Manual del usuario	39
Bibliografía	41

Índice de figuras

A.1. Resumen del ciclo de Scrum	2
A.2. Eventos de Scrum	3
A.3. <i>Burndown Report Sprint 01</i>	5
A.4. <i>Burndown Report Sprint 02</i>	7
A.5. <i>Burndown Report Sprint 03</i>	8
A.6. <i>Burndown Report Sprint 04</i>	9
A.7. <i>Burndown Report Sprint 05</i>	11
A.8. <i>Burndown Report Sprint 06</i>	12
A.9. <i>Burndown Report Sprint 07</i>	14
A.10. <i>Burndown Report Sprint 08</i>	15
A.11. <i>Burndown Report Sprint 09</i>	17
A.12. <i>Burndown Report Sprint 11</i>	19
A.13. <i>Burndown Report Sprint 12</i>	21
A.14. <i>Burndown Report Sprint 13</i>	22
A.15. <i>Burndown Report Sprint 14</i>	24
A.16. <i>Burndown Report Sprint 15</i>	25
A.17. <i>Burndown Report Sprint 16</i>	27
D.1. <i>Co-forest</i> : Configuración de un experimento en KEEL	38

Índice de tablas

B.1. CU-1 Nombre del caso de uso.	30
C.1. Diccionario de datos: Users	32
C.2. Diccionario de datos: Available_instances	32
C.3. Diccionario de datos: Available_models	33
C.4. Diccionario de datos: Available_co_forests	33
C.5. Diccionario de datos: Available_tri_trainings	34
C.6. Diccionario de datos: Available_democratic_cos	34
C.7. Diccionario de datos: Candidate_instances	35
C.8. Diccionario de datos: Model_is_trained_with	35

Apéndice A

Plan de Proyecto Software

A.1. Introducción

En este documento se pretende mostrar el plan de proyecto seguido a la hora de realizar el trabajo de fin de grado.

Debido al auge de las metodologías ágiles en la industria y sus indiscutibles ventajas, se ha escogido la metodología Scrum para desarrollar el proyecto. Los conceptos teóricos seguidos se encuentran en el «Manual de Scrum» [5], temario necesario para obtener la certificación de Scrum Manager.

Posteriormente, se expondrá la viabilidad legal y económica del producto.

A.2. Scrum

Scrum es una metodología ágil basada en cuatro valores [5]. Sintetizando sus principios, se puede deducir que se pretende valorar a los individuos por encima de las herramientas, el *software* apropiado a la documentación exhaustiva, la colaboración con el cliente y la habilidad de dar respuesta al cambio ante imprevistos.

Siguiendo este esquema, se desarrolla el «ciclo de Scrum» representado en la imagen A.1, que se puede dividir en varios pilares.

Figura A.1: Resumen del ciclo de Scrum según el Manual de Scrum [5].



Roles

Descripción de los posibles interventores durante el desarrollo de un producto.

- *Product owner*: es el representante del cliente, y su responsabilidad es el valor del producto. Es quien gestiona la pila del producto (conjunto de historias de usuario solicitadas por el cliente), así como la prioridad de cada ítem que lo compone.
- *Scrum master*: es el responsable de garantizar que el proyecto se desarrolla siguiendo los principios de Scrum, asesorando a los desarrolladores. También es el moderador en las reuniones diarias de Scrum y el encargado de resolver dinámicas que puedan perjudicar al equipo.
- Equipo de desarrollo: es el conjunto de programadores autogestionados encargados de generar los incrementos. Profesionales multifuncionales, deben completar las tareas que se les asignen en el plazo estimado, además de participar en la toma de decisiones.

Artefactos

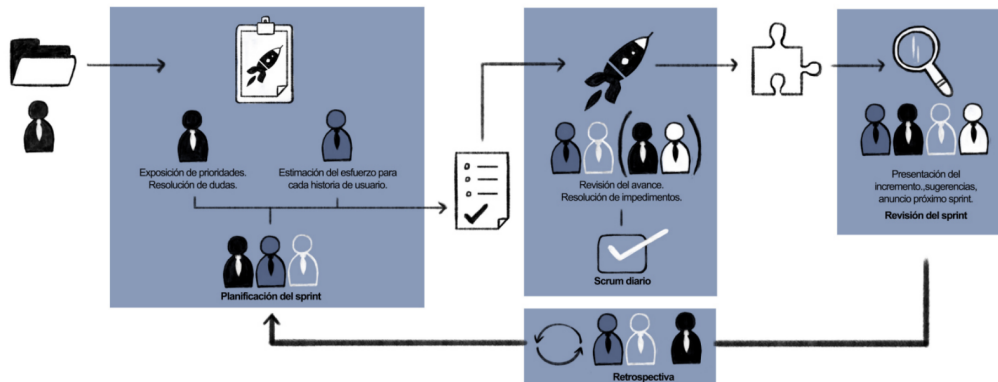
Son las «herramientas» [5] elementales. Entre ellos se encuentran:

- Pila de producto o *product backlog*: contiene las historias de usuario (el equivalente a los «requisitos» en las metodologías tradicionales). Evoluciona durante el proyecto en función de las peticiones del cliente.
- Pila del *sprint* o *sprint backlog*: es la lista de tareas que han de completar los desarrolladores en un *sprint*. En este proyecto, se han utilizado las *milestones* de GitHub (asignándoles *issues*) para representarla.
- Incremento: resultado de cada *sprint*. Ha de ser un entregable.
- Gráfico de avance o *burn down report*: muestra el trabajo pendiente por realizar en un *sprint* y es actualizado por los desarrolladores. Indica, además, el ritmo de trabajo «ideal» que se debería seguir para alcanzar los objetivos. En este caso, se ha utilizado el gráfico generado por ZenHub.
- Gráfico de producto o *burn up report*: mide cuánto se ha completado respecto al total.

Eventos

Durante el ciclo de Scrum, se pueden identificar varias actividades que constituyen la rutina y se representan en la imagen A.2 facilitada por el Manual de Scrum [5].

Figura A.2: Eventos de Scrum según el Manual de Scrum [5].



1. *Sprint* o iteración: es un periodo de tiempo fijo (y breve) en el que se trabaja para completar una cantidad de tareas prefijadas con antelación (la pila del *sprint*). Se han utilizado los *sprints* de ZenHub para realizar el seguimiento.

2. Reunión de planificación del *sprint*: marca el inicio de cada *sprint* y determina las tareas a desarrollar, además de su duración temporal.
3. Scrum diario: breve reunión en la que cada integrante del equipo notifica su ritmo de trabajo con el fin de corregir posibles impedimentos que ralenticen el ciclo. Además, se actualiza el *burndown report*. En este caso, debido a que el equipo está formado únicamente por un desarrollador, se ha omitido.
4. Revisión del *sprint*: se analiza el incremento entregado y se adapta la pila del producto en caso de necesitarlo (por ejemplo, si se ha encontrado algún *bug* o se necesita refactorizar).
5. Retrospectiva del *sprint*: se aporta el *feedback* necesario para mejorar la siguiente iteración.

Medición

Como se puede observar, cada equipo puede realizar una cantidad de trabajo, generalmente fija, en cada *sprint*. Por ello, es necesario estimar el tiempo que requiere cada tarea y no asignar más trabajo del que se pueda asimilar en cada iteración.

En este proyecto, se han utilizado los «puntos de historia» como unidad de medida.

A.3. Planificación temporal

Planificación por *sprints*

Siguiendo los eventos de Scrum, y adaptándolos teniendo en cuenta el tamaño del equipo (un desarrollador), se ha decidido planificar el proyecto mediante *sprints*.

Sprint 1: Mustard

■ *Planning meeting*

Durante la reunión se marcaron los siguientes objetivos:

1. Configuración básica: incluyendo la creación del repositorio, la correcta instalación de ZenHub, la creación de entornos virtuales

(miniconda, Scikit-Learn, etc.) y la familiarización con conceptos Scrum: *milestones*, *sprints*, *epics*, etc.


2. Memoria: comienzo de la redacción incluyendo las secciones de introducción, conceptos teóricos (aprendizaje automático) y trabajo relacionado.
3. Investigación: búsqueda del código SSADR-CoF y de las bases de datos utilizadas en el paper.
4. Lectura de papers: Engelen & Hoos [8], García, Triguero & Herrera [6], y Zhou & Duan [9].

■ Marcas temporales

El *sprint* se desarrolló entre el 24 de septiembre de 2022 y el 2 de octubre del 2022.

■ *Burndown Report*

Figura A.3: *Burndown Report Sprint 01*



Como se puede comprobar, no todos los objetivos marcados fueron cumplidos: la estimación del tiempo fue demasiado optimista, además de no contar con el tiempo requerido en solucionar problemas técnicos (L^AT_EX). Se dejó para próximos sprints la lectura del último paper.

- ***Sprint review meeting***

Durante la reunión se fijaron ciertas correcciones en la memoria (mejorar referencias bibliográficas y la sección de «Trabajos relacionados»), además de la necesidad de introducir una sección teórica de ataques a los sistemas de recomendación.

Sprint 2: Paprika

- ***Planning meeting*** Objetivos del siguiente Sprint:

1. Configuración: debido a la gran cantidad de tiempo invertida en solucionar errores de compilación en \LaTeX , se decidió migrar el proyecto a una nueva instalación basada en Debian.
2. Correcciones: aspectos estilísticos y completar información.
3. Lectura: Mingdan y Qingshan [4] con el objetivo de introducir una sección teórica de ataques.
4. Memoria: redacción completa de los modelos de ataque en los aspectos teóricos.

- **Marcas temporales**

El *sprint* se desarrolló entre el 3 de octubre de 2022 y el 18 de octubre del 2022.

- ***Burndown Report***

En este *sprint* sí se cumplió con los objetivos marcados. Sin embargo, la estimación de tiempo tampoco fue la adecuada, requiriendo más de lo previsto.


- ***Sprint review meeting***

Durante la reunión se resolvieron dudas acerca de bibliografía, referencias y trabajo previo. Además, se acordó empezar a programar, definiendo así los *issues* desarrollados en el siguiente *sprint*.

Sprint 3: Fennel Seeds

- ***Planning meeting***

Durante esta reunión, se decidió empezar a programar el *co-forest*. Para ello, se definieron los siguientes pasos:

Figura A.4: *Burndown Report Sprint 02*

1. Librerías: se acordó aprender a utilizar las librerías más comunes en el *data science*. Entre ellas: Matplotlib y Scikit-Learn. Además, se requirió la correcta configuración del entorno virtual, haciendo que el tiempo dedicado al *issue* fuese mayor de lo estimado (problemas en el PATH y con las dependencias).
2. *SKLearn*: aprovechando la correcta documentación de la librería, se decidió repasar los conceptos teóricos básicos, además del manejo de la «interfaz» (métodos comunes). Entre ellos:
 - *Decision trees*
 - *Self training*
 - *Random Forest*
3. Lectura: se concertó la relectura del artículo de Zhou [9] con la intención de comprender el algoritmo y del *paper* «original» del *co-forest* [3]. Durante el proceso de programación, además, se encontró la tesis de Van Engelen [7] y se añadió al conjunto.
4. Documentación: se acordó la corrección de los errores previamente señalados y la inclusión del *sprint* en los anexos.
5. Programación del *co-forest*: se programó el pseudocódigo ilustrado en la Tesis de Van Engelen [7], que es muy similar al original [3]


pero con algunas diferencias. Inicialmente se intentó usar el *random forest* de Scikit-Learn, pero se descartó la idea debido a la poca versatilidad que se ofrecía para manejar los *concomitant ensembles*. Se han de corregir ciertos factores, pero se pospondrá hasta la correcta discusión con el tutor.

■ Marcas temporales

El *sprint* se desarrolló entre el 19 de octubre de 2022 y el 2 de noviembre del 2022.

■ *Burndown Report*

Figura A.5: *Burndown Report Sprint 03*



En este *sprint* se cumplió con los objetivos marcados. Nuevamente, la estimación del tiempo fue inferior a la real (se pensaba que se podría depender más de librerías existentes de lo que se pudo en realidad), calculándose un total de aproximadamente 25 horas reales.

■ *Sprint review meeting*

Durante la revisión del *sprint*, se llegó a la conclusión de que el pseudocódigo podía ser mejor implementado aprovechando ciertas librerías de Python. Se comentó cómo mejorar complejidades espaciales y reducir el código. Se fijaron objetivos para las próximas semanas.

Sprint 4: Cayenne

■ *Planning meeting*

Durante la reunión se acordaron los siguientes objetivos:


1. Reimplementación del código: se acordó volver a programar el *co-forest*, esta vez implementando una versión más «pythonizada» con el fin de mejorar la complejidad espacial y facilitar la lectura.
2. Curso de Numpy: se decidió que sería interesante la realización de un curso para aprender a utilizar la librería y aplicarla al código.
3. Curso de Pandas: aprovechando la relación con el punto anterior, se acordó completar también un curso de esta librería.
4. Memoria: corregir aspectos anteriores e incluir toda la teoría relacionada con el *co-forest*.

■ *Marcas temporales*

El *sprint* se desarrolló entre el 3 de noviembre de 2022 y el 15 de noviembre del 2022.

■ *Burndown Report*

Figura A.6: *Burndown Report Sprint 04*



En este *sprint* se completaron los objetivos, aunque quedaron pendientes ciertos aspectos a comentar respecto al código. Destacar que, debido a que se terminaron antes de lo planeado los *issues* planificados, se aprovechó para modificar ciertos aspectos pendientes relacionados con la memoria y para probar correctamente el código. Esto hizo que el tiempo real dedicado haya sido ligeramente superior al estimado (más tiempo de documentación).

- ***Sprint review meeting***

En la reunión se acordó experimentar con el algoritmo utilizando distintos conjuntos de datos, además de mejorar ciertos detalles de implementación.

Sprint 5: Curry

- ***Planning meeting***

Durante la reunión se acordaron los siguientes objetivos:

1. Ajustes al código: se acordó mejorar algunos factores, como la generación de objetos «aleatorios» para obtener resultados deterministas en los experimentos, optimización de memoria o corrección de parámetros.
2. Experimentación: se determinó probar el código con distintos conjuntos de datos en diferentes fases: durante el entrenamiento y tras terminarlo. Para ello, se estudiaron algunos conceptos teóricos y el uso de la librería Matplotlib para representar gráficamente los resultados obtenidos.
3. Memoria: documentación de los experimentos realizados y correcciones.

- ***Marcas temporales***

El *sprint* se desarrolló entre el 15 de noviembre de 2022 y el 25 de noviembre del 2022.

- ***Burndown Report***

En este *sprint* se cerraron todos los puntos de historia propuestos. Aunque se estimaron 11 horas de trabajo, el tiempo invertido fue superior, realizando 15. La mayor dedicación se justifica por la existencia de reuniones intermedias y de «defectos» encontrados en el código en el transcurso del *sprint*.

Figura A.7: *Burndown Report Sprint 05*

■ *Sprint review meeting*

Durante la reunión se acordó comparar los resultados obtenidos con los de otras herramientas, además de empezar el tratamiento de los conjuntos de datos utilizados en el *paper* [9].

Sprint 6: Coriander

■ *Planning meeting*

Durante la reunión se fijaron los siguientes objetivos:


1. Ajustes en las gráficas: arreglar detalles menores en el formato de ciertos gráficos.
2. Comparativas: probar los resultados obtenidos y compararlos la herramienta de la Universidad de Granada llamada KEEL.
3. *Datasets* «reales»: probar el algoritmo utilizando MovieLens, una de las bases de datos utilizadas en el *paper* [9]. Para ello, es necesaria una re-lectura del artículo y realizar el procesamiento inicial de los datos.
4. Memoria: documentación de los experimentos realizados.

■ Marcas temporales

El *sprint* se desarrolló entre el 25 de noviembre de 2022 y el 5 de diciembre del 2022.

■ *Burndown Report*

Figura A.8: *Burndown Report Sprint 06*



Puede parecer que los puntos de historia fueron mal estimados debido a que el ritmo de trabajo es bajo. Sin embargo, se justifica debido a que durante la experimentación (en concreto, durante la comparativa contra KEEL) se encontraron dos *bugs* en el código (causados no por la lógica del programa, sino por el operador *in* de Python y por no estar preparado para recibir etiquetas que no comiencen en 0).

Debido a que los errores se encontraron una vez se realizó toda la documentación, se tuvo que repetir la sección asociada a los experimentos del *co-forest*, además de localizar y depurar los errores de código. Todo este trabajo supuso un esfuerzo extra de 7 horas, que fueron introducidas en el *backlog* del *sprint* a mediados del mismo (debido a la gran importancia que tienen y la influencia en pasos posteriores). Por este motivo, no se completaron los objetivos previstos. Sin embargo, el tiempo dedicado al proyecto fue el estimado.

Es destacable también que de los 6 puntos de historia que quedan se realizaron 2, pero se decidió dejar el *issue* abierto para el siguiente *sprint*.

■ ***Sprint review meeting***

Habiendo finalizado el modelo, se decidió empezar a experimentar con bases de datos de sistemas de recomendación. Además, se acordó añadir nuevas gráficas.

Sprint 7: Cinnamon

■ ***Planning meeting***

Se marcaron los siguientes objetivos para el *sprint*.


1. Extraer vectores de características: estudiar e implementar el método de extracción de vectores por ventanas expuesto en el *paper* de Zhou y Duan [9]. Generar ficheros *.csv* con dichos vectores para poder importarlos posteriormente con Pandas. Probar la correcta generación de vectores con perfiles verdaderos y atacantes.
2. Generación de reseñas de atacantes: siguiendo los modelos estadísticos, generar reseñas de ataque para el *random attack*, el *average attack* y el *bandwagon attack*.
3. Documentación: añadir introducción y descripción de Scrum en los anexos. Corregir las sugerencias anteriores. Incluir la descripción del método de extracción de vectores de características por ventanas y la generación de reseñas de atacantes.

■ **Marcas temporales**

El *sprint* se planificó para desarrollarse entre el 8 y el 20 de diciembre de 2022. Sin embargo y debido al ritmo de trabajo, se cerró el 15 de diciembre de 2022.

■ ***Burndown Report***

Como se puede comprobar, se finalizaron las tareas del *sprint* antes de lo previsto. En gran parte, debido a que el *issue* de extracción de vectores de características estaba ya comenzado en el *sprint* anterior, y requirió menos tiempo del planificado. Además, el resto de tareas no dieron problemas en esta iteración. Debido a que Scrum no permite

Figura A.9: *Burndown Report Sprint 07*

añadir nuevos ítems en la pila del *sprint* durante el desarrollo de este, se decidió cerrar y comenzar uno nuevo.

■ *Sprint review meeting*

Durante la reunión se concluyó que la forma de generar vectores de características y reseñas de ataques es correcta, por lo que se decidió experimentar con el *co-forest* y datos reales.

Sprint 8: Kaffir Lime Leaves

■ *Planning meeting*

Durante este *sprint* se fijaron los siguientes objetivos:

1. Refactorizar el extractor de vectores de características y el generador de reseñas de atacantes: debido a que la sintetización de los conjuntos de entrenamiento y *test* requiere demasiado tiempo (25h), se ha decidido mejorar la complejidad algorítmica y convertir a clase con el fin de reducir llamadas con mayor complejidad temporal. Se redujo el tiempo requerido a (10h) mediante el uso de la nueva estructura (en lugar de fichero de utilidades).


2. Completar el *co-forest*: añadir nuevos métodos para realizar comparaciones (predicción con probabilidades, AUC, *recall* y precisión).
3. Orden de repositorio: lectura acerca de la creación de módulos en python, conversión de los *notebooks* a archivos `.py` importables, configuración de rutas.
4. Análisis de resultados: analizar los resultados en busca de posibles errores cometidos durante la experimentación.
5. Generación de gráficas y comparación contra *random forest*: utilizando clases de Scikit-Learn, automatizar la generación de gráficas para imitar el experimento realizado por Zhou y Duan [9] para el *co-forest* y dos *random forest* con distintos conjuntos de entrenamiento.

■ Marcas temporales

Para evitar solapamientos con el *sprint* anterior, oficialmente (en el repositorio) se desarrolló entre el 18 y el 22 de diciembre del 2022. Sin embargo, se empezó unos días antes.

■ *Burndown Report*

Figura A.10: *Burndown Report Sprint 08*



Como se puede comprobar, los *issues* fueron completados correctamente.

■ *Sprint review meeting*

Durante la reunión se comprobó que los resultados obtenidos en la fase de experimentación no se asemejan a los presentados en el *paper* seguido [9]. Sin embargo, se concluyó que podrían ser correctos. Para evitar realizar afirmaciones erróneas, se decidió revisar todo el proceso de experimentación.

Sprint 9: Ginger

■ *Planning meeting*

Debido a que este *sprint* se realizó durante la época vacacional, se decidió realizar una revisión general del documento completando aspectos pendientes.

1. Experimentación *co-forest*: se incluyó una gráfica *extra* pendiente (tiempo de entrenamiento-número de árboles) y se repitió la experimentación esta vez utilizando conjuntos estratificados. Se corrigieron los cambios surgidos y actualizaron las gráficas en la memoria. Se revisó la clase del *co-forest* y se terminó de documentar, además de adaptar los métodos a la interfaz de SKLearn (cambio de firma).
2. Documentación: se decidió cerrar aspectos pendientes. Entre ellos: completar las secciones teóricas de semisupervisado, ensembles y métricas, repetir gráficas e ilustraciones incorrectas, revisar la bibliografía y trabajos relacionados, completar los anexos y corregir aspectos menores.
3. Revisión de la detección de ataques: debido a que los resultados obtenidos no son los esperados, se decidió revisar toda la generación de reseñas de atacantes, extracción de perfiles y métodos de experimentación en busca de posibles errores. Se incluyeron alternativas para la AUC (curva *precision - recall*).
4. Implementación: se investigó acerca del *tri-training* y se implementó este nuevo método.

■ **Marcas temporales**

El *sprint* se desarrolló entre el 27 de diciembre del 2022 y el 8 de enero del 2023.

■ *Burndown Report*

Figura A.11: *Burndown Report Sprint 09*



El número total de horas dedicadas al proyecto fue de 20. Aunque se «dejó abierto» el *sprint* hasta el 8 de enero, la intención era acabarlo el 4 de enero, por lo que la estimación temporal fue correcta.

■ *Sprint review meeting*

Tras haber finalizado la experimentación, se decidió investigar nuevos temas para dedicar el tiempo restante a otros con mejor método de extracción de vectores de características.

Sprint 10: Amchur

■ *Planning meeting*

En este *sprint* se decidió:

1. Lectura de aplicación del semisupervisado a la intrusión de redes: lectura del paper de BigFlow y su mejora semisupervisada. Investigación de la base de datos.
2. Búsqueda de aplicaciones del semisupervisado a nuevos temas: entre ellos NIDS, *phishing*, detección de *malware*, de *markets* en

la *deep web*, de intrusiones en redes IoT, etc. Búsqueda de bases de datos.

3. Continuación de implementación del *democratic co-learning*: implementación del algoritmo y lectura del paper.

■ Marcas temporales

El *sprint* se desarrolló entre el 9 y el 20 de enero. Fueron dedicadas al *sprint* 9 horas de trabajo. No se incluye un *burndown report* debido a que no se asociaron las horas de investigación a ningún repositorio en concreto.

■ *Sprint review meeting*

Tras haber comentado las distintas ramas de investigación posibles, en esta reunión se decidió cambiar el tema principal a la aplicación del aprendizaje semisupervisado para la detección de *phishing*.

Sprint 11: Parsley

■ *Planning meeting*

Durante esta reunión se acordó comenzar a trabajar en el nuevo objetivo, además de completar documentación pendiente.

1. Extracción de vectores de características de URLs: generar el código que permita diferenciar un enlace de *phishing* de uno verídico.
2. Pruebas unitarias: debido a que se ha creado una clase de utilidades para apoyar la extracción de los vectores de características, se ha decidido investigar acerca de las pruebas unitarias en Python e implementar algunas.
3. Creación de instancias de Tor: debido a que algunos de los métodos de los vectores de características requieren hacer peticiones a páginas peligrosas, se ha decidido proteger esas peticiones utilizando instancias de Tor, de manera que se oculte la IP del ordenador que realiza las peticiones. Para ello, se ha creado un *script* capaz de levantar estas conexiones y se han utilizado como *proxies* (protocolo SOCKS5).
4. Documentación y experimentación: se ha generado la documentación relativa al algoritmo *tri-training*, además de su comparativa y estudio (gráficas).


5. Refactorización: debido a que muchos de los métodos para realizar las gráficas del *tri-training* duplican código de los utilizados para generar el *co-forest*, se ha decidido realizar métodos comunes y una clase de utilidades para las gráficas.

■ Marcas temporales

El *sprint* fue completado entre el 24 y el 30 de enero del 2022.

■ *Burndown Report*

Figura A.12: *Burndown Report Sprint 11*



El número total de horas dedicadas al proyecto fue de 30, requiriendo una cifra ligeramente inferior a la estimada. Aún así se cerró antes de tiempo debido a que se pudieron invertir más horas por día de las predichas. Nuevamente, recalcar que el tiempo sobrante en ciertos *issues* fue destinado a la generación de vectores de características.

■ *Sprint review meeting*

En la reunión se concluyó que el trabajo desarrollado es correcto, a excepción de un detalle a cambiar respecto al algoritmo TF-IDF.

Sprint 12: Oregano**■ *Planning meeting***

En este *sprint* se decidió, principalmente, avanzar la documentación. Por lo tanto, se acordó:

1. Documentar los resultados de la aplicación de *machine learning* a la detección de ataques en sistemas de recomendación.
2. Documentar la parte teórica de ciberseguridad, protocolos (SOCKS5), Tor, etc., además de la creación del *script* para levantar instancias.
3. Documentar y realizar la comparativa del *tri-training*.
4. Documentar algunas de las herramientas utilizadas hasta ahora.
5. Documentar la generación de vectores de características para la detección de phishing, además de revisar el código.

Adicionalmente se solucionaron algunos aspectos no relacionados con la documentación:

1. Arreglar el uso del algoritmo TF-IDF e integrarlo en la generación de vectores para la detección de *phishing*.
2. Creación de métodos que recopilen las URLs de las que se extraerán los vectores de características, además de depurar algunos de los *csv* que se necesitan para los enlaces persistentes.

■ *Marcas temporales*


El *sprint* se desarrolló entre el 31 de enero y el 6 de febrero del 2023.

■ *Burndown Report*

En este *sprint*, no se pudieron cerrar todos los *issues* planeados debido a que algunos de los completados requirieron más tiempo de lo estimado (por ejemplo, los métodos de obtención de URLs debido a que un servidor bloqueó la IP del equipo por exceso de peticiones o la comparativa del *tri-training* debido a que se decidió cambiar la estética de las gráficas de toda la memoria).

■ *Sprint review meeting*

Tras haber resuelto los problemas que surgieron en el *sprint* y revisado la documentación, se decidió continuar con el proyecto.

Figura A.13: *Burndown Report Sprint 12*

Sprint 13: Tandoori Masala

■ *Planning meeting*

En este *sprint* se decidió continuar con el algoritmo *democratic-co learning*, además de seguir documentando e iniciar el control de calidad.


1. Implementar el *democratic-co learning* y documentarlo en la sección teórica.
2. Documentar la extracción de vectores de características de *phishing*, ataques *web* típicos, la sección teórica del *phishing*, los anexos e incluir las correcciones realizadas por el tutor.
3. Renombrar el repositorio y adaptar la memoria a la nueva sección de *phishing*: modificar introducción, trabajos relacionados etc.
4. Crear ilustraciones para mejorar la memoria, además de modificar las existentes con el fin de incluirlas en formato **pdf** para mejorar la calidad.
5. Revisar la extracción de vectores de características para *phishing* (*features* 1-7).
6. Vincular el repositorio con Sonarcloud e implementar control de calidad. Cambiar el archivo **README.md** e incluir nuevos *badges*.

- **Marcas temporales**

El *sprint* fue desarrollado entre el 7 y el 13 de febrero de 2022.

- ***Burndown Report***

Figura A.14: *Burndown Report Sprint 13*



En este *sprint* todos los *issues* fueron cerrados. Al igual que en ocasiones anteriores, aunque la estimación particular de cada tarea pudo no ser correcta, en general la de todo el *sprint* resultó equilibrada. Se calcula que el tiempo real dedicado al proyecto fue ligeramente superior, de unas 26 horas. Esto es debido principalmente a que se dedicó tiempo a la revisión «estilística» de la memoria (corrección de cursivas incorrectas, nombres propios, anglicismos, etc.).

- ***Sprint review meeting***

Lo más destacable es la corrección de ciertos aspectos relacionados con el *democratic-co learning*. Por ello, se estimó que debían ser corregidos.

Sprint 14: Chimichurri

- ***Planning meeting***

Se decidió trabajar en:

1. Corrección de los vectores de características de *phishing* y de la API de extracción de enlaces. Generación de *dataset* parcial y gráficas de pruebas para comprobar el nivel de detección de la propuesta.
2. Documentar algún aspecto pendiente. En especial herramientas nuevas, anexos y el proceso de minería de datos (realizar ilustraciones).
3. Introducir DeepSourceBot y mejorar la calidad del proyecto (corregir defectos de código). Proteger las ramas del repositorio para prevenir posibles conflictos con el *bot*.
4. Incluir Travis CI y generar una *build* de *tests*. Reorganizar el proyecto en estructura de paquetes.
5. Corregir el *democratic-co learning*, realizar la comparativa contra *sslearn* y documentar los resultados.
6. Lanzar los primeros experimentos de detección de *phishing* y corregir posibles *bugs*.

■ Marcas temporales

El *sprint* fue desarrollado entre el 14 y el 20 de febrero de 2022.

■ *Burndown Report*

En este *sprint* se concluyó el trabajo propuesto. Debido a que hubo ciertas dificultades, se calcula que la estimación real del trabajo es de 33 horas.

■ *Sprint review meeting*


En el *feedback* se estimó que los algoritmos de semisupervisado están correctamente implementados y se decidió avanzar otros aspectos del proyecto.

Sprint 15: Anise

■ *Planning meeting*

Se decidió trabajar en:

1. Comienzo de la *web*: aprender a utilizar Flask y desarrollar la aplicación. Manejar archivos *.css* básicos y aprender a usar (por encima) ciertas librerías como Bootstrap, SQLAlchemy, Flask WTF, etc. Búsqueda de una plantilla atractiva y desplegable.


Figura A.15: *Burndown Report Sprint 14*

2. Sistema de bases de datos: buscar servidor (comparativa entre MariaDB y PostgreSQL) y desplegar en local.
3. Despliegue: despliegue en Heroku y gestión de errores. Levantar tanto la *web* como el servidor de bases de datos.
4. Documentación: corrección de aspectos indicados por el tutor, redacción de anexos, inclusión del apartado «técnicas» en la memoria principal.
5. Experimentación: generación del *dataset* real de *phishing* (2000 instancias) y realización de las gráficas con datos reales. Posible búsqueda de alternativas a la generación de vectores.
6. Calidad: corrección de *issues* utilizando Deep Source Bot.
7. Diagramas: comenzar a realizar diagramas de casos de uso, clases, etc.

■ Marcas temporales

El *sprint* fue desarrollado entre el 23 de febrero y el 6 de marzo de 2022.

■ *Burndown Report*

Figura A.16: *Burndown Report Sprint 15*

El tiempo estimado de trabajo fue de 29 horas. Sin embargo, el tiempo real ha sido de 37.5 horas, y no todos los *issues* pudieron ser cerrados. En concreto, se decidió posponer la búsqueda de nuevas formas de generar vectores de características por los buenos resultados reportados y no se dedicó tanto tiempo como el esperado a la generación de diagramas (únicamente se realizó el de casos de uso).

Claramente se subestimó el tiempo requerido en realizar pantallas *web*, desplegar en Heroku y gestionar servidores de bases de datos. Hubo complicaciones debido a que se ha escogido una plantilla profesional, y el uso del lenguaje es complejo. Todavía hay ciertos aspectos que arreglar respecto al despliegue en Heroku (no renderiza correctamente los menús desplegables a diferencia de «local»).

■ *Sprint review meeting*

En esta reunión se concluyó que el incremento había sido desarrollado correctamente con la excepción de los diagramas (debido a que se dedicó poco tiempo). Por lo tanto, se ofreció retroalimentación con respecto a los mismos con el fin de volverlos a generar. También se recibió *feedback* relacionado con la documentación.

Sprint 16: Vanilla

■ *Planning meeting*

En esta reunión se plantearon los siguientes objetivos:

1. Diagramas: repetir el diagrama de casos de uso partiendo de la retroalimentación proporcionada por el *product owner*. Realizar el diagrama de clases de la base de datos relacional y generar *mockups* de las interfaces para la página *web*.
2. *Web*: implementación de funcionalidad. Serialización y deserialización de clasificadores, generación de funciones de utilidades para modularizar el ML y diseño de la interacción entre elementos (comunicación en variables de sesión, formularios nuevos, etc.). Nuevas pantallas (carga con animaciones para tareas que requieran más tiempo), adaptación del modelo de datos de la *web* al nuevo diagrama de clases e introducción de roles y permisos. Pantallas asociadas al administrador (esqueleto realizado y adaptación del menú). Mejoras estilísticas (segmentos utilizados, usuarios activos, *badges* y más) y corrección de errores (encabezados y sesiones activas). Implementación definitiva de los modelos de la base de datos (sustituidos los anteriores por no ser suficiente para cubrir los nuevos requerimientos).
3. Documentación: corregir aspectos previos y realizar anexos. Introducir las secciones de CD/CI, Gitflow, Scrum y complementar las herramientas. Planificación temporal del *sprint*.
4. Herramientas: realizar una primera «toma de contacto» con D3.js y decidir si merece la pena introducir esta tecnología en la página *web*.

■ Marcas temporales


El *sprint* fue desarrollado entre el 7 de marzo y el 13 de marzo del 2023.

■ *Burndown Report*

En este *sprint* todos los *issues* fueron cerrados. Se estimó un tiempo total de trabajo de 29 horas y el tiempo real dedicado ha sido de 30 horas. Cabe destacar que los *issues* de realización de *mockups* requirieron menos tiempo del estimado y que el tiempo sobrante se empleó en seguir programando la página *web*.

Aunque no estaba planificado, también se incluyó la tecnología Git-Guardian en el flujo de Git con el fin de proteger la aplicación ante posibles filtraciones de contraseñas (en concreto, de la base de datos).

■ *Sprint review meeting*

Figura A.17: *Burndown Report Sprint 16****Sprint N:***

- *Planning meeting*
 - 1.
 - 2.
 - 3.
 - 4.
- Marcas temporales
- *Burndown Report*
- *Sprint review meeting*

A.4. Estudio de viabilidad

Viabilidad económica

Viabilidad legal

Apéndice B

Especificación de Requisitos

B.1. Introducción

Una muestra de cómo podría ser una tabla de casos de uso:

B.2. Objetivos generales

B.3. Catálogo de requisitos

B.4. Especificación de requisitos

CU-1	Ejemplo de caso de uso
Versión	1.0
Autor	Alumno
Requisitos asociados	RF-xx, RF-xx
Descripción	La descripción del CU
Precondición	Precondiciones (podría haber más de una)
Acciones	<ol style="list-style-type: none"> 1. Pasos del CU 2. Pasos del CU (añadir tantos como sean necesarios)
Postcondición	Postcondiciones (podría haber más de una)
Excepciones	Excepciones
Importancia	Alta o Media o Baja...

Tabla B.1: CU-1 Nombre del caso de uso.

Apéndice C

Especificación de diseño

C.1. Introducción

C.2. Diseño de datos

Diccionario de datos

Se adjunta a continuación, para cada tabla, el diccionario de datos correspondiente.

Tabla de usuarios (**Users**)

Esta tabla (C.1) almacena la información relevante de cada usuario registrado en la base de datos. Si se comprueba el diagrama E-R, se puede comprobar que una peculiaridad de esta tabla es que es una ISA. Debido a que, además del discriminante (usuario administrador o estándar), únicamente hay un atributo que diferencia ambas clases, se ha decidido implementar utilizando una sola tabla.

Tabla de instancias (**Available_instances**)

Esta tabla (C.2) almacena la información asociada a cada instancia disponible en el *dataset*. Las instancias son URLs que pueden ser utilizadas posteriormente para entrenar y probar modelos. Además, esta tabla también almacena enlaces reportados por usuarios por pertenecer a una lista blanca o negra.

Nombre	Tipo y tamaño	Otros	Descripción
<u>id</u>		<u>PK</u>	Identificador
username			Nombre de usuario
email			Email del usuario
password			Contraseña
user_first_name			Nombre
user_last_name			Apellidos
user_rol		Por defecto: «standard»	Rol. Puede ser «standard» o «admin».
n_urls_accepted			Atributo de usuarios «standard». Contador de aquellas instancias que han sido reportadas y aceptadas por un administrador.

Tabla C.1: Diccionario de datos. Tabla correspondiente a la clase **Users**.

Nombre	Tipo de dato y tamaño	Por defecto	Otros	Descripción
instance_id	INTEGER 8	anterior	PK	Identificador
reviewed_by				
instance_url				
instance_fv				
instance_class				
colour_list				
instance_labels				

Tabla C.2: Diccionario de datos. Tabla correspondiente a la clase **Available_instances**.

Nombre	Tipo de dato y tamaño	Por defecto	Otros	Descripción
model_id	INTEGER 8	anterior	PK	Identificador
created_by				
model_name				
file_name				
date				
default				
visible				
random_state				

Tabla C.3: Diccionario de datos: tabla correspondiente a la clase `Available_models`.

Nombre	Tipo de dato y tamaño	Por defecto	Otros	Descripción
model_id	INTEGER 8	anterior	PK	Identificador
max_features				
thetha				
n_trees				

Tabla C.4: Diccionario de datos: tabla correspondiente a la clase `Available_co_forests`.

Tabla de modelos (`Available_models`)

Esta tabla (C.3) almacena los modelos de aprendizaje que han sido creados por un administrador y están disponibles en la *web* para su uso.

Si se comprueba el diagrama E-R, se puede comprobar que esta tabla es una ISA. En este caso se ha decidido implementar considerando que es una interrelación 1:1. Por ello, se ha creado una tabla para la generalización y otra tabla para cada una de las especializaciones. Estas se enumeran a continuación:

- **Available_co_forests:** los modelos pertenecientes a este algoritmo poseen los atributos de la tabla C.4.
- **Available_tri_trainings:** los modelos pertenecientes a este algoritmo poseen los atributos de la tabla C.5.

Nombre	Tipo de dato y tamaño	Por defecto	Otros	Descripción
model_id	INTEGER 8	anterior	PK	Identificador
cls_one				
cls_two				
cls_three				

Tabla C.5: Diccionario de datos: tabla correspondiente a la clase `Available_tri_trainings`.

Nombre	Tipo de dato y tamaño	Por defecto	Otros	Descripción
model_id	INTEGER 8	anterior	PK	Identificador
base_cls				

Tabla C.6: Diccionario de datos: tabla correspondiente a la clase `Available_democratic_cos`.

- **Available_democratic_cos**: los modelos pertenecientes a este algoritmo poseen los atributos de la tabla C.6.

Tablas de relación

Se enumeran a continuación las tablas que son resultado de una relación entre entidades.

- **Candidate instances**: en esta tabla (C.7) se almacenan aquellas instancias que han sido reportadas por un usuario estándar y necesitan ser revisadas por un administrador antes de ser incluidas en el *dataset* utilizable de la aplicación.
- **Model_is_trained_with**: en esta tabla (C.8) se almacena qué instancia ha sido utilizada para entrenar qué modelo en el sistema.

C.3. Diseño procedimental

C.4. Diseño arquitectónico

Nombre	Tipo de dato y tamaño	Por defecto	Otros	Descripción
user_id	INTEGER 8	anterior	PK	Identificador
instance_id				
date				
suggestion				

Tabla C.7: Diccionario de datos: tabla correspondiente a la clase `Candidate_instances`.

Nombre	Tipo de dato y tamaño	Por defecto	Otros	Descripción
model_id	INTEGER 8	anterior	PK	Identificador
instance_id				

Tabla C.8: Diccionario de datos: tabla correspondiente a la clase `Model_is_trained_with`.

Apéndice *D*

Documentación técnica de programación

D.1. Introducción

D.2. Estructura de directorios

D.3. Manual del programador

D.4. Compilación, instalación y ejecución del proyecto

D.5. Compilación, instalación y ejecución de herramientas auxiliares

KEEL


KEEL es una herramienta que permite experimentar con modelos de *machine learning*. Ha sido creada por distintas universidades españolas y financiada por el Ministerio de Educación y Ciencia [2].

Para poder ejecutarla, en primer lugar, se han de descargar los ficheros fuente del repositorio de GitHub [1]. Una vez se han descargado, se compilan aprovechando el fichero `build.xml` contenido y la herramienta `ant`.

Mediante el comando `ant cleanAll` se eliminan barios previos (para evitar conflictos), y mediante el comando `ant` se compila el código fuente.

Posteriormente se ejecuta la aplicación mediante el comando `java -jar ./dist/GraphInterKeel.jar` y se utiliza mediante su interfaz gráfica.

Figura D.1: Configuración de un experimento que utiliza el algoritmo *coforest* mediante la GUI de KEEL.



D.6. Pruebas del sistema

Apéndice E

Documentación de usuario

- E.1. Introducción
- E.2. Requisitos de usuarios
- E.3. Instalación
- E.4. Manual del usuario

Bibliografía

- [1] Jesús Alcalá, Alberto Fernández, Julián Luengo, Francisco Herrera, Joaquín Derrac, Salvador García, and Luciano Sánchez. Github: Keel, 2018. <https://github.com/SCI2SUGR/KEEL>.
- [2] Jesús Alcalá, Alberto Fernández, Julián Luengo, Francisco Herrera, Joaquín Derrac, Salvador García, and Luciano Sánchez. Keel: Knowledge extraction based on evolutionary learning, 2018. <https://sci2s.ugr.es/keel/members.php>.
- [3] Ming Li and Zhi-Hua Zhou. Improve computer-aided diagnosis with machine learning techniques using undiagnosed samples. *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, 37(6):1088–1098, 2007.
- [4] Si Mingdan and Qingshan Li. Shilling attacks against collaborative recommender systems: a review. *Artificial Intelligence Review*, 53, 01 2018.
- [5] Marta Palacio. *Scrum Master. Temario troncal 1*. 02 2022. https://www.scrummanager.com/files/scrum_master.pdf.
- [6] Isaac Triguero, Salvador García, and Francisco Herrera. Self-labeled techniques for semi-supervised learning: Taxonomy, software and empirical study. *Knowledge and Information Systems*, 42, 02 2015.
- [7] Jesper Van Engelen and Holger Hoos. Semi-supervised ensemble learning. master’s thesis., 07 2018.
- [8] Jesper Van Engelen and Holger Hoos. A survey on semi-supervised learning. *Machine Learning*, 109, 02 2020.

- [9] Quanqiang Zhou and Liangliang Duan. Semi-supervised recommendation attack detection based on co-forest. *Comput. Secur.*, 109(C), oct 2021.