



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



TFG del Grado en Ingeniería
Informática

Aprendizaje semisupervisado
y ciberseguridad: detección
automática de ataques en
sistemas de recomendación y
phishing



Presentado por Patricia Hernando Fernández
en Universidad de Burgos — 13 de mayo
de 2023

Tutor: Álvaro Arnaiz González



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



D. Álvar Arnaiz González, profesor del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos.

Expone:

Que la alumna D.^a Patricia Hernando Fernández, con DNI 71362977A, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado «Aprendizaje semisupervisado y ciberseguridad: detección automática de ataques en sistemas de recomendación y *phishing*».

Y que dicho trabajo ha sido realizado por la alumna bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 13 de mayo de 2023

Vº. Bº. del Tutor:

D. Álvar Arnaiz González

Resumen

En este primer apartado se hace una **breve** presentación del tema que se aborda en el proyecto.

Descriptores

Palabras separadas por comas que identifiquen el contenido del proyecto Ej: servidor web, buscador de vuelos, android ...

Abstract

A **brief** presentation of the topic addressed in the project.

Keywords

keywords separated by commas.

Índice general

Índice general	iii
Índice de figuras	v
Índice de tablas	vii
1. Introducción	1
2. Objetivos del proyecto	3
3. Conceptos teóricos	7
3.1. Aprendizaje automático	7
3.2. Aprendizaje semisupervisado	8
3.3. <i>Ensembles</i>	11
3.4. Métricas y técnicas de evaluación	15
3.5. <i>Co-forest</i>	19
3.6. <i>Tri-Training</i>	25
3.7. <i>Democratic-co learning</i>	28
3.8. Proceso de minería de datos	32
3.9. Conceptos básicos de ciberseguridad	33
3.10. Ataques a sistemas de recomendación	40
3.11. <i>Phishing</i>	45
4. Técnicas y herramientas	55
4.1. Técnicas	55
4.2. Herramientas	58
5. Aspectos relevantes del desarrollo del proyecto	65

5.1. Algoritmos de aprendizaje semisupervisado	65
5.2. Detección de ataques en sistemas de recomendación	79
5.3. Detección de <i>phishing</i>	85
6. Trabajos relacionados	95
7. Conclusiones y Líneas de trabajo futuras	99
Bibliografía	101

Índice de figuras

3.1. Suposiciones del aprendizaje semisupervisado	9
3.2. Taxonomía de métodos de aprendizaje semisupervisado	10
3.3. Entrenamiento <i>bagging</i> y <i>boosting</i>	14
3.4. Combinación mediante votación en <i>ensembles</i>	15
3.5. Curva ROC	17
3.6. AUC curvas ROC y PR	18
3.7. Validación cruzada	19
3.8. Proceso de minería de datos	34
3.9. Enrutado cebolla.	37
3.10. Ataques <i>web</i> : SQLi	38
3.11. Ataques <i>web</i> : CSRF	39
3.12. Ataques <i>web</i> : XSS	40
3.13. <i>Phishing</i> : Anatomía de una URL.	48
4.1. Técnicas: Ciclo de vida del CI/CD	57
5.1. <i>Co-Forest</i> : resultados (inicialización W con 6 árboles)	67
5.2. <i>Co-Forest</i> : resultados (inicialización W con 20 árboles)	68
5.3. <i>Co-Forest</i> : distribución de datos entrenamiento y <i>test</i>	69
5.4. <i>Co-Forest</i> : resultados (iteraciones-entrenamiento)	70
5.5. <i>Co-Forest</i> : resultados (tiempo-porcentaje)	71
5.6. <i>Co-Forest</i> : resultados (número de árboles)	72
5.7. <i>Tri-training</i> : resultados (iteraciones-entrenamiento)	74
5.8. <i>Tri-training</i> : resultados (tiempo-porcentaje)	74
5.9. <i>Tri-training</i> : comparativa contra LAMDA	76
5.10. <i>Tri-training</i> : comparativa contra <i>sslearn</i>	76
5.11. <i>Democratic-co</i> : resultados (iteraciones-entrenamiento)	77
5.12. <i>Democratic-co</i> : resultados (tiempo-porcentaje)	78
5.13. <i>Democratic-co</i> : comparativa contra <i>sslearn</i>	79

5.14. <i>Random attack</i> : detección.	83
5.15. <i>Average attack</i> : detección.	84
5.16. <i>Bandwagon attack</i> : detección.	85
5.17. <i>Phishing</i> : detección (f1-f19)	88
5.18. <i>Phishing</i> : detección (f1-f19, matriz de confusión CoF_PL)	89
5.19. <i>Phishing</i> : detección (f1-f8)	89
5.20. <i>Phishing</i> : detección (f1-f8, matriz de confusión TT)	90
5.21. <i>Phishing</i> : detección (f9)	90
5.22. <i>Phishing</i> : detección (f10-f15)	91
5.23. <i>Phishing</i> : detección (f10-f15, atributos relevantes)	92
5.24. <i>Phishing</i> : detección (f16)	93
5.25. <i>Phishing</i> : detección (f17-f19)	93
5.26. <i>Phishing</i> : detección (f1-f19, atributos relevantes)	94

Índice de tablas

3.1. Sistemas de recomendación: ataques básicos	42
3.2. Sistemas de recomendación: ataques con poco conocimiento . .	42
3.3. Sistemas de recomendación: estrategias de ofuscación	43
5.1. Experimentación: <i>datasets</i> estándar	66
5.2. <i>Co-forest</i> : resumen del experimento	72
5.3. <i>Co-forest</i> : comparativa entre KEEL y la implementación propia	73
5.4. Experimentación: características de ataques a detectar	81
5.5. Sistemas de recomendación: descripción de los conjuntos	82
5.6. <i>Phishing</i> : descripción del <i>dataset</i>	86

1. Introducción

A diferencia de unas décadas atrás, la sociedad actual está gobernada por los datos. La transición a la era de la información puede ser compleja para determinados colectivos y, consecuentemente, han surgido grupos que pretenden facilitar la experiencia de los usuarios, mientras que otros buscan aprovechar la falta de información general para lograr un beneficio.

Este trabajo de investigación pretende explorar cómo la minería de datos, en concreto el aprendizaje semisupervisado, puede aplicarse a la seguridad informática con el fin de lograr un entorno digital de confianza. Para ello, se han abierto dos ramas de investigación: la detección automática de ataques en sistemas de recomendación y la detección de *phishing*.

Un sistema de recomendación es un algoritmo desarrollado con el fin de resumir información y facilitar la toma de decisiones. Son herramientas que pretenden realizar sugerencias de objetos que pueden resultar interesantes para un determinado perfil. Económicamente, este tipo de algoritmo es un claro objeto de interés, puesto que puede influir en la toma de decisiones de los compradores y hacer que se inclinen por un determinado producto (por ejemplo, el que tenga una mejor valoración). Los atacantes conocen esta situación y manipulan estas herramientas mediante el uso de perfiles falsos con el fin de beneficiar sus productos o perjudicar los de la competencia. Por ello, uno de los objetivos del proyecto es explorar cómo el aprendizaje semisupervisado puede ayudar a detectar los ataques a sistemas de recomendación, diferenciando entre perfiles genuinos e inyectados, además de comprobar la veracidad de los trabajos previos planteados por otros investigadores.

Por otro lado, se denomina *phishing* a la técnica de ingeniería social en la que un atacante suplanta la identidad de una entidad de confianza con el fin de extraer datos o información personal de un determinado usuario. Este

tipo de ataque es uno de los más comunes y peligrosos. Según el informe *State of the Phish Report*, en el 2021, un 83 % de las empresas encuestadas sufrieron un ataque de estas características y el 54 % acabó con brechas de datos de clientes [15]. Por ello, se pretende crear un sistema de detección que permita distinguir enlaces falsos de auténticos mediante técnicas de aprendizaje semisupervisado.

2. Objetivos del proyecto

Previo a la introducción de objetivos técnicos y de desarrollo, se facilita al lector el contexto en el que se desarrolla este proyecto de investigación con el fin de que se familiarice con el mismo.

Contexto

Es reseñable que este proyecto se sostiene sobre tres pilares complementarios pero a su vez independientes.

Aprendizaje semisupervisado

Por un lado, en este trabajo se pretende ahondar en el concepto de aprendizaje semisupervisado. Para ello, se va a implementar y validar diversos algoritmos de este tipo, en concreto el *co-forest*, el *democratic-co learning* y el *tri-training*.

Es reseñable que se pretende alcanzar un nivel de comprensión superior a la mera programación, realizando incluso pequeñas aportaciones a los algoritmos (basadas en la experimentación) en aquellos casos donde el pseudocódigo facilitado por los autores carezca de detalles de implementación.

Ciberseguridad

Implementar algoritmos es un ejercicio relevante, pero carece de sentido si no pueden ser utilizados. Por ello, se pretende encontrar una aplicación a los mismos. Concretamente, se ha propuesto el modelado de un problema real relacionado con la ciberseguridad.

En un primer lugar se valoró estudiar la detección de ataques en sistemas de recomendación, pero se desestimó por su bajo desempeño. Finalmente, se ha escogido la detección de *phishing*.

Desarrollo

Por último, se pretende elaborar una herramienta que permita poner al servicio de la comunidad el conocimiento desarrollado. Se ha decidido crear un analizador de *phishing* en formato página *web*, permitiendo además la administración avanzada de modelos de *machine learning* e instancias de aprendizaje.

Objetivos técnicos

Se han propuesto los siguientes objetivos técnicos:

1. Implementar y evaluar distintos algoritmos de aprendizaje semisupervisado: con rigor científico y procurando una codificación eficiente.
2. Experimentar con detalles de implementación no concretados: para comprobar cómo determinadas decisiones pueden afectar el desempeño de un algoritmo.
3. Comparar contra implementaciones de terceros: logrando unas condiciones de análisis justas.
4. Modelar un problema de ciberseguridad: ofreciendo una solución práctica basada en el aprendizaje predictivo.
5. Establecer medidas de seguridad: siendo consciente de que los métodos de extracción pueden amenazar vulnerabilidades y mitigando el riesgo.
6. Evaluar la calidad de la solución aportada: en términos de rendimiento.
7. Aprendizaje de nuevas tecnologías: y familiarización con la programación *web*.

Objetivos de desarrollo *software*

Se han propuesto los siguientes objetivos de desarrollo software:

1. Implementar de forma estándar los algoritmos: siguiendo interfaces conocidas por la comunidad (métodos `fit` y `predict`).

2. Adoptar metodologías ágiles de desarrollo: y familiarización con el flujo de Scrum.
3. Documentar el producto desarrollado: de forma concisa y que resuma utilizando herramientas visuales (como diagramas) la arquitectura planteada.
4. Lograr un código de calidad: desarrollando un producto que tenga una deuda técnica baja y una curva de aprendizaje asumible mediante el uso de herramientas como SonarCloud.
5. Aplicar la integración y entrega continua: de forma que se garantice el desarrollo de un producto mínimo viable que permita la detección temprana de errores y facilite la corrección por parte del tutor.
6. Vincular fuentes de persistencia: como bases de datos SQL.
7. Desplegar en plataformas: logrando una familiarización con nuevas tecnologías en auge como Heroku y Docker.
8. Automatizar pruebas: en distintas fases del ciclo de vida del producto mediante el uso de herramientas como TravisCI y Selenium.

3. Conceptos teóricos

Se sintetizarán a continuación algunos de los conceptos teóricos más relevantes para la correcta comprensión del trabajo realizado.

3.1. Apendizaje automático

Se denomina aprendizaje automático a aquella rama de la inteligencia artificial cuyo objetivo es desarrollar métodos que permitan que un algoritmo mejore su rendimiento mediante la experiencia y procesamiento de datos. Consecuentemente, los modelos entrenados realizarán predicciones cada vez más precisas como resultado del algoritmo implementado.

Se conoce como «instancia» (o entrada) a cada fila del *dataset*. Estas están caracterizadas por atributos, que pueden ser numéricos (sus valores son números) o categóricos (sus valores son etiquetas, nombres, categorías, etc) [28].

Dentro del aprendizaje automático se diferencian tres grandes grupos en función del tipo de entrada que sea consumida durante el entrenamiento [24]: el aprendizaje supervisado (datos etiquetados), el no supervisado (datos no etiquetados) y el semisupervisado (datos etiquetados y no etiquetados), siendo esta última categoría objeto de estudio en este proyecto de investigación. Se entiende por etiqueta como la representación de una determinada clase.

El aprendizaje supervisado (vertiente predictiva) tiene como meta construir un clasificador (o regresor) que sea capaz de estimar el valor de salida para entradas nuevas (que no se hayan «visto» hasta el momento). Por otro lado, el aprendizaje no supervisado (vertiente descriptiva) trata de inferir la estructura interna de las entradas y agruparlas según similitudes (*clustering*).

Por último, el aprendizaje semisupervisado es la rama que pretende combinar estas dos vertientes complementándolas [24]. La aplicación más común de estos métodos es generar clasificadores efectivos cuando los datos disponibles son escasos, aunque no es la única.

Un clasificador generalmente cuenta con dos fases a lo largo de su ciclo de vida: la fase de entrenamiento y la fase de predicción. En la primera, el estimador trata de encontrar una hipótesis idéntica al concepto objetivo para todos los datos de entrenamiento, suponiendo que la mejor hipótesis para los datos no vistos es aquella que mejor se ajusta a los datos de entrenamiento [53]. Es decir, trata de «aprender» sobre el conjunto de entrenamiento. Posteriormente, el clasificador está preparado para realizar predicciones en instancias nuevas.

El *dataset* disponible inicialmente suele ser dividido en conjuntos más pequeños en función de su finalidad [28]. El conjunto de entrenamiento es aquel subconjunto de los datos utilizado para construir los modelos predictivos (generalmente, a mayor sea este conjunto mejor). Por otro lado, el conjunto de *test* es un subconjunto menor no visto por el modelo (no utilizado durante el entrenamiento) utilizado para estimar el desempeño del modelo a posteriori.

3.2. Aprendizaje semisupervisado

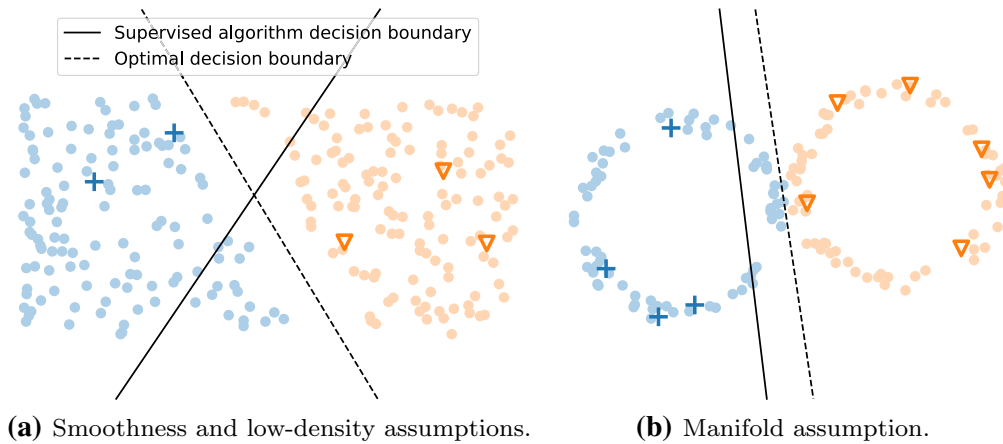
Como se ha mencionado anteriormente, se denomina aprendizaje semisupervisado a aquel conjunto de algoritmos que utiliza datos etiquetados y no etiquetados para realizar tareas de aprendizaje.

Cuando se habla de aprendizaje semisupervisado, hay ciertas suposiciones que se asumen, además de una condición: que la distribución marginal subyacente en el espacio de entradas $p(x)$ contenga información acerca de la posterior distribución $p(y|x)$ [24]. Si no se cumple este requisito, no se puede asegurar que las predicciones basadas en datos no etiquetados vayan a ser adecuadas, aunque en la mayoría de los casos de la vida real ocurre. Sin embargo, la forma en la que $p(x)$ y $p(y|x)$ interactúan no siempre es la misma, aunque se pueden esperar ciertos comportamientos plasmados en las «suposiciones del aprendizaje semisupervisado» (imagen 3.1). Entre ellas:

- ***Smoothness assumption***: si dos muestras x y x' están cerca en el espacio de entrada, sus etiquetas y y y' deberían ser las mismas.

- **Low-density assumption:** esta suposición propone que la frontera de decisión de un clasificador no debería cortar regiones con alta densidad de datos.
- **Mainfold assumption:** postula que el espacio de entrada está compuesto por varios *manifolds* («colectores») de dimensiones menores, y que todos los datos contenidos en un mismo *manifold* tienen la misma etiqueta.

Figura 3.1: Suposiciones del aprendizaje semisupervisado: *smoothness* y *low-density assumption* a la izquierda, *manifold assumption* a la derecha. Extraída de «*A survey on semi-supervised learning*» [24].

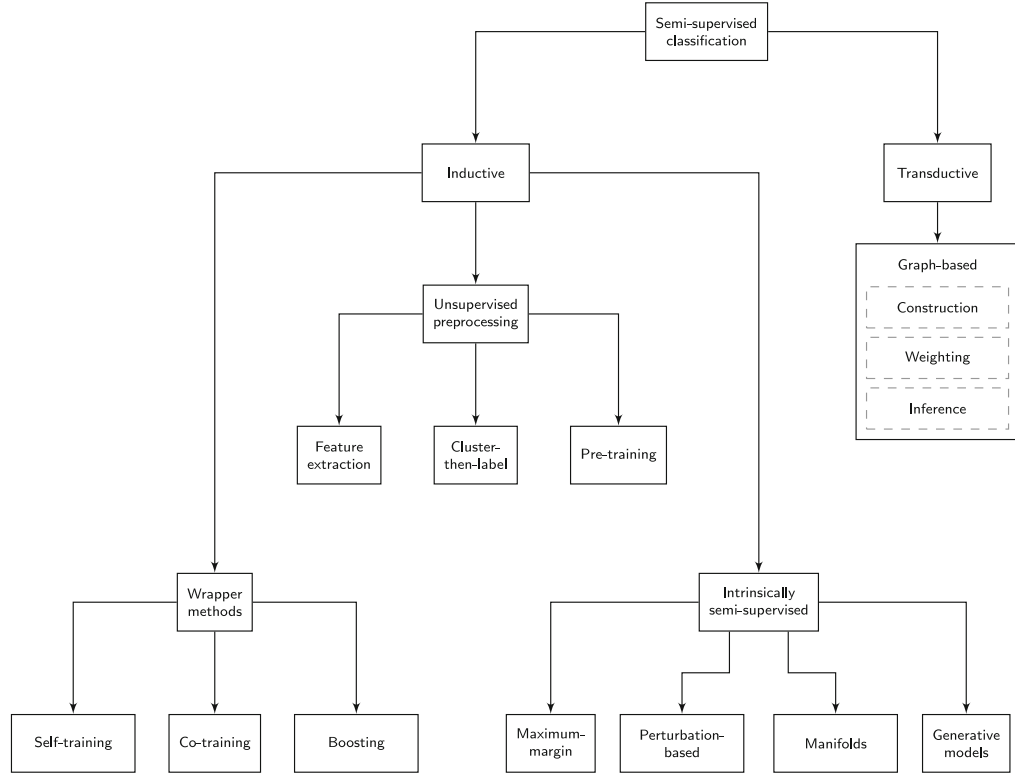


Clasificación

Inicialmente, se pueden diferenciar dos categorías [24]: los métodos inductivos, cuyo objetivo principal es construir un clasificador que genere predicciones para cualquier entrada y los métodos transductivos, cuyo poder de predicción está limitado a los objetos utilizados en la fase de entrenamiento.

Prescindiendo de los métodos transductivos por ser menos versátiles y útiles en nuestro propósito, los métodos inductivos se subdividen en tres grupos [24]: *wrapper methods* (o métodos de envoltura), *unsupervised preprocessing* y *intrinsically semi-supervised*, siendo materia de estudio los métodos de envoltura.

Figura 3.2: Taxonomía de métodos de aprendizaje semisupervisados. Extraída de «*A survey on semi-supervised learning*» [24].



Métodos de envoltura

Estos modelos utilizan uno o más clasificadores que son entrenados iterativamente con los datos etiquetados de entrada, además de con datos pseudo-etiquetados. Se denomina pseudo-etiquetado a aquellos datos que inicialmente no estaban etiquetados, pero acabaron estándolo por iteraciones previas de los clasificadores.

Consecuentemente, el procedimiento consta de dos fases que se repiten en cada iteración: el entrenamiento y el pseudo-etiquetado. Durante el entrenamiento, los clasificadores se alimentan de datos etiquetados (o pseudo-etiquetados). En la fase de pseudo-etiquetado, se utilizan datos no etiquetados para que sean procesados por los clasificadores previamente entrenados.

Dentro de esta categoría, se pueden diferenciar tres grandes grupos: *self-training*, que utilizan únicamente un clasificador, *co-training* [24], que utilizan más de uno y los *pseudo-labelled boosting methods*, que construyen

clasificadores individuales que se alimentan de las predicciones más fiables. Se estudiará más en profundidad los métodos *co-training*.

Co-training

En estos algoritmos, varios clasificadores son entrenados iterativamente utilizando datos etiquetados y añadiendo las predicciones (resultados) más confiables al conjunto para ser utilizadas en las siguientes iteraciones [24]. Para que los clasificadores sean capaces de generar información distinta, generalmente se divide el conjunto de entrada según alguna característica (no siendo estrictamente necesario). El *co-forest*, algoritmo protagonista de este proyecto, pertenece a esta categoría.

Para que estos métodos tengan éxito, es importante que los clasificadores base no estén fuertemente correlacionados con sus predicciones, ya que entonces se limita el potencial para proporcionar información útil al resto [24]. Es decir, los estimadores han de ser diversos. Una de las formas de conseguir diversidad es mediante el uso de clasificadores inestables. Otra, obtener más de una vista del conjunto de datos inicial.

3.3. Ensembles

Cuando se cuenta con un único estimador base a la hora de realizar una predicción, la etiqueta asignada es directamente la predicha por el clasificador. Sin embargo, en muchas ocasiones, puede resultar enriquecedor recurrir a lo estimado por más de un modelo [58].

Se define *ensemble* como un conjunto de modelos de *machine learning* donde cada estimador base genera una predicción individual que se combina con el resto para generar una salida única [48]. Hay varios motivos por los que resulta favorecedor contar con un conjunto de clasificadores en lugar de con un único estimador base [58]:

- **Motivos estadísticos:** en muchas ocasiones se obtienen buenos resultados en los datos de entrenamiento, pero un error de generalización alto. También se puede dar el caso en el que un conjunto de clasificadores con resultados similares en el conjunto de prueba actúe de manera distinta en la aplicación real (el conjunto de *test* no es lo suficientemente representativo). En estos casos, el hecho de contar con un conjunto de clasificadores reduce considerablemente las probabilidades de predecir mal una etiqueta. Una analogía en la vida real sería cuando

se pide opinión médica a un conjunto de doctores (y no a uno solo) para obtener un diagnóstico no sesgado por las experiencias previas de un sólo médico.

- **Gran cantidad de datos:** cuando la cantidad de información es demasiada, puede no ser manejada correctamente por un único clasificador. Por ello, es mejor particionarla en distintos conjuntos de entrenamiento y prueba, y alimentar cada modelo con una partición.
- **Escasa cantidad de datos:** si los datos no son suficientes, puede ocurrir que un clasificador no sea capaz de aprender su estructura interna. Por ello, es recomendable realizar un muestreo de los datos (con reemplazo) y entrenar varios modelos distintos con ellos. De esta manera, los errores disminuyen.
- **Divide y vencerás:** cuando un problema es demasiado complicado de resolver utilizando un único clasificador, utilizar un conjunto de ellos puede ser efectivo.

Diversidad y clasificación

En la realidad, los datos contienen ruido, *outliers*, distribuciones que se solapan, etc. Por ello, es muy complicado obtener un clasificador con un desempeño perfecto [58]. Los *ensembles* reducen el error cometido por cada estimador base debido a que combinan las salidas de los mismos. Puede parecer «negativo» que los clasificadores individuales difieran. Sin embargo, la realidad es que cuanto más único sea cada estimador utilizado y más distintas sean sus *decision boundaries* (frontera que divide la superficie del problema en partes), mejor.

Esta diversidad se puede obtener de distintas formas, por ejemplo, utilizando distintos conjuntos de entrenamiento y *test* en los estimadores base (utilizando técnicas de *bootstrapping*, por ejemplo). Otra opción muy destacable es utilizando clasificadores «inestables» (aquellos que sean muy distintos con pequeños cambios en el conjunto de entrenamiento), como por ejemplo los árboles.

A la hora de crear un *ensemble*, hay dos preguntas clave: ¿cómo se van a generar los clasificadores base? ¿cómo van a diferenciarse los unos de los otros? [58].

Para lograr un mayor nivel de diversidad, se pueden utilizar procedimientos de muestreo o selección de parámetros. En función de ellos y de cómo se

realice el entrenamiento (consultar imagen 3.3), los *ensembles* pueden ser de distintos tipos.

Bagging (Random Forest)

El *bagging* es uno de los modelos más antiguos y populares [58]. Se compone de un conjunto de estimadores base entrenados en paralelo. Por lo tanto, el resultado es el promedio (o más popular) de las salidas de los modelos simples. Para entrenar cada estimador base se utiliza *bootstrapping* [72], que es una técnica de muestreo que genera un subconjunto de datos seleccionando aleatoriamente muestras de un conjunto mayor permitiendo la repetición. Es decir, los clasificadores son entrenados con un subconjunto aleatorio del total de los datos etiquetados como se ilustra en la figura 3.3. Esta técnica puede ser utilizada con o sin reemplazo, entendiendo que el muestreo con reemplazo se produce cuando cada una de las unidades maestras seleccionada es devuelta a la población total antes de extraer la siguiente (puede repetirse).

El *bagging* es muy útil cuando se dispone poca cantidad de datos, y la cantidad de muestras que contiene cada conjunto de entrenamiento es de entre el 75 % – 100 % del total del *dataset* [58]. Al utilizar *bootstrapping*, los conjuntos de *test* se suelen solapar, además de poder contener muestras repetidas (reemplazo). Por ello, es recomendable utilizar clasificadores base inestables, como por ejemplo los árboles.


Cuando todos los estimadores base son árboles, se habla de ***random forest***, uno de los métodos de *bagging* más populares que obtiene resultados certeros debido a la aleatoriedad introducida [48]. Cuando el *ensemble* devuelve una etiqueta, es el resultado de una votación realizada por todos los árboles del conjunto. Además de utilizar *bootstrapping*, en el entrenamiento individual de cada árbol, únicamente se «ven» algunos atributos (no el total) para introducir mayor aleatoriedad. Es decir, en cada nodo del árbol solo se tienen en cuenta ciertas características seleccionadas aleatoriamente.

Boosting

Si el anterior modelo utiliza los clasificadores base «en paralelo», este lo haría «en serie» [72]. Es decir, hay un orden secuencial: los estimadores dependen del resultado anterior y tratan de compensar el error que se haya podido cometer (los *weak learners* se convierten en *strong learners* [58]).

El entrenamiento se focaliza, por lo tanto, en torno a las instancias en las que hayan fallado los clasificadores previos. Esto se consigue dando más

Figura 3.3: Diferencias esquemáticas entre el entrenamiento en *bagging* (izquierda) y *boosting* (derecha).



peso a aquellas muestras mal clasificadas. Por ejemplo, en problemas de regresión, las predicciones con un mayor error cuadrático medio tendrán más peso para el siguiente modelo. En clasificación, los estimadores se entrenan con aquellas muestras en las que los otros elementos del *ensemble* difieran.

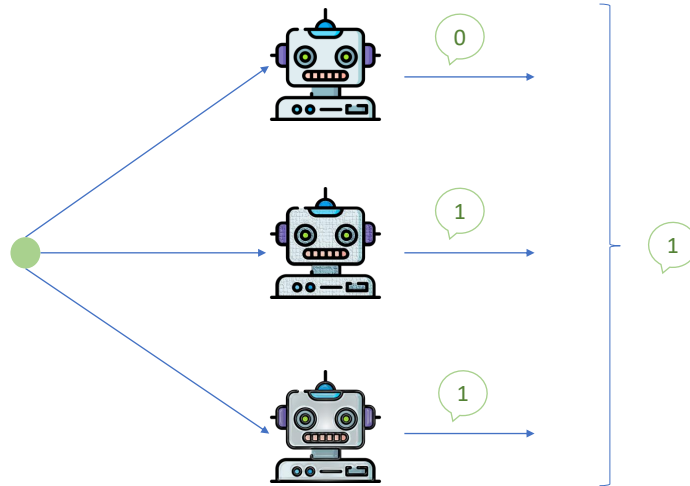
Combinación de los clasificadores

Suponiendo que sólo se dispone de las etiquetas asignadas por los clasificadores base como salida, hay diversos modos de «fusionar» los *outputs* en uno único [58].

En el caso de que todos los estimadores base sean «iguales», es frecuente utilizar *majority voting* («votación de la mayoría»). Cuenta con tres versiones: la votación unánime (todos los clasificadores coinciden), la mayoría simple (coincidencia de más del 50 % de los votos) y la votación por mayoría (la etiqueta que más votos haya recibido, representado en la ilustración 3.4).

Sin embargo, si se sabe que algunos clasificadores son mejores que otros, se puede aplicar *weighted majority voting*, donde las etiquetas predichas por los estimadores con mejor rendimiento tienen más peso que el resto (se asigna una proporción).

Figura 3.4: Representación de la combinación mediante votación.



3.4. Métricas y técnicas de evaluación

En este trabajo de investigación se van a realizar continuamente comparaciones entre modelos de clasificación. Con el fin de hacerlo correctamente, es necesario definir unas métricas y técnicas de evaluación.

Métricas de evaluación

Estas se basan en conceptos que se exponen a continuación [28]:

- **Verdadero positivo o *True positive***: se obtiene cuando un clasificador acierta en su predicción y esta es la clase de interés. Generalmente es la clase «positiva» y, en el caso de la aplicación en la detección de ataques a sistemas de recomendación, la «minoritaria».
- **Verdadero negativo o *True negative***: resultado obtenido cuando un clasificador acierta en su predicción y esta no es la clase de interés.
- **Falso positivo o *False positive***: se obtiene cuando un clasificador falla en su predicción y predice que es la clase de interés, cuando en realidad no lo es.
- **Falso negativo o *False negative***: resultado obtenido cuando un clasificador falla en su predicción y afirma que una muestra no pertenece a la clase de interés, cuando en realidad sí pertenece.

- **Total:** la suma de los cuatro puntos anteriores equivale al total de predicciones ($T = TP + TN + FP + FN$).
- **Class imbalance problem:** es un problema que se genera cuando hay muy pocas instancias positivas en el conjunto de datos en comparación con las negativas (es decir, cuando hay un desequilibrio evidente entre ambas clases). Generalmente, causa que la *accuracy* (consultar ecuación 3.1) sea muy elevada, pero no se detecten instancias de la clase positiva, generando modelos inservibles.

Dadas las definiciones anteriores, se facilitan las siguientes métricas utilizadas [28]:

- **Accuracy, exactitud o porcentaje de acierto:** mide la tasa de aciertos de un determinado clasificador. A lo largo del proyecto, también es llamada «*score*».

$$Accuracy = \frac{|Aciertos|}{|Total|} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.1)$$

- **Error rate, o porcentaje de error:** mide la tasa de error del clasificador.

$$ErrorRate = \frac{|Fallos|}{|Total|} = \frac{FP + FN}{TP + TN + FP + FN} = 1 - Accuracy \quad (3.2)$$

- **Precisión:** mide cuántas predicciones son verdaderamente positivas entre todas las seleccionadas como tal.

$$Precision = \frac{TP}{TP + FP} \quad (3.3)$$

- **Recall, sensitivity o TPR (true positive rate):** determina la capacidad del clasificador para detectar clases positivas. En otras palabras, determina el porcentaje de positivos detectados sobre el total de positivos reales.

$$Recall = \frac{TP}{TP + FN} \quad (3.4)$$

- **FPR (*false positives rate*)**: determina cuántos negativos son clasificados como positivos sobre el total de negativos.

$$FPR = \frac{FP}{FP + TN} \quad (3.5)$$


- **Specificity**: determina cuántos elementos negativos son detectados.

$$Specificity = \frac{TN}{TN + FP} \quad (3.6)$$

- **F-Measure**: medida que combina la *precision* y el *recall*. Es de interés puesto que la meta general suele ser maximizar estas dos medidas.

$$F\text{-Measure} = 2 \times \frac{precision \times recall}{precision + recall} = \frac{2 \times TP}{2 \times TP + FP + FN} \quad (3.7)$$


Figura 3.5: Calidad del clasificador en función de su curva ROC. Extraída de https://ca.wikipedia.org/wiki/Fitxer:Roc_curve.svg



- **Curva ROC (*operating characteristic curve*)**: Representación gráfica del *recall* frente a la *specificity* [18]. Un clasificador perfecto tendría una «curva» equivalente a un punto en la esquina superior izquierda de la gráfica, mientras que el peor clasificador (uno aleatorio) obtendría una recta diagonal. Si la curva está por debajo de esta recta que divide el área en dos, significa que las predicciones están siendo «invertidas». Esta medida es popular debido a que no se ve afectada por problemas de clases no balanceadas [10]. Sin embargo, sí que es sensible cuando hay muy pocas instancias positivas en el *dataset* y las estimaciones pueden no ser certeras [27].

- **Curva PR (*precision-recall curve*):** Representación gráfica de la precisión frente al *recall*. Cuando se presenta un *class imbalance problem* con muy pocas clases positivas, es adecuado utilizar una curva de estas características debido a que la *precision* y el *recall* permiten evaluar la actuación del clasificador en la clase minoritaria [37].
- **AUC (*area under curve*):** Número decimal que representa el área bajo una determinada curva. Cuando una curva es perfecta (ya sea ROC o PR), su área es 1.

Figura 3.6: Representación de las curvas ROC y PR obtenidas por un *co-forest* entrenado con un *dataset* de clasificación binario.



Técnicas de evaluación

La validación cruzada es una técnica utilizada para evaluar los resultados de un modelo y garantizar que son independientes de la partición concreta de los datos de entrenamiento y prueba. Se utiliza en entornos donde el objetivo principal es la predicción y se quiere estimar la precisión real de un clasificador.


Aunque hay varias formas de realizar esta técnica, la principal (y la utilizada en este proyecto) es la validación cruzada de K iteraciones (*K-fold cross-validation*).

En este proceso los datos de muestra se dividen en K subconjuntos. Uno de los subconjuntos se utiliza como conjunto de *test* y el resto ($K-1$) como conjunto de entrenamiento. Este proceso se repite k veces, utilizando un subconjunto de prueba distinto cada vez [76].

Los resultados finales son la media aritmética de los obtenidos en cada iteración. De esta forma, se garantiza que los resultados obtenidos no son producto de una partición concreta de los datos.

La principal desventaja es que requiere un mayor uso de recursos computacionales, y aunque se puede asignar un entero cualquiera al parámetro k , lo más común es establecer $k = 10$ (10-fold cross-validation).

Figura 3.7: Proceso de validación cruzada. Extraída de https://es.wikipedia.org/wiki/Validacion_cruzada



3.5. Co-forest

Descripción

El denominado *co-forest* [48] es un método de clasificación para aprendizaje semisupervisado (más concretamente, de envoltura) que permite construir un *ensemble* de árboles de decisión (clasificación). Este método está basado en el *random forest* y se podría considerar su «versión semisupervisada».

Que sea un algoritmo semisupervisado implica que, durante la fase de entrenamiento, además de utilizar el conjunto de datos etiquetados (L), se utilicen también aquellas pseudo-etiquetas de las predicciones con mejor confianza del conjunto de datos no etiquetados (U).

El proceso de entrenamiento se realiza iterativamente [72], y en cada una de estas repeticiones, se examina cada árbol y se entrena individualmente

con un subconjunto de L (L_i) y con un subconjunto de U ($L'_{i,t}$) formado por aquellas pseudo-etiquetas que, además de pertenecer a la submuestra (aleatoria), posean un nivel de confianza superior a un umbral definido por el usuario (θ). Quienes estiman esta confianza de predicción para las muestras seleccionadas son el conjunto de todos los árboles que forman el *ensemble* menos el árbol que está siendo entrenado individualmente (de ahora en adelante *concomitant ensemble* o conjunto concomitante).

El criterio de parada de la fase de entrenamiento del *co-forest* es el *out-of-bag error* [81] (de ahora en adelante, OOB). Se define OOB como el error que comete el conjunto concomitante de un árbol para el total de los datos etiquetados. Es decir, el número de árboles que aciertan la etiqueta entre el número de árboles que votan teniendo en cuenta que, para calcular el OOB del total de los datos etiquetados, sólo votan aquellos árboles que no hayan utilizado la muestra concreta de L para su entrenamiento.

Algoritmo

Variables utilizadas

Para facilitar la comprensión del pseudocódigo, se definen a continuación algunas de las variables utilizadas:

- n : número total de árboles del ensemble.
- h_i : árbol i -ésimo del conjunto.
- H_i : *concomitant ensemble* o conjunto concomitante del árbol i -ésimo (todos los árboles del *co-forest* menos él).
- x_j : muestra j -ésima (generalmente sin etiqueta).
- $H_i(x_j)$: etiqueta asignada por H_i a la muestra j -ésima.
- $w_{i,t,j}$: confianza de predicción (individual) calculada para una muestra x_j por H_i en la iteración t . Se define confianza como el grado de acuerdo que existe en una votación.
- W : sumatorio de las confianzas de predicción individuales de un conjunto $W = \sum w_{i,t,j}$.
- L : conjunto de datos etiquetados utilizados durante el entrenamiento.
- L_i : subconjunto obtenido tras aplicar *bootstrapping* a L que se utiliza para entrenar el árbol h_i .

- U : conjunto de datos no etiquetados utilizados durante el entrenamiento.
- $U'_{i,t}$: subconjunto aleatorio de U cuya W es menor que W_{max} (consultar ecuación 3.12).
- $L'_{i,t}$: subconjunto formado por aquellas muestras de $U'_{i,t}$ cuya confianza de predicción es superior a θ .
- θ : nivel de confianza mínimo que tiene que tener el clasificador al predecir la etiqueta de una muestra de U para ser utilizada durante el entrenamiento de un árbol.
- $\hat{e}_{i,t}$: OOB comedido por H_i en L en el instante de tiempo t .

Pseudocódigo

Se facilita a continuación (pseudocódigo 1) la versión del *co-forest* de la tesis de Engelen [72], basada en la original [48], pero introduciendo los cambios observables en la sección «Discusión de los parámetros del algoritmo».

Fases

En primer lugar, se ha de construir un *random forest* de n árboles. Para introducir aleatoriedad, cada uno de esos árboles es entrenado utilizando un subconjunto aleatorio de L . Es decir, un subconjunto obtenido tras aplicar *bootstrap* a L .

Otro parámetro a tener en cuenta es el número de atributos a considerar en cada árbol de decisión. Por defecto, se ha establecido este valor al \log_2 del total (heurística de Breiman [72]). Sin embargo, también podría ser el la raíz cuadrada del total o el total, entre otros.

La segunda fase es entrenar el *random forest* de manera semisupervisada e iterativa hasta que se cumpla el criterio de parada (como se ha mencionado anteriormente, basado en el OOB). Para ello, se calcula el OOB de un árbol para una iteración. Si es superior al anterior, se considera que el rendimiento ha empeorado para ese árbol. El algoritmo finaliza cuando todos los árboles empeoran su rendimiento en una determinada iteración.

Por el contrario, en caso de que se haya mejorado, se toma una submuestra de U para pseudo-etiquetar (evidentemente, distinta para cada árbol). Posteriormente se examina cada una de las muestras que forman $U'_{i,t}$, y en

Algoritmo 1: Co-Forest

Input: Conjunto de datos etiquetados $L\{(x_i, y_i)\}_{i=1}^l$, conjunto de datos no etiquetados $U\{x_i\}_{i=l+1}^k$, número de árboles n y umbral de confianza θ

Output: *Ensemble* de árboles entrenado H .

```

1  for  $i = 0, \dots, n - 1$  do
2       $L_i \leftarrow Bootstrap(L)$ 
3       $h_i = EntrenarArbol(L_i)$ 
4       $\hat{e}_{i,t} \leftarrow 0,5$ 
5       $W_{i,0} \leftarrow InicializarW(L, criterio)$  // Consultar sección 5.1
6  end for
7   $t \leftarrow 0$ 
8  while Algún árbol recibe pseudo-etiquetas do
9       $t \leftarrow t + 1$ 
10     for  $i = 0, \dots, n - 1$  do
11          $\hat{e}_{i,t} \leftarrow OOB(E_i, L)$ 
12          $L'_{i,t} \leftarrow \emptyset$ 
13         if  $\hat{e}_{i,t} < \hat{e}_{i,t-1}$  then
14              $W_{max} = \hat{e}_{i,t-1} W_{i,t-1} / \hat{e}_{i,t}$ 
15              $U'_{i,t} \leftarrow Submuestrear(U, H_i, W_{max})$ 
16              $W_{i,t} \leftarrow 0$ 
17             foreach  $x_j \in U'_{i,t}$  do
18                 if  $Confianza(H_i, x_j) > \theta$  then
19                      $L'_{i,t} \leftarrow L'_{i,t} \cup x_j, H_i(x_j)$ 
20                      $W_{i,t} \leftarrow W_{i,t} + Confianza(H_i, x_j)$ 
21                 end if
22             end foreach
23         end if
24     end for
25     for  $i = 0, \dots, n - 1$  do
26         if  $(\hat{e}_{i,t} * W_{i,t} < \hat{e}_{i,t-1} * W_{i,t-1})$  then
27              $h_i = EntrenarArbol(L_i \cup L'_{i,t})$ 
28         end if
29     end for
30 end while
31 return  $H$ 

```

caso de que el nivel de confianza supere el umbral, se selecciona esa muestra para el entrenamiento (pasa a formar parte de $L'_{i,t}$).

El último paso sería reentrenar los árboles que hayan cambiado con su propio conjunto inicial de datos etiquetados unido a las pseudo-etiquetas generadas en la correspondiente iteración ($L_i \cup L'_{i,t}$). Es decir, en cada iteración se considera U al completo para poder generar la muestra con la que se pseudo-etiquete, y las anteriores pseudo-etiquetas para un árbol en concreto son descartadas [72].

Tratamiento del ruido y teoría de errores

Como se señala en el *paper* de Zhou y Duan [81], de acuerdo con el trabajo de Angluin y Laird [3], si el tamaño de los datos utilizados en el entrenamiento (m), la tasa de ruido (η), el error de la hipótesis en el peor caso (ϵ) y una constante (c) cumplen la relación de la ecuación 3.8, entonces la hipótesis aprendida por el árbol h_i (que minimiza el desacuerdo en un conjunto de muestras de entrenamiento con ruido) converge a la hipótesis verdadera.

$$m = \frac{c}{\epsilon^2(1 - 2\eta)^2} \quad (3.8)$$

De acuerdo con [81], se puede obtener la función de utilidad mostrada en la ecuación 3.9 operando en la expresión 3.8.

$$f = \frac{c}{\epsilon^2} = m(1 - 2\eta)^2 \quad (3.9)$$

Como se ha mostrado en el pseudocódigo, en la iteración i -ésima un determinado árbol se entrena con sus datos etiquetados L_i y un conjunto de pseudo-etiquetas $L'_{i,t}$. Si se considera que el OOB cometido en L por H_i es $\hat{e}_{i,t}$, entonces se puede estimar que el número de pseudo-etiquetas erróneas en $L'_{i,t}$ equivale a $\hat{e}_{i,t} \times W_{i,t}$ (se recuerda al lector que $W_{i,t}$ es el sumatorio de la confianza de predicción (grado de acuerdo) de H_i en cada muestra de $L'_{i,t}$). Por lo tanto, la tasa de ruido que se encuentra en $L_i \cup L'_{i,t}$ es la estimada por la ecuación 3.10, donde W_0 y η_0 son los parámetros correspondientes a L .

$$\eta = \frac{\eta_0 W_0 + \hat{e}_{i,t} W_{i,t}}{W_0 + W_{i,t}} \quad (3.10)$$

De acuerdo con la ecuación 3.9, la función de utilidad f es inversamente proporcional a ϵ^2 . Por lo tanto, si se quiere reducir el error cometido, se debe

aumentar la utilidad de cada árbol en cada iteración [81]. Consecuentemente, se debe cumplir la ecuación 3.11.

$$\frac{\hat{e}_{i,t}}{\hat{e}_{i,t-1}} < \frac{W_{i,t-1}}{W_{i,t}} < 1 \quad (3.11)$$

Discusión acerca de los parámetros del algoritmo

Intuitivamente se puede deducir la ecuación 3.11, ya que el error debe disminuir y la confianza de predicción aumentar con cada iteración. Sin embargo, aunque esto se cumpla, puede ser que se deje de cumplir que $\hat{e}_{i,t}W_{i,t} < \hat{e}_{i,t-1}W_{i,t-1}$, ya que puede ocurrir que $W_{i,t} \gg W_{i,t-1}$. Por este motivo y para cumplir con lo expuesto en la ecuación 3.11, se limita W_{max} como se muestra en la ecuación 3.12 al realizar el muestreo de U en el algoritmo.

$$W_{max} = \frac{\hat{e}_{i,t-1}W_{i,t-1}}{\hat{e}_{i,t}} > W_{i,t} \quad (3.12)$$

El algoritmo original propuesto por [48] y el utilizado en [81] dejan, sin embargo, una cuestión pendiente. Como se puede observar en la ecuación 3.12, W_{max} requiere para calcularse tanto el OOB como la W obtenida en la iteración anterior, y ambos autores inician W a 0. Esto implica que en la primera iteración $W_{max} = 0$ y, por lo tanto, evita que se realice un muestreo de U para pseudo-etiquetar (pararía el algoritmo). En su tesis, Engelen [72] propone solucionar este problema iniciando $W = \min(\frac{1}{10}|U|, 100)$. Sin embargo y tras consultarlo con expertos en el área, se ha decidido realizar una pequeña experimentación para probar cómo afecta la inicialización de este parámetro al rendimiento del algoritmo. Se puede consultar en la sección 5.1.

Decisiones de implementación

Además de los aspectos expuestos en el apartado anterior, hay dos decisiones adicionales que se han tomado en la implementación por no estar contempladas en el pseudocódigo original.

En primer lugar, el valor de W_{max} cuando $\hat{e}_{i,t}$ es 0. Como se puede comprobar en la fórmula 3.12, al estar en el denominador, se produce una indeterminación. Si el valor se sustituye por un número muy cercano a 0, W_{max} tiende a infinito, provocando una submuestra de U ilimitada. Como la función de W_{max} es determinar el tamaño de la submuestra, y en este

caso el error del conjunto concomitante es nulo, se ha decidido mantenerlo alto pero limitar a $\theta \times |U|$.

Por otro lado, tampoco se hace explícito cómo iniciar $W_{i,t}$ en aquellas iteraciones en las que no se cumple que $\hat{e}_{i,t} < \hat{e}_{i,t-1}$. Se puede pensar que se debe iniciar a 0. Sin embargo, esto causaría que en iteraciones posteriores nunca se genere una submuestra de U , pues como se puede comprobar en la ecuación 3.12 el tamaño de W_{max} sería 0. Por este motivo, se ha decidido iniciar $W_{i,t} \leftarrow W_{i,t-1}$.

3.6. *Tri-Training*

Descripción

El denominado *tri-training* [83] es un método de clasificación para aprendizaje semisupervisado perteneciente a la rama del *co-training*. Utiliza tres estimadores base (i , j y k) que son entrenados utilizando un conjunto de datos etiquetados L y pseudo-etiquetas generadas por el resto del conjunto.

Dos de las principales características que lo convierten en un algoritmo fácil de utilizar en escenarios reales de minería de datos es que no requiere vistas suficientes y redundantes de los datos ni el uso de distintos algoritmos de aprendizaje supervisado en los clasificadores base [83]. Sin embargo, sí que es un requisito que los estimadores base sean diversos.

El proceso de entrenamiento se realiza iterativamente, actualizando los estimadores base oportunos utilizando L y un subconjunto de U (L_i) pseudo-etiquetado por los dos clasificadores restantes. Este subconjunto se genera (para i) utilizando aquellas instancias de U en las que los estimadores concomitantes de i (es decir, j y k) concuerden en su etiqueta.

Por otro lado, el error para i se aproxima dividiendo el número de muestras de L para las cuales el conjunto concomitante de i realiza una predicción incorrecta entre el número total de muestras de L para las cuales la etiqueta predicha por j es la misma que la predicha por k .

Algoritmo

Variables utilizadas

Para facilitar la comprensión del pseudocódigo, se definen a continuación algunas de las variables utilizadas:

- h_i : estimador i -ésimo del *ensemble* (entrenado con un conjunto concreto de datos que puede variar en cada iteración).
- L : conjunto de datos etiquetados utilizados durante el entrenamiento.
- U : conjunto de datos no etiquetados utilizados durante el entrenamiento.
- S_i : subconjunto obtenido tras realizar *bootstrap* a L para un clasificador en concreto.
- L_i : subconjunto de U pseudo-etiquetado para i .
- l_i : tamaño del conjunto L_i en la iteración anterior (utilizable para saber si anteriormente un clasificador ha sido entrenado con pseudo-etiquetas o no).
- e_i : error del estimador i .
- e'_i : error anterior del clasificador i .

Pseudocódigo

Se facilita a continuación (pseudocódigo 2) el pseudocódigo original [83] del algoritmo *tri-training*.

Fases

En primer lugar, se entrenan los estimadores base utilizando un subconjunto aleatorio de L .

La segunda fase es entrenar el *tri-training* de manera semisupervisada e iterativa hasta que los estimadores base no reciban nuevas etiquetas del resto del *ensemble*. Para ello, se comprueba que el error (explicado anteriormente) sea menor que en la iteración anterior, y en ese caso, se genera L_i utilizando aquellas instancias de U en las que los estimadores concomitantes de i (es decir, j y k) concuerden en su etiqueta. En caso de que anteriormente no se haya entrenado con pseudo-etiquetas, se estima el valor que hubiese tenido el conjunto L_i anterior.

Posteriormente, se comprueba si el conjunto L_i nuevo es mayor que el anterior. En caso de que lo sea, se realizan algunas correcciones para evitar violar ecuaciones relacionadas con el tratamiento de errores. Puede llegar a ocurrir que se reduzca el tamaño de L_i durante este proceso.

Algoritmo 2: *Tri-Training*

Input: Conjunto de datos etiquetados L , conjunto de datos no etiquetados U , tres clasificadores base.

Output: *Ensemble* de tres estimadores base entrenados.

```

1  for  $i = 1, \dots, 3$  do
2     $S_i \leftarrow \text{Bootstrap}(L)$ 
3     $h_i \leftarrow \text{EntrenarClasificador}(S_i)$ 
4     $e'_i \leftarrow 0.5$ 
5     $l'_i \leftarrow 0.0$ 
6  end for
7  while Algún estimador base reciba pseudo-etiquetas do
8    for  $i = 1, \dots, 3$  do
9       $L_i \leftarrow \emptyset$ 
10      $\text{actualizar}_i \leftarrow \text{Falso}$ 
11      $e_i \leftarrow \text{Error}(h_i \& h_k)(j, k \neq i)$ 
12     if  $e_i < e'_i$  then
13       foreach  $x \in U$  do
14         if  $h_j(x) = h_k(x)$  ( $j, k \neq i$ ) then
15            $L_i \leftarrow L_i \cup \{(x, h_j(x))\}$ 
16         end if
17       end foreach
18       if  $l'_i = 0$  then
19          $l'_i \leftarrow \lfloor \frac{e_i}{e'_i - e_i} + 1 \rfloor$ 
20       end if
21       if  $l'_i < |L_i|$  then
22         if  $e_i \times |L_i| < e'_i \times l'_i$  then
23            $\text{actualizar}_i \leftarrow \text{Verdadero}$ 
24         end if
25         else if  $l'_i > \frac{e_i}{e'_i - e_i}$  then
26            $|L_i| \leftarrow \text{Submuestrear}(L_i, \lceil \frac{e'_i \times l'_i}{e_i} - 1 \rceil)$ 
27            $\text{actualizar}_i \leftarrow \text{Verdadero}$ 
28         end if
29       end if
30     end if
31   end for
32   for  $i = 1, \dots, 3$  do
33     if  $\text{actualizar}_i \leftarrow \text{True}$ 
34     then
35        $h_i = \text{Entrenar}(L \cup L_i)$ 
36        $e'_i \leftarrow e_i$ 
37        $l'_i \leftarrow |L_i|$ 
38     end if
39   end for
40 end while

```

El último paso sería reentrenar los clasificadores base que hayan recibido nuevas etiquetas con estas mismas unidas a L .

Tratamiento del ruido y teoría de errores

En este algoritmo no es necesario calcular explícitamente la «confianza» del conjunto para cada muestra de U debido a que, para que se añada a L_i , es suficiente con que los otros dos estimadores base del conjunto coincidan en la etiqueta [83]. Puede ocurrir que tanto j como k se equivoquen en una predicción y, por lo tanto, se añada ruido al conjunto de entrenamiento de i . Sin embargo, como se comentó anteriormente en el *co-forest*, de acuerdo con el trabajo de Angluin y Laird [3], si el tamaño de los datos utilizados en el entrenamiento (m), la tasa de ruido (η), el error de la hipótesis en el peor caso (ϵ) y una constante (c) cumplen la relación de la ecuación 3.8, entonces la hipótesis aprendida por el estimador h_i converge a la hipótesis verdadera.

Para cada iteración del algoritmo, se considera un L_i independiente y obtenido considerando todo U . El ratio del ruido de clasificación en la iteración t -ésima se puede calcular mediante la ecuación 3.13, donde \check{e}_1^t es el límite superior del error cometido por j y k en la iteración t , L^t es el conjunto de pseudo-etiquetas para i en la iteración t y η_L es la tasa de ruido en L .

$$\eta^t = \frac{\eta_L |L| + \check{e}_1^t |L^t|}{|L \cup L^t|} \quad (3.13)$$

Como se muestra en la función de utilidad de la ecuación 3.9, como f es inversamente proporcional a $\frac{c}{\epsilon^2}$, entonces se puede deducir que si $f^t > f^{t-1}$ entonces $e^t < e^{t-1}$, lo que implica que el clasificador i va a mejorar si se utilizan las pseudo-etiquetas de L^t en el entrenamiento [83].

3.7. *Democratic-co learning*

Descripción

El *democratic-co learning* es un método de aprendizaje semisupervisado que sólo necesita una vista de los datos para entrenarse y, además, es aplicable cuando se tiene un pequeño conjunto de datos etiquetados [82].

Como estimadores base se utiliza un conjunto de algoritmos de aprendizaje que se emplea para entrenar un conjunto de clasificadores. Teóricamente

este conjunto puede tener un tamaño arbitrario (n), aunque en el artículo original se utilizó $n = 3$ durante la experimentación.

Además, en la fase de predicción, el método cuenta con un algoritmo de combinación de etiquetas basado en el «peso» (como sinónimo de confianza) que tiene cada clasificador [82].

Algoritmo

Variables utilizadas

Se definen a continuación algunas de las variables utilizadas en el pseudocódigo facilitado en [82]:

- A_i : algoritmo de aprendizaje i -ésimo original (antes de ser entrenado).
- H_i : estimador i -ésimo del *ensemble* (entrenado con un conjunto concreto de datos que puede variar en cada iteración).
- L : conjunto de datos etiquetados utilizados durante el entrenamiento.
- U : conjunto de datos no etiquetados utilizados durante el entrenamiento.
- L_i : datos etiquetados utilizados para entrenar a i .
- L'_i : datos pseudoetiquetados propuestos (pueden ser rechazados) para añadir a L_i .
- e_i : estima el número de etiquetas erróneas contenidas en L_i .
- e'_i : estima la nueva tasa de error.
- q_i : estima la tasa de error.
- q'_i : estima la nueva tasa de error si se añade L'_i a L_i .
- c_j : conjunto de estimadores que concuerdan en que la etiqueta para una muestra x es j .
- l_i, h_i : límites inferior y superior del intervalo de confianza al 95 % para el estimador H_i .
- w_i : peso asociado al estimador H_i . Es el valor que estima la «confianza» que se tiene en un determinado clasificador base.

Pseudocódigo

Se facilita a continuación (pseudocódigo 3) el pseudocódigo original [82] del *democratic-co learning*.

Es probable que surja una cuestión: ¿qué ocurre con aquellas instancias de U que han sido permanentemente añadidas a un L_i en iteraciones posteriores? En este caso, se ha decidido actualizar la etiqueta existente previamente.

Fases

Durante el entrenamiento se pueden diferenciar distintas fases. De manera similar a otros algoritmos, el criterio de parada es que ningún clasificador reciba nuevas pseudoetiquetas (Es decir, ningún L_i cambia).

En cada iteración se entrena cada clasificador base con su conjunto de datos etiquetados (formado por L y pseudoetiquetas de iteraciones anteriores). Posteriormente, para cada muestra contenida en U , se genera un «grupo» que contiene aquellos clasificadores que coinciden en la etiqueta predicha para la muestra.

A continuación, se escogen aquellas muestras a añadir a los conjuntos L'_i (es decir, las muestras «propuestas»). Es destacable que estas nuevas etiquetas sólo se añaden al conjunto de entrenamiento de los clasificadores que han predicho una etiqueta diferente a la más votada.

Antes de añadir las muestras propuestas al conjunto de entrenamiento de los clasificadores de forma definitiva se estima si, con este nuevo cambio, se mejora la *accuracy*, y sólo se realiza en caso afirmativo. Este proceso se repite hasta cumplir el criterio de parada.

Combinación de los resultados y corrección de errores

Aunque la forma más simple de crear la hipótesis final es combinando mediante votación por mayoría, el *democratic-co learning* tiene en cuenta, además, la confianza individual que se tiene en cada clasificador (w_i) a la hora de realizar la predicción global.

De este modo, se dividen los clasificadores en grupos dependiendo de la etiqueta a la que hayan votado y se calcula la confianza media que se tiene en cada grupo. Para ello, además, se utiliza una corrección de Laplace (de la forma $s = \frac{n+0.5}{n+1}$) para evitar el sesgo generado cuando se tiene un grupo muy pequeño [82].

Algoritmo 3: *Democratic-co*

Input: Conjunto de datos etiquetados L , conjunto de datos no etiquetados U , clasificadores base (A_1, \dots, A_n) .

Output: *Ensemble* entrenado.

```

1  for  $i = 1, \dots, n$  do
2     $e_i = 0.0$ 
3     $L_i \leftarrow L$ 
4  end for
5  while Algún estimador base reciba pseudo-etiquetas do
6    for  $i = 1, \dots, n$  do
7       $H_i = \text{Entrenar}(A_i, L_i)$ 
8    end for
9    for  $x \in U$  do
10     for posible etiqueta  $j = 1, \dots, r$  do
11        $c_j = |\{H_i | H_i(x) = j\}|$ 
12     end for
13      $k = \text{argmax}_j \{c_j\}$ 
14   end for
15   # Se escogen las muestras a proponer para etiquetar
16   for  $i = 1, \dots, n$  do
17      $l_i, h_i = \text{Intervalo\_de\_confianza\_95 \%}(H_i, L)$ 
18      $w_i = (l_i + h_i)/2$ 
19   end for
20   for  $i = 1, \dots, n$  do
21      $L'_i = \emptyset$ 
22   end for
23   if  $\sum_{H_j(x)=c_k} w_j > \max_{c'_k \neq c_k} \sum_{H_j(x)=c'_k} w_j$  then
24      $L'_i = L'_i \cup \{(x, c_k)\}, \forall i$  tal que  $H_i(x) \neq c_k$ 
25   end if
26   # Se estima si añadir  $L'_i$  a  $L_i$  mejora la accuracy
27   for  $i = 1, \dots, n$  do
28      $l_i, h_i = \text{Intervalo\_de\_confianza\_95 \%}(H_i, L_i)$ 
29      $q_i = |L_i|(1 - 2(\frac{e_i}{|L_i|}))^2$ 
30      $e'_i = (1 - \frac{\sum_{i=1}^d l_i}{d})|L'_i|$ 
31      $q'_i = |L_i \cup L'_i|(1 - \frac{2(e_i + e'_i)}{|L_i \cup L'_i|})^2$ 
32     if  $q'_i > q_i$  then
33        $L_i = L_i \cup L'_i$ 
34        $e_i = e_i + e'_i$ 
35     end if
36   end for
37 end while
```

Algoritmo 4: *Predicción del democratic-co learning*

Input: Conjunto de instancias a predecir.

Output: Conjunto de etiquetas predichas.

```

1 for  $x$  perteneciente a las instancias a predecir do
2   for  $i = 1, \dots, n$  do
3     if  $H_i(x)$  predice la etiqueta  $c_j$  y  $w_i > 0.5$  then
4        $G_j = G_j \cup \{H_i\}$ 
5     end if
6   end for
7   for  $j = 1, \dots, r$  do
8      $\overline{C}_{G_j} = \frac{|G_j|+0.5}{|G_j|+1} \times \frac{\sum_{H_i \in G_j} w_i}{|G_j|}$ 
9   end for
10   $H$  predice con  $G_k$  para toda  $k = \operatorname{argmax}_j(\overline{C}_{G_j})$ 
11 end for

```

Debido a que este ajuste puede no resultar efectivo cuando los valores de confianza individuales para cada clasificador son muy dispares, se ignoran aquellos clasificadores con $w < 0.5$ (consultar algoritmo 4).

3.8. Proceso de minería de datos

Aunque es probable que el lector se sienta atraído por los algoritmos mostrados en secciones anteriores, se calcula que aproximadamente un 80 % [22] del esfuerzo en un proceso de minería de datos se destina a fases previas a la aplicación de los algoritmos. Por ello, se muestra a continuación el ciclo de vida del proceso (ilustrado en la imagen 3.8), donde se pueden diferenciar distintas fases [28]:

1. **Definición y comprensión del problema:** como se puede deducir, para que un modelo pueda llegar a ser útil, se han de definir bien las instancias. Es decir, la calidad de la solución depende de lo bien que pueda el analista (o ingeniero de datos) definir y modelar el problema. Por ello, es fundamental que la mayor parte del esfuerzo se dedique a conseguir un *dataset* apropiado y de calidad. Para ello, el primer paso, es comprender qué se quiere conseguir aplicando la minería y cuáles son los objetivos a perseguir.

2. **Adquisición de los datos:** el siguiente paso consiste en obtener los datos del problema que se quiere resolver. Para ello, se han de identificar las fuentes necesarias, recolectar e integrar los datos (incluso si este proceso requiere conversión y alineación). El resultado es un *dataset* coherente, aunque no listo para ser introducido en un algoritmo.
3. **Preparación de los datos:** se distinguen dos fases: la exploración y el preprocesado de los datos. El objetivo de la exploración es entender y definir los datos. Es decir, encontrar posibles correlaciones, tendencias o valores atípicos (*outliers*) con el fin de facilitar las fases posteriores. Por otro lado, el preprocesado busca preparar los datos para poder ser analizados. Para ello se ha de limpiar las instancias (eliminar duplicados, inconsistencias, valores perdidos, ruido, etc.), transformarlas (escalar rangos, reducir dimensiones o realizar filtrados) y, optativamente, seleccionar los atributos (o las instancias) que resulten relevantes para resolver el problema.
4. **Análisis de los datos:** en este apartado se seleccionan los algoritmos de *machine learning* (ML) apropiados para los datos (se recuerda que no existe ningún algoritmo que funcione siempre mejor que otros sino que cada problema tiene uno mejor adecuado), se construye el modelo, se entrena con los datos preparados y se evalúa el desempeño.
5. **Informe:** en esta fase se comunican los resultados utilizando gráficos, informes y todo tipo de herramientas que faciliten la comprensión del conocimiento expuesto.
6. **Actuación:** el último paso consiste en la toma de decisiones basadas en los informes generados. Es importante destacar que el impacto de las acciones tomadas ha de ser evaluado.

Este proceso es iterativo [22] y los resultados de unas fases pueden alimentar otras con nueva información mejorando así los resultados.

3.9. Conceptos básicos de ciberseguridad

Sin pretender profundizar en ningún aspecto en concreto, se enumeran a continuación algunos conceptos básicos de ciberseguridad necesarios para la correcta comprensión del documento.

Figura 3.8: Representación del proceso de minería de datos.



Sistemas de cifrado

Un sistema de cifrado es un algoritmo que convierte un texto plano (*input*) en un texto cifrado (*output*). La clave reside en que el nuevo texto es ilegible si se carece de la clave necesaria para descifrarlo, y debe ser lo suficientemente seguro como para que romperlo requiera una cantidad extremadamente grande de recursos (generalmente, tiempo) [7]. El cifrado es aplicable a datos almacenados o «en movimiento» (por ejemplo, intercambio de datos a través de internet).

Cifrado simétrico o criptografía de clave privada

En este tipo de algoritmos, la clave de cifrado y descifrado es la misma (de ahí que deba permanecer «privada»). Se conocen dos tipos, los cifrados de bloque y los cifrados de flujo [45].

En los cifrados de bloque, el texto se divide en bloques de una longitud fija y se cifran bloque a bloque. En función de los modos de operación (los más comunes ECB, CBC, OFB y CTR), también se pueden variar las

propiedades de los algoritmos. Algunos de los ejemplos más comunes son DES, Triple DES, AES o Twofish.

Cifrado asimétrico o criptografía de clave pública

En este tipo de sistemas, se utiliza una clave para cifrar los datos (la clave pública) y otra distinta para descifrarlos (la clave privada) [38]. Generalmente este tipo de cifrado es mucho más costoso computacionalmente [45], por ello no suelen ser utilizados cuando la cantidad de información a procesar es demasiado grande.

Algunos de los métodos más comunes son RSA o ECC (criptografía de curva elíptica). Dentro de este tipo de algoritmos también se encuentran los sistemas de intercambio de claves, como Diffie-Hellman.

Algoritmos de *hash*

Una función *hash* es simplemente un método de compresión de cadenas donde la entrada se denomina «mensaje» y la salida «*digest*». La característica principal de estos algoritmos es que la salida siempre cuenta con una longitud física independiente de los datos de entrada [45].

Cuando se habla de funciones *hash* criptográficas, el algoritmo debe tener diversas características, entre ellas: compresión, eficiencia, unidireccionalidad (dado un valor y , no se puede encontrar una x tal que $h(x) = y$), resistencia débil a colisiones (dado x y $h(x)$, es inviable encontrar $y \neq x$ tal que $h(x) = h(y)$) y resistencia fuerte a colisiones (es inviable encontrar x e y tales que $h(x) = h(y)$).

Un ejemplo de este tipo de algoritmos es el denominado SHA-512. Como curiosidad, ha sido el algoritmo elegido para cifrar las contraseñas de la aplicación *web* de este proyecto.

Peticiones HTTP

En la programación *web*, los clientes se comunican con los servidores realizando peticiones mediante el protocolo HTTP. El cliente realiza peticiones (*requests*) (por ejemplo, una petición *get* cuando se quiere solicitar un recurso o una *post* para enviar datos al servidor), mientras que el servidor responde mediante *responses*.

Estas peticiones contienen cabeceras y código de estado. Para el desarrollo de este proyecto, es importante conocer ciertos campos de la cabecera, entre

ellos las *cookies* (pueden ser usadas para indicar que se ha iniciado sesión), los *proxies* (o servidores intermedios) y el *user-agent* (información sobre el dispositivo que realiza una consulta). Estos campos pueden ser introducidos mediante código [20].

Además es destacable el código de estado, ya que permite conocer si una petición ha sido completada con éxito. En concreto, aquellos códigos comprendidos entre el 100 y el 199 son informativos, entre el 200 y el 299 son operaciones exitosas, entre el 300 y el 399 son redirecciones, entre el 400 y el 499 son errores por parte del cliente y entre el 500 y el 599 son errores por parte del servidor [21].

Comunicaciones anónimas

Las redes clásicas son sencillamente rastreables, como por ejemplo, hacer una consulta en internet. En este caso, el ordenador peticionario genera un paquete que circula hasta el *router* de la red a la que esté conectado. Este *router* lo reenvía a los DNS (*domain name service*) del ISP (*internet service provider*) correspondiente, y de ahí puede ir directamente a la página que se desea consultar, o, por el contrario, pasar por un mayor número de nodos intermedios.


Este camino es relativamente sencillo de rastrear [4], ya que los ISP tienen acceso a los metadatos de las comunicaciones. Adicionalmente, si el contenido de los mensajes se encuentra incorrectamente cifrado, puede derivar en un ataque a los mismos en caso de interceptación por parte de alguno de los nodos intermedios. Se puede pensar que ocultar esta información a terceros es tan sencillo como, por ejemplo, utilizar una de las bien conocidas VPN (*virtual private network*). Sin embargo, los proveedores de servicio de las VPN serán ahora quienes puedan acceder a los metadatos de las comunicaciones [44].

Enrutado cebolla, red Tor y protocolo SOCKS5

Uno de los protocolos que permite ocultar esta información es el llamado enrutado cebolla (*onion routing*) [31], que recibe su nombre por el sistema de capas que utiliza, como se representa en la imagen 3.9. En el mismo, se pueden diferenciar las siguientes fases [44]:

1. Fase uno: la petición se cifra en varias capas (el estándar es 3). Es decir, con la clave pública del nodo de salida, la del nodo intermedio

Figura 3.9: Infografía de la red Tor y del enrutado cebolla.



y, por último, al del nodo de entrada. Recordemos que para descifrar una capa, es necesario la clave privada del nodo correspondiente.

2. Fase dos: el servidor de entrada recibe la petición cifrada, y se encarga de descifrar la capa externa (posee la clave), obteniendo la dirección IP del nodo intermedio. De este modo, el servidor puede reenviar el mensaje a este último.
3. Fase tres: el servidor del medio descifra la siguiente capa y encuentra la dirección IP del nodo de salida. Reenvía el resto de la petición cifrada.
4. Fase cuatro: el servidor de salida descifra la última capa y accede a la petición. Sin embargo, no tiene información acerca de quién la realizó. Sí sabe, en su defecto, la dirección del nodo inmediatamente anterior, por lo que puede resolverla y devolvérsela.

La red Tor, utiliza este sistema [4] de enrutado. Para ello, calcula una ruta pseudo-aleatoria hacia destino, obteniendo las claves públicas de los nodos intermedios. Por otro lado, SOCKS5 es un protocolo de Internet usado por Tor [60] que permite redirigir el tráfico a través de la red Tor, actuando como un proxy de la capa de sesión del protocolo OSI. Por motivos de seguridad,

se usará más adelante para ocultar la dirección IP de los investigadores a la hora de extraer vectores de características de sitios *phishing*.


Ataques *web* y vulnerabilidades en navegadores

Cada vez que se visita una *web*, el navegador (ya sea en ventana o pestaña) carga el contenido, lo renderiza y responde a los eventos. Esto no deja de ser una oportunidad para los atacantes, que pueden utilizar las etiquetas HTML (por ejemplo, dentro de una imagen) para comunicarse con otros sitios o suplantar webs legítimas. Además, también pueden utilizar *scripts* para comunicarse con lugares externos (*remote scripting*).

Un ataque *web* es aquel en el que el atacante controla el sitio visitado (por ejemplo: `www[.]atacante[.]com`) [45]. Otro factor a tener en cuenta es que se pueden explotar las vulnerabilidades de los navegadores para atacar. Algunos de los escenarios más comunes se mencionan a continuación:

- **SQL Injection (SQLi)**: este tipo de ataque inyecta código con el fin de extraer información de una base de datos relacional. El escenario más común se da cuando, en un formulario, un usuario introduce una consulta de SQL con fines maliciosos [61] (por ejemplo, en lugar de unas credenciales). La solución se implementa a nivel de código, principalmente utilizando consultas parametrizadas. Una representación gráfica se puede observar en la imagen 3.10.


Figura 3.10: Infografía de un ataque SQL Injection.



- **Cross-site request forgery (CSRF)**: en este ataque se consigue que el navegador de un usuario legítimo envíe una petición HTTP

maliciosa a un sitio objetivo. A ojos del servidor atacado, la petición es realizada por el usuario genuino (ya que sus *cookies* son suplantadas), pero en realidad viene del atacante. El ataque puede originarse en forma de correos o páginas webs maliciosas, y el objetivo es una página legítima en la que el usuario ha tenido que iniciar sesión previamente. Las consecuencias (a parte de robo de información) son suplantaciones de identidad y se puede prevenir utilizando ciertas *flags* de sesión en las *cookies* o implementando *tokens* CSRF [5].

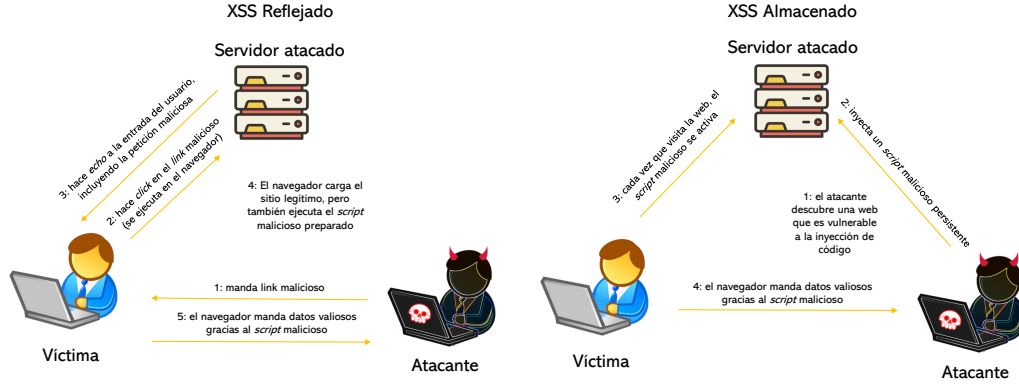
Figura 3.11: Infografía de un ataque CSRF.



- **Cross Site Scripting (XSS):** es uno de los ataques más populares existentes consistente en la inyección de código malicioso en el navegador de la víctima con el fin de robar información del usuario (*cookies* o *tokens* de sesión) [35]. Suele estar realizado con JavaScript y HTML (lado del cliente). Los dos escenarios más comunes son el XSS reflejado (la víctima recibe un enlace y se ejecuta código malicioso en su navegador) y el XSS almacenado (el *script* malicioso se guarda en el servidor de forma permanente y se ejecuta en todos los navegadores de todos los usuarios que visiten la *web*) [73].

La principal diferencia entre XSS y CSRF es que XSS es un ataque «de dos vías» (permite al atacante ejecutar código, recibir respuestas y reenviarlas) y CSRF es de «una vía» (el atacante sólo puede lanzar una petición HTTP corrupta), de forma que el alcance de CSRF es limitado, mientras que XSS permite al atacante realizar prácticamente lo que desee. Además, XSS no necesita que se haya iniciado sesión previamente para tener éxito [74].

Figura 3.12: Infografía de los tipos de ataque XSS existentes: reflejado y almacenado.



3.10. Ataques a sistemas de recomendación

Los ataques a los sistemas de recomendación (generalmente denominados *shilling attacks* [52] o *profile injection attack* [77]) tienen como objetivo manipular las sugerencias que propone un determinado algoritmo para conseguir que un cliente se incline hacia un elemento deseado. Esta alteración del sistema se consigue inyectando perfiles falsos.

Múltiples estudios se han centrado en formalizar las características de estos ataques con el fin de detectarlos. Entre ellas se encuentran [52]:

- **Intención:** normalmente, se pretende manipular la opinión general acerca de un elemento (ya sea para bien o para mal). Según el objetivo se pueden diferenciar dos tipos de ataques: *push attacks*, que pretenden hacer un objeto más atractivo o *nuke attacks*, cuya intención es la contraria. En caso de que el atacante no busque alterar la opinión acerca de un producto sino restar credibilidad a un sistema (mediante valoraciones aleatorias), se habla de *random vandalism* [11].
- **Fuerza:** la calidad de los ataques se mide teniendo en cuenta el tamaño del relleno (número de valoraciones asignadas a un perfil atacante, que suele rondar entre el 1 y el 20 % del total de los ítems [52]), correspondiente a la ecuación 3.14 y el tamaño del ataque (número de perfiles inyectados en el sistema, rondando entre el 1 y el 15 %), correspondiente a la ecuación 3.15 .

$$Fillersize = \frac{|I_a|}{|I|} \quad (3.14)$$

$$Attacksize = \frac{|U_a|}{|U_g|} \quad (3.15)$$

- **Coste:** se distinguen dos tipos: *knowledge-cost*, que hace referencia al coste de construir perfiles y *deployment-cost*, que es el número de perfiles que se deben inyectar para conseguir un ataque efectivo [77].

Tipos de ataques

En la actualidad se distinguen multitud de ataques distintos. Con el fin de formalizarlos matemáticamente, se han establecido ciertos conjuntos de interés dependiendo de los ítems que contengan [81].

- I_S : conjunto de ítems seleccionados para recibir un tratamiento especial (puede ser vacío).
- I_F : conjunto de ítems seleccionados para «rellenar».
- I_0 : conjunto de ítems pertenecientes al sistema de recomendación sin valorar.
- I_t : conjunto de ítems objetivo.

Ataques básicos

Se distinguen dos tipos: *random attack* y *average attack* [52]. Ambos tienen parámetros y características muy similares, como se muestra en la tabla 3.1. La principal diferencia reside en que el *average attack* es mucho más potente debido a que cuenta con mayor información acerca del sistema: las valoraciones a los ítems de relleno siguen una distribución $\mathcal{N}(\mu_i, \sigma_i)$, en lugar de $\mathcal{N}(\mu, \sigma)$. Es decir, la valoración para un determinado ítem se adecúa a la distribución concreta de ese ítem en lugar de a la de todo el *dataset*.

Ataques con poco conocimiento del sistema

Los más populares son *bandwagon attack* (o *popular attack*) y *segment attack*. Sus principales rasgos se ilustran en la tabla 3.2.

La principal característica del *bandwagon attack* es que el conjunto I_S ya no está vacío, sino que contiene algunos de los ítems más populares de la base de datos [81]. Estos ítems recibirán también la máxima puntuación

Modelo	I_S	Valoración I_F	I_0	Valoración I_t
Random	\emptyset	Aleatoria siguiendo una distribución normal definida por todas las valoraciones para todos los ítems del sistema $\mathcal{N}(\mu, \sigma)$.	\emptyset	máxima o mínima
Average	\emptyset	Aleatoria siguiendo una distribución normal definida por las otras valoraciones para ese ítem en concreto $\mathcal{N}(\mu_i, \sigma_i)$.	\emptyset	máxima o mínima

Tabla 3.1: Descripción de los ataques básicos [81].

Modelo	I_S	Valoración I_F	I_0	Valoración I_t
Bandwagon (average)	Ítems populares (valoración máxima) o ítems desfavorecidos (puntuación mínima) (reverse)	Aleatoria siguiendo una distribución normal definida por las otras valoraciones para ese ítem en concreto $\mathcal{N}(\mu_i, \sigma_i)$.	\emptyset	máxima o mínima (reverse)
Bandwagon (random)	Ítems populares (valoración máxima) o ítems desfavorecidos (puntuación mínima) (reverse)	Aleatoria siguiendo una distribución normal definida por todas las valoraciones para todos los ítems del sistema $\mathcal{N}(\mu, \sigma)$.	\emptyset	máxima o mínima (reverse)

Tabla 3.2: Descripción de los ataques con poco conocimiento del sistema.

posible, de forma que ya no sólo se puntúa el conjunto objetivo. Existe una variante de este ataque llamada *reverse bandwagon attack*, cuyo objetivo es hacer *nuke*, es decir, I_S contiene los ítems menos populares y reciben la puntuación mínima (junto con I_t).

En el *segment attack*, se realiza un pequeño «estudio de mercado» y se introduce en I_S ítems en los que estaría interesado un usuario que fuese a valorar también I_t (de forma que el ataque es más realista).

Modelo	Estrategia de ofuscación
Noise Injection	$\forall i \in I_F \cup I_S : R_i = r_i + \text{aleatorio} * \alpha$
Target Shifting	$\forall i \in I_F \cup I_S : R_i = r_i; I_T : r_{max} - 1 \text{ o } r_{min} + 1$
AOP	I_F escogido del top ítems más populares.

Tabla 3.3: Descripción de las estrategias de ofuscación.

Ataques con gran conocimiento del sistema

Este tipo de ataques resulta menos relevante que los anteriores debido a la dificultad de su ejecución. En la mayoría de los casos, se necesita una gran cantidad de información, siendo poco realista que se produzca una situación de estas características en la realidad.

Por ejemplo, el llamado *perfect knowledge attack* [77] basa su efectividad en reproducir la distribución exacta de la base de datos real (exceptuando los ítems objetivos). El *sampling attack* construye los perfiles a inyectar basándose en una muestra de perfiles reales [52].

Como se puede intuir, conocer datos estadísticos exactos sobre una base de datos o metadatos asociados a perfiles de usuarios es poco realista (cada vez menos debido a las mayores medidas de seguridad) y por lo tanto estos ataques resultan meramente teóricos.

Ataques ofuscados

Los ataques ofuscados [52] se basan en intentar «camuflar» los perfiles inyectados haciéndolos pasar por reales. Algunas de las características de su implementación se pueden consultar en la tabla 3.3.

El ataque de *noise injection* introduce a los conjuntos I_S e I_F un «ruido» (número aleatorio que sigue una distribución Gaussiana) multiplicado por una constante α . *Target shifting* incrementa (o decrementa) en una unidad la valoración de I_t con el fin de crear diferencias entre ataques similares sin influir excesivamente el resultado y el *Average over popular items* (AOP) pretende ofuscar el *average attack* cambiando la forma de selección de I_F (en lugar de seleccionar los ítems del conjunto total de la colección, se seleccionan los $X\%$ ítems más populares).

Otros tipos de ataques

Además de los ataques previamente ilustrados, existen otros con objetivos más diversos o estrategias distintas. El anteriormente mencionado *random*

vandalism (cuya intención únicamente es degradar la calidad del recomendador para causar descontento entre los usuarios) pertenece a esta categoría. Se pueden distinguir, además, ataques basados en copiar comportamientos de usuarios influyentes (modelo PUA (*Power User Attack*)) o ítems poderosos (PIA (*Power Item Attack*)) [52]. Sin embargo, son menos populares.

Extracción de vectores de características

Para que un problema pueda ser analizado por un algoritmo de aprendizaje, cada una de las instancias que lo compone ha de poder ser representada en un vector de características. Como se puede comprobar en el *paper* de Zhou y Duan [81] los perfiles de usuarios normales son distinguibles de los atacantes debido a su forma de puntuar. En función de estos hábitos, se puede elaborar un método de detección basado en ventanas.

En primer lugar, se dividen todos los ítems del *dataset* en ventanas, consiguiendo un conjunto de J ventanas ($\{w_1, w_2, \dots, w_J\}$). No se aplica ningún orden especial, sino que se respeta el que aparece en la propia base de datos. El número de ítems que posee cada ventana se reparte como se muestra en la ecuación 3.10, donde Q es el cociente de dividir el número total de ítems entre J .

$$|w_j| = \begin{cases} Q + 1, & j < q \\ Q, & j \geq q \end{cases}$$

Posteriormente se calcula, para cada usuario y ventana, NRW_{u,w_j} y $WNRW_{u,w_j}$ como se muestra en las ecuaciones 3.16 y 3.17 respectivamente. NRW son las siglas de *number of ratings per window*, y $WNRW$ *weighted number of ratings per window*. Es decir, para un determinado usuario, el número de votaciones que haya realizado en una ventana y el ratio de esta respecto al total.

$$NRW_{u,w_j} = \sum_{i \in w_j, r_{u,i} \neq 0} 1 \quad (3.16)$$

$$WNRW_{u,w_j} = \frac{\sum_{i \in w_j, r_{u,i} \neq 0} 1}{\sum_{i \in I, r_{u,i} \neq 0} 1} \quad (3.17)$$

Aplicando estas fórmulas como se muestra en el pseudocódigo 5, se obtienen los vectores de características. Como se puede deducir, este algoritmo se aplica indistintamente a perfiles genuinos y atacantes, ya que únicamente

se precisan las reseñas del usuario. Para una mayor comodidad a la hora de experimentar con estos datos, se han generado ficheros `.csv` con los vectores de características que posteriormente se importarán mediante Pandas para generar conjuntos de entrenamiento y *test*. Debido a que se trata de un problema de clasificación binaria, los perfiles atacantes reciben una etiqueta de 1 y los verdaderos un 0. Cabe destacar, que debido a que en el conjunto de MovieLens todos los usuarios son genuinos, se han de generar las reseñas de los perfiles atacantes.

Algoritmo 5: Algoritmo de generación de vectores de características.

Input: Conjunto de usuarios S , número de ventanas J , conjunto de reseñas del usuario R .

Output: Conjunto de vectores de características X .

```

1  $X \leftarrow \emptyset$ 
2 for  $u \in S$  do
3   for  $j \in J$  do
4     Calcular  $NRW_{u,w_j}$ 
5     Calcular  $WNRW_{u,w_j}$ 
6   end for
7    $x_u \leftarrow \{NRW_{u,w_1}, WNRW_{u,w_1}, \dots, NRW_{u,w_j}, WNRW_{u,w_j}\}$ 
8    $X \leftarrow X \cup x_u$ 
9 end for
10 return  $X$ 

```

3.11. Phishing

El *phishing* es una técnica de ingeniería social¹ en la que un atacante suplanta la identidad de una entidad de confianza con el fin de extraer datos o información personal de un determinado usuario. Este tipo de ataque suele enviarse mediante correo electrónico o mensajes de texto, y suelen incluir imágenes de la marca y un enlace con sintaxis muy parecida a la original (camuflada mediante el uso de técnicas como Leet Speak²). Generalmente suelen redireccionar a páginas *web* con formularios de inicio de sesión o

¹Técnica empleada por atacantes para ganarse la confianza de un usuario y conseguir que realice las acciones que desea (por ejemplo, ejecutar programas maliciosos, comprar en sitios fraudulentos, facilitar sus claves, etc.) [39].

²Lenguaje utilizado para evitar la búsqueda por palabras clave (por ejemplo, sustituyendo caracteres por dígitos de apariencia similar).

algún campo similar para que el usuario introduzca sus datos personales, pero también pueden incluir archivos infectados [8].

Hay multitud de variaciones dentro del *phishing*, pero algunos de los ataques más comunes se enumeran a continuación [62]:

- ***Spear phishing***: este tipo de ataque es «personalizado», es decir, el atacante conoce la información personal de la víctima y la utiliza con el fin de que sus ataques parezcan más legítimos.
- ***Whaling phishing***: es similar al anterior, solo que el objetivo suele ser un subconjunto de personas (por ejemplo, una pequeña red dentro de una empresa). La intención en este caso suele ser conseguir información clasificada de una entidad en concreto.
- ***Smishing***: nombre que recibe la variación de *phishing* que se realiza por mensajes SMS.
- ***Malvertising***: en este caso, los atacantes pagan a anunciantes verídicos para que muestren sus páginas en redes sociales u otros sitios *web* con el fin de que los usuarios de estas naveguen a los enlaces maliciosos.

El impacto de un ataque de *phishing* varía en función de la víctima. A nivel personal, una estafa exitosa puede suponer cargos económicos fraudulentos, pérdida de acceso a archivos personales y suplantación, entre otros. Sin embargo, a nivel corporativo, un ataque realizado correctamente puede acarrear filtraciones de datos clasificados e información de clientes, pérdida de acceso a archivos, exposición de los trabajadores, etc. Debido a que los daños pueden ser irreparables y este tipo de ataque es uno de los más comunes, se han de encontrar medidas de seguridad aplicables a la detección de los mismos [51].

Técnicas auxiliares

Se exponen a continuación algunas de las técnicas auxiliares más comunes tanto a la hora de realizar ataques de *phishing* como a la hora de detectarlos.

Leet Speak, 1337 5p34k o escritura *leet*

La escritura *leet* es un lenguaje utilizado en la informática cuando se quiere evitar que ciertos archivos (o páginas *web*) se descubran mediante la búsqueda por palabras clave [84]. La aplicación más sencilla es sustituir

aquellas letras que se parezcan a números por estos mismos. Por ejemplo, en lugar de escribir *password*, se podría utilizar **p4\$\$w0rd**.

Es común que páginas de *phishing* utilicen estas técnicas con el fin de confundir al usuario. Por ejemplo, si un enlace contiene la palabra *Office* en lugar de *Office*, es sencillo que un usuario que no esté prestando especial atención caiga en la estafa por no haberse percatado de que la letra O mayúscula es, en realidad, un cero.

TF-IDF

TF-IDF es un algoritmo que pretende definir la importancia que tiene una determinada palabra dentro de un documento teniendo en cuenta la relación que pueda tener con otros documentos dentro del mismo cuerpo [9]. Es decir, es una especie de «puntuación» para cada palabra del texto que aumenta cada vez que hay una ocurrencia, pero disminuye gradualmente cada vez que aparece en el resto de la colección. Por este motivo, puede ser realmente útil a la hora de extraer *keywords* [80]. Se basa en dos principios:

1. Una palabra que aparezca con mucha frecuencia en un documento tiene especial importancia para el mismo, por lo que es probable que el texto tenga relación con esa palabra.
2. Una palabra que aparezca repetidamente en varios documentos no sirve para identificar uno (o un pequeño subconjunto) en una colección (no sirve como *keyword*), por lo que no es relevante para el mismo.

Para calcular esta puntuación, se han de utilizar las ecuaciones facilitadas a continuación, donde N es el número de documentos disponibles, d es un documento en concreto, D es la colección de todos los documentos y w es una palabra dentro de un documento.

- **TF**: la frecuencia de una palabra w en un documento d se calcula con la ecuación 3.18.

$$\text{tf}(w,d) = \log(1 + f(w,d)) \quad (3.18)$$

- **IDF**: la frecuencia inversa de una palabra w en la colección d se calcula con la ecuación 3.19, aunque puede implementarse de otras maneras [46] en función del peso que se quiera dar.

$$\text{idf}(w,D) = \log \left(\frac{N}{f(w,D)} \right) \quad (3.19)$$

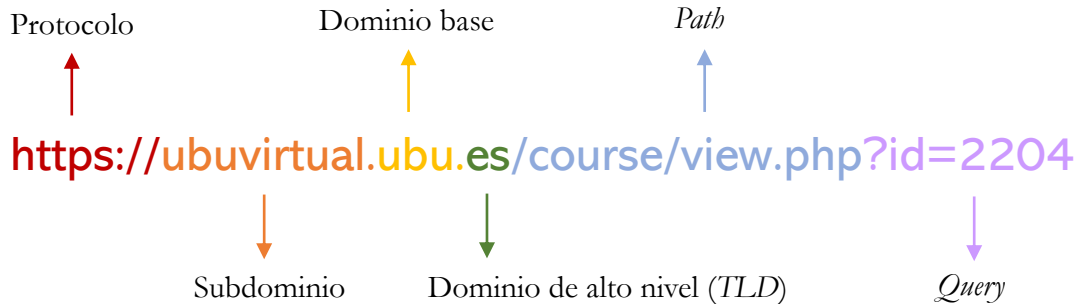
- **TF-IDF**: la puntuación TF-IDF se obtiene en combinación de las dos puntuaciones anteriores.

$$\text{tf-idf}(w,d,D) = \text{tf}(w,d) \times \text{idf}(w,D) \quad (3.20)$$

Extracción de vectores de características

Para caracterizar un enlace de *phishing* desde el lado del cliente, es suficiente con fijarse en cinco tipos de atributos clasificados en función de lo que definen [41]: las características basadas en la URL, las basadas en la aparición del formulario de *login*, las basadas en los hiperenlaces contenidos, las basadas en el fichero CSS y, por último, las basadas en la identidad de la página web.

Figura 3.13: Ilustración que muestra la anatomía de una URL.



Características basadas en la URL

Estas son aquellas que se extraen de una URL (cuya anatomía se muestra en la ilustración 3.13) y están definidas por parámetros como la longitud, tipo de caracteres contenidos, etc. En concreto, se extraen 8 características distintas enumeradas a continuación:

- **F1**: en general, los dominios legítimos no contienen más de tres puntos en la URL [41]. Por lo tanto, esta característica se establece a 1 si el número de puntos en la URL es mayor o igual que 4.

$$F1 = \begin{cases} 1, & \text{puntos en URL} \geq 4 \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F2:** determina la existencia de ciertos caracteres especiales en las URL. En concreto, el uso de «@» (provoca que se ignore todo lo escrito anteriormente al símbolo) y «-» (utilizado para engañar a los usuarios en enlaces como por ejemplo [www\[.\]paypal-india\[.\]com](http://www[.]paypal-india[.]com)) [41].

$$F2 = \begin{cases} 1, & \text{URL contiene «@» o «-»} \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F3:** normalmente, los dominios oficiales son cortos y significativos. Sin embargo, aquellos sitios de *phishing* suelen ser más largos (con el fin de confundir al usuario u ocultar información).

$$F3 = \begin{cases} 1, & \text{si la longitud de la URL} \geq 74 \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F4:** según [41], es común que las páginas de *phishing* añadan palabras clave en los enlaces para ganar la confianza de sus víctimas. En concreto, estas palabras son: *security*, *login*, *signin*, *bank*, *account*, *update*, *include*, *webs* y *online*. Como aportación propia, se ha tenido en cuenta que estas palabras puedan estar escritas utilizando el lenguaje *leet*.

$$F4 = \begin{cases} 1, & \text{si la URL contiene palabras sospechosas} \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F5:** en los dominios legítimos, el TDL no está presente en la parte perteneciente al dominio base, ni ocurre más de una vez en la dirección.

$$F5 = \begin{cases} 1, & \text{si el TDL está presente en la zona del dominio} \\ 1, & \text{si hay más de un TDL en la URL} \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F6:** en sitios genuinos, la cadena «http» sólo se encuentra una vez en la sección del protocolo. Sin embargo, puede ser que ocurra más de una vez si se trata de un sitio *phishing*.

$$F6 = \begin{cases} 1, & \text{si la URL contiene más de una vez la cadena «http»} \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F7**: la gran mayoría de los sitios de *phishing* contienen el nombre de la marca objetivo en la URL. Por ello, se han seleccionado algunos de los objetivos más comunes para los atacantes (por ejemplo, Google o PayPal) y, si se encuentra el nombre en una posición incorrecta, se asume que se trata de un intento de estafa. Nuevamente, se ha tenido en consideración que dichas palabras puedan estar escritas utilizando *leet*.

$$F7 = \begin{cases} 1, & \text{si la URL contiene el nombre de una marca famosa en la} \\ & \text{URL y la posición no es la correcta} \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F8**: según [41], los ataques basados en la existencia de un *Data URI* son muy comunes. Este esquema permite insertar datos en línea dentro de un documento. El peligro reside en que esos datos pueden codificar cualquier tipo de archivo (por ejemplo, un *script* de Javascript), pudiendo extraer datos o incluso realizar ataques XSS [49]. Un *Data URI* se reconoce por seguir la siguiente sintaxis: `data:[<mime type>][;charset=<charset>][;base64],<encoded data>` [14].

$$F8 = \begin{cases} 1, & \text{si la página contiene algún Data URI} \\ 0, & \text{cualquier otro caso} \end{cases}$$

Características basadas en la aparición del formulario de *login*

Esta es aquella que se basa en la aparición de un formulario de inicio de sesión.

- **F9**: es común que los sitios de *phishing* incluyan formularios de inicio de sesión debido a que es una forma común de introducir datos personales. En concreto, la diferencia reside en que en los sitios legítimos el campo de acción suele contener un enlace con el mismo dominio base que el sitio inicial. Sin embargo, en los sitios de *phishing* esto no es así. Hay otras variaciones como campos vacíos, con enlaces nulos o archivos PHP (por ejemplo: `login.php`) que almacenen las credenciales. Por lo tanto:

$$F9 = \begin{cases} 1, & \text{si el valor del campo de acción está vacío, «\#» o} \\ & \text{es javascript:void(0)} \\ 1, & \text{si el valor del campo de acción posee una sintáxis} \\ & \text{compatible con «fichero.php»} \\ 0, & \text{cualquier otro caso} \end{cases}$$

Características basadas en los hiperenlaces contenidos

- **F10**: normalmente, los sitios *phishing* contienen menos páginas (por ejemplo, un enlace a una página de *login*) que los legítimos. Estos se encuentran contenidos en el atributo «*src*» de las etiquetas pertenecientes a imágenes, *scripts*, *frames*, etc., además del atributo «*href*» de la etiqueta ancla [19].

$$F10 = \text{enlaces presentes en el sitio } web \quad (3.21)$$

- **F11**: por el contrario, también es muy sospechoso que una página *web* no contenga ningún hiperenlace debido a que se podrían estar utilizando técnicas de ocultación de sitios peligrosos para esquivar sistemas *anti-phishing* [30].

$$F11 = \begin{cases} 1, & \text{si la página no contiene enlaces} \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F12**: debido a que los sitios atacantes suelen imitar la estética de sus objetivos, es común que posean múltiples hiperenlaces que apunten a sitios externos. Se consideran externos a aquellos enlaces absolutos [71] distintos al sitio base.

$$F12 = \begin{cases} 1, & \text{si el ratio } \frac{\text{enlaces externos}}{\text{enlaces totales}} > 0.5 \text{ y el número de enlaces} > 0 \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F13**: cuando un enlace está vacío, si el usuario pulsa, es redirigido a la misma página de la que se parte (es decir, no hay redirección a un sitio distinto), lo que incrementa las posibilidades de que la víctima caiga en el ataque. Además, también se pueden utilizar otro tipo de vulnerabilidades existentes en los navegadores para aumentar la tasa de éxito. Algunos ejemplos son [41]: ``, `` o ``.

$$F13 = \begin{cases} 1, & \text{si el ratio } \frac{\text{enlaces vacíos}}{\text{enlaces totales}} > 0.34 \text{ y el número de enlaces} > 0 \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F14**: se considera un enlace erróneo aquel que devuelve un código 403 o 404 cuando se pulsa en él.

$$F14 = \begin{cases} 1, & \text{si el ratio } \frac{\text{enlaces erróneos}}{\text{enlaces totales}} > 0.3 \text{ y el número de enlaces} > 0 \\ 0, & \text{cualquier otro caso} \end{cases}$$

- **F15**: es común que los atacantes traten de confundir al usuario redirigiendo su solicitud a lugares externos. Una redirección se identifica gracias a su código de respuesta, que es un 301 o un 302.

$$F15 = \begin{cases} 1, & \text{si el ratio } \frac{\text{enlaces que redirigen}}{\text{enlaces totales}} > 0.3 \text{ y el número de enlaces} > 0 \\ 0, & \text{cualquier otro caso} \end{cases}$$

Características basadas en el fichero CSS

- **F16**: para imitar la estética de un sitio legítimo, los atacantes podrían utilizar su fichero CSS. Un CSS es una hoja de estilos que define el aspecto visual de una página *web*, y puede estar incrustado en el propio HTML de la página o ser un fichero externo [68]. En el caso de ser único y externo, se entiende que puede tratarse de un intento de estafa.

$$F16 = \begin{cases} 1, & \text{si existe un fichero CSS y es externo} \\ 0, & \text{cualquier otro caso} \end{cases}$$

Características basadas en la identidad de la página *web*

- **F17**: las páginas legítimas suelen contener el nombre del dominio en la sección dedicada a *copyright* (que se ubica por encontrarse a continuación de los símbolos «@», «©», o de las frases *© copy*, *copyright* o *all right reserved*).

$$F17 = \begin{cases} 0, & \text{si las palabras del } \textit{copyright} \text{ están en el dominio base} \\ 1, & \text{cualquier otro caso} \end{cases}$$

- **F18**: para cada página *web*, se ha construido un conjunto de *keywords* compuesto por las palabras contenidas en el título, en las etiquetas *meta* (cuyo campo *name* equivalga a *description* o *keywords* [40]) y por las más relevantes del cuerpo del sitio (extraídas mediante el algoritmo TF-IDF [80]). Lo más común es que los sitios legítimos contengan al menos una de estas palabras en el dominio base. En caso contrario, se considera un intento de *phishing*.

$$F18 = \begin{cases} 0, & \text{si una } keyword \text{ coincide con el dominio base} \\ 1, & \text{cualquier otro caso} \end{cases}$$

- **F19**: un *favicon* es una miniatura asociada a una página *web*. Por ello, los atacantes pueden plagiar los iconos de los sitios legítimos para ganarse la confianza de los usuarios. De este modo, se considera intento de estafa cualquier icono que contenga un enlace externo. Para localizarlos, se ubica el atributo «*rel*» dentro de las etiquetas «*link*» y se comprueba que su valor sea la cadena *shortcut icon* o *icon* (por ejemplo: `<link type='image/png' href='«enlace»' rel='shortcut icon'>`).

$$F19 = \begin{cases} 1, & \text{si se encuentra un dominio externo en el } favicon \\ 0, & \text{cualquier otro caso} \end{cases}$$

4. Técnicas y herramientas

En esta sección se pretende introducir al lector en algunas de las técnicas y herramientas relevantes en el desarrollo del proyecto.

4.1. Técnicas

Se presentan a continuación algunas de las técnicas más influyentes en materias relacionadas con este trabajo de investigación:

CRISP-DM

Una metodología común, no propietaria y abierta de desarrollo para proyectos de ML es CRISP-DM (Cross-Industry Standard Process for Data Mining). Nacida del trabajo conjunto de un grupo de empresas, consta de un proceso iterativo y adaptable.

Sin pretender desarrollar exhaustivamente la misma, se muestra a continuación un resumen de sus 6 principales fases [28].

1. **Compresión del negocio:** el objetivo de esta fase es entender los requerimientos del proyecto observados bajo un prisma empresarial y aplicar dicho conocimiento a la definición del problema de minería de datos.
2. **Compresión de los datos:** consiste en recopilar y explorar los datos con el objetivo de conocerlos. También se pretende identificar problemas de calidad y posibles subconjuntos de datos con especial interés para ser analizados.

3. **Preparación de los datos:** se busca procesar el conjunto de datos seleccionado con el fin de ser utilizable en algoritmos de ML. Por lo tanto, se incluyen todas las tareas de adecuación de los datos al problema de aprendizaje que se consideren necesarios.
4. **Modelado:** en esta fase se pretende aplicar las técnicas de ML seleccionadas a las vistas obtenidas anteriormente, y se evalúa utilizando técnicas específicas de aprendizaje.
5. **Evaluación:** a diferencia de la fase anterior, se busca evaluar el modelo desde el punto de vista del objetivo del negocio. Es decir, determinar si responde ante los objetivos empresariales planteados con anterioridad.
6. **Despliegue y explotación:** en la última fase, se integran los modelos en los procesos de la organización y se aprovecha el conocimiento generado.

Es relevante destacar la naturaleza cíclica y no rígida de la metodología, permitiendo que algunas fases alimenten sus predecesoras o que incluso algunos proyectos motiven el lanzamiento de otros.


DevOps y CI/CD

CI/CD (*continuous integration and continuous delivery*) se refiere al conjunto de prácticas de desarrollo que permite la entrega rápida y fiable de código gracias a la automatización de procesos [70], mientras que DevOps es la cultura que engloba estas prácticas buscando lograr un desarrollo de *software* más eficaz. El ciclo de vida³ se muestra en la imagen 4.1.

CI (integración continua) es la práctica que permite integrar repetidas veces en pequeños segmentos temporales cambios en un repositorio de código. En este proyecto, para garantizar que los nuevos cambios introducidos en el repositorio son seguros y el *merge* de las nuevas ramas no va a perjudicar versiones anteriores de código, se han automatizado distintos procesos (ejecución automática de *tests*, análisis de código, escáneres de filtraciones de credenciales, etc.) utilizando las herramientas descritas en la sección 4.2. Por otro lado, la entrega continua automatiza el despliegue de código a los usuarios finales, liberando a los equipos de operaciones de procesos manuales [36].

³Fuente: <https://es.parasoft.com/blog/implementing-qa-in-a-ci-cd-pipeline/>

Figura 4.1: Representación del ciclo de vida del CI/CD.



DevOps, sin embargo, abarca más. Esta cultura busca cubrir el ciclo completo del desarrollo de *software*, desde la estructura del equipo hasta el control de versiones, y se sirve de las prácticas de CI/CD para lograr este fin.

Gitflow

Gitflow es un modelo alternativo de creación de ramas. Se caracteriza por contar con ramas de función y ramas principales, siendo recomendable aplicarlo en proyectos que trabajen con CD/CI [6]. En concreto, han sido utilizadas ramas principales y de desarrollo, fusionando el resultado de ésta última al final de cada *sprint*. Debido a que en el equipo trabaja un único desarrollador, se ha desestimado crear una rama por *feature* lanzada. Para garantizar que los *merge* a la rama principal son seguros, se ha automatizado el uso de las herramientas desarrolladas en la sección 4.2, generando *builds* cada vez que se integra una rama nueva.

Scrum

Scrum es una metodología ágil basada en cuatro valores [55]. Sintetizando sus principios, se puede deducir que se pretende valorar a los individuos por encima de las herramientas, el software apropiado a la documentación exhaustiva, la colaboración con el cliente y la habilidad de dar respuesta al cambio ante imprevistos.

Se describe en profundidad este método y cómo se ha desarrollado el trabajo siguiendo sus principios en los anexos.

4.2. Herramientas

Se muestra a continuación algunas de las herramientas más relevantes en el desarrollo del proyecto.

Librerías

Principalmente de Python, se destacan las siguientes utilidades:

Scikit-Learn

Una de las librerías referentes en el ámbito de *machine learning* y Python. Además de utilizar la vertiente relacionada con aprendizaje automático, también se aprovecharon otras ramas del módulo como la de extracción de características de texto (TF-IDF) [29]. Debido a que proporciona una interfaz estándar para los clasificadores base de muchos algoritmos, posee muy buena documentación y es compatible con otras librerías, ha sido muy utilizada.

sslearn

Librería desarrollada por José Luis Garrido-Labrador dedicada al aprendizaje semisupervisado en Python. Utilizada para realizar comparaciones con algunos de los algoritmos implementados [29].

LAMDA

Toolkit escrito en Python con algunas implementaciones de los algoritmos más relevantes de aprendizaje semisupervisado [42]. Nuevamente, ha sido utilizada como referente a la hora de realizar comparaciones contra las implementaciones propias [43].

Beautiful soup

Biblioteca de Python utilizada para extraer datos de ficheros HTML obtenidos mediante la realización de *web scraping* a la hora de sintetizar vectores de características para la detección de *phishing*. Se ha recurrido a ella, principalmente, cuando la obtención de ciertos campos en las etiquetas puede ser vulnerada mediante el uso de expresiones regulares corrientes [66].

TLD

Librería de Python utilizada para extraer dominios de alto nivel (TLDs) de los enlaces facilitados [17]. Para evitar dependencias de bibliotecas externas, en un primer momento se consideró trabajar con una lista del *top* dominios más comunes (extraída de [1]). Sin embargo, se descartó la idea debido a que no existe una forma intrínseca de saber qué cadenas son TLD y cuales son subdominios. Por ejemplo, `zap.co.it` es un subdominio ya que existe el TLD `co.it`. Sin embargo, en un país que no venda dominios de la forma `co.«pais»` sería un TLD [50].

NLTK

Toolkit de Python utilizado para trabajar con lenguaje natural. Su principal utilidad ha sido procesar palabras como *tokens* para poder facilitar la implementación de algoritmos más complejos como TD-IDF o para analizar y procesar texto [69].

Otros

Otras de las dependencias (estándar) del proyecto se enumeran a continuación.

- **Requests:** permite realizar peticiones a distintas URLs, además de especificar parámetros relevantes en las mismas (como *headers*, *cookies*, *proxies* o *timeouts*).
- **urllib:** procesa URLs y las divide en campos.
- **re:** utilizada para aplicar expresiones regulares en Python.
- **Numpy, Pandas, Matplotlib:** utilizadas para tratar vectores, operaciones en *arrays*, *dataframes* y representar resultados.

Extensiones y portales

Principalmente utilizados para control de versiones, realización de *test* y seguimiento de la metodología Scrum, se encuentran:

ZenHub

Zenhub es una extensión dedicada a la gestión de proyectos *software* que se integra directamente con Github. Permite visualizar proyectos, *sprints*,

gráficos propios de Scrum y crear tableros. Debido a que el equipo de desarrollo cuenta con un único integrante, se considera la alternativa óptima (por ejemplo, a Jira) por su sencillez [79].

Selenium IDE

Selenium es una herramienta de automatización que permite grabar, editar y depurar pruebas, además de exportarlas a algunos de los lenguajes de programación más comunes.

En concreto, se ha utilizado la extensión para navegadores Selenium IDE, que consiste en un entorno de pruebas *software* para *webs* que permite grabar y reproducir *test* paso a paso sin necesidad de programar [63].

Github

Portal que permite alojar distintos repositorios en la nube [33]. Ha sido escogido por ser una de las plataformas más populares, además de por permitir la interacción entre distintos usuarios. La gestión del *backlog* del producto ha sido simulada mediante la creación de *issues*.

Programas

En versión de escritorio, únicamente ha sido necesario recurrir a:

KEEL

Herramienta desarrollada en Java por distintas universidades españolas y financiada por el Ministerio de Educación y Ciencia [2]. Proporciona implementaciones de *machine learning*, y ha sido utilizada para probar aquellos algoritmos no disponibles en las librerías de Python mencionadas anteriormente.

T_EXStudio

Editor de L^AT_EX utilizado.

Git BASH

Emulador de BASH para Microsoft Windows que proporciona una terminal de línea de comandos de Git.

Entorno de programación

Relativo a la creación de un entorno que pueda ser reproducible, se facilita la siguiente información:

- **Python:** lenguaje de programación interpretado de propósito general. Ha sido escogido para realizar este proyecto debido a la gran cantidad de paquetes dedicados a la ciencia de datos que posee [56].
- **Visual Studio Code:** editor y depurador de código empleado junto a algunas de sus principales extensiones.
- **Entornos virtuales:** un entorno virtual es un directorio que contiene una instalación concreta de Python y los paquetes que se hayan decidido instalar [57]. Como se puede deducir, la correcta utilización de los entornos virtuales conlleva muchas ventajas, como tener varios paquetes sin conflictos entre ellos o evitar corromper la instalación base si se está probando algún elemento nuevo.
- **Conda:** es un sistema de gestión de paquetes y entornos *opensource*. Es especialmente útil a la hora de realizar trabajos de ML ya que posee librerías como SciPy y TensorFlow [13].

Control de calidad

Siguiendo los principios de CD/CI, se ha procurado garantizar la calidad del código desarrollado. Para ello se han utilizado diversas herramientas, entre ellas:

- **SonarCloud:** se trata de un servicio de análisis estático de código que notifica diversos parámetros a revisar como *codesmells*, *bugs* o vulnerabilidades. Se ha integrado en el repositorio con la intención de realizar código limpio y aumentar la calidad del proyecto [65].
- **DeepSource:** se trata de una plataforma que fusiona el análisis estático de código, SAST (*static application security testing*), cobertura de código, entre otros, para mejorar la calidad de los proyectos. Además, posee un *bot* que realiza ciertas correcciones automáticas (por ejemplo, modifica errores de documentación) y facilita *badges*⁴ para los repositorios [16].

⁴Un *badge* o insignia es una imagen que muestra el estado de un flujo de trabajo o un repositorio. Por ejemplo, una insignia para los defectos de código muestra visualmente el número de *code smells* que hay en un determinado proyecto.

- **Travis CI:** se ha utilizado el servicio para la realización automática de *test* cada vez que se actualiza el repositorio. Para ello, se ha configurado una *build* y recreado el entorno del programador. De este modo, antes de realizar un *merge* a la rama principal se puede comprobar rápidamente si las pruebas siguen pasando, lo que mejora la integración y despliegue continuo [12].
- **Git Guardian:** herramienta que escanea los repositorios en busca de posibles filtraciones de credenciales, se ha utilizado para garantizar que las contraseñas de acceso a bases de datos y otros secretos permanezcan ocultos. Ha sido incluida, junto con las anteriores, en el flujo de Git [34].

Scripts

En algunos casos no se han encontrado soluciones de terceros y ha sido necesario implementar *scripts* propios. Los mas relevantes se citan a continuación:

Script para levantar proxies SOCKS5

Durante la extracción de vectores de características, se realizan peticiones a páginas de *phishing*. Para garantizar que estas páginas no puedan rastrear desde donde se ha realizado la petición, se han utilizado *proxies* que implementan el protocolo SOCKS5.

Para ello, se ha implementado en Python un *script* auxiliar que levanta en paralelo tantas instancias de Tor como se soliciten, y mantiene los hilos vivos hasta que se interrumpa la ejecución del *script*.

Por cada instancia de Tor que se quiera levantar, se necesita un fichero *torrc* en el directorio */etc/tor/* [59]. Cada una de ellas debe tener, además, su propio puerto de control, su propio puerto *socks* y su directorio de datos. Por ello, se ha creado una clase auxiliar que genera estos ficheros. Para levantar la instancia simplemente ha de ejecutarse el comando `tor -f /etc/tor/torrc.x` (siendo *x* el número de la instancia correspondiente), aunque se ha decidido, además, dirigir la salida al fichero */dev/null*. Es importante destacar que el puerto de control debe ser el siguiente al puerto *socks*. Teniendo en cuenta que los puertos por defecto de Tor son el 9050 y el 9051, se puede incrementar partiendo de esos números⁵. Para comprobar

⁵Solución basada en la respuesta del usuario «zkilnbqi» en Stack Overflow <https://stackoverflow.com/questions/14321214/how-to-run-multiple-tor-processes-at-once-with-different-exit-ips>.

que la instancia levantada funciona correctamente, se hace una petición a <http://ipinfo.io/ip> y se comprueba con una expresión regular que la dirección obtenida es la correcta. De este modo, se sabe que el *proxy* HTTP levantado funciona, y se puede utilizar redireccionando las peticiones oportunas a través del *proxy socks5h://127.0.0.1:y* (donde *y* es el puerto *socks* de la instancia correspondiente). Para que pueda ser usado en código, se ha generado un JSON donde se incluyen como diccionarios los *proxies* disponibles, y se utilizan en combinación con la librería Requests.

Debido a que el puerto Tor queda «a la escucha» en la máquina local (está esperando que se realice una conexión), no conlleva ningún riesgo. Para cerrar el puerto, es suficiente con parar el proceso que esté ejecutando el *script*. Se puede comprobar ejecutando en una terminal el comando `sudo lsof -i:y` (nuevamente, *y* es el puerto *socks* levantado). Cuando el *script* esté funcionando, la salida del comando mostrará diversos campos, como el propio comando (Tor), el PID, el nombre (*listen*). Si el *script* se para, el comando no mostrará salida, lo que implica que el puerto no está abierto [32].

5. Aspectos relevantes del desarrollo del proyecto

Este capítulo de la memoria pretende resumir y resaltar tanto la parte más teórica de algunos de los algoritmos más relevantes de aprendizaje semisupervisado, como su aplicación en diversos ámbitos de la ciberseguridad. Por ello, en este apartado se pueden encontrar diversos puntos importantes.

En la primera subsección 5.1 se desarrollará cómo se han validado los algoritmos de aprendizaje implementados. Para ello, se definirá qué experimentos se han realizado, se reportarán los resultados obtenidos y se realizarán comparativas contra otras implementaciones.

En la segunda subsección 5.2 se mostrarán los resultados obtenidos tras aplicar métodos de aprendizaje a la detección de ataques en sistemas de recomendación y se valorará si el método de generación de vectores de características expuesto en 3.10 es extrapolable a una aplicación real.

Por último, en la tercera subsección 5.3 (dedicada al *phishing*), se estudiarán los resultados del método de extracción expuesto en 3.11.

5.1. Algoritmos de aprendizaje semisupervisado

Uno de los principales objetivos del proyecto es entender e implementar (siendo capaz de tomar decisiones de implementación no arbitrarias en caso de que sea requerido) algunos de los algoritmos de aprendizaje semisupervisado más relevantes. Además, se ha querido ser crítico con estos métodos, y para ello se ha buscado validar su funcionamiento mediante diversos experimentos.

Nombre	Descripción	Clases	n	m
Iris	Conjunto de instancias pertenecientes a diferentes tipos de plantas de la especie Iris.	3	150	4
Dígitos	Conjunto de instancias que representan una imagen de 8x8 perteneciente a un dígito.	10	1797	64
Vino	Conjunto de instancias pertenecientes a tres clases de vino con sus parámetros estimados mediante análisis químico.	3	178	13
Cáncer de Mama	Conjunto de instancias que representan parámetros de distintas mujeres que pueden padecer o no cáncer (clasificación binaria).	2	569	30

Tabla 5.1: Descripción de los *datasets* utilizados para validar los algoritmos.

A continuación se facilitan los resultados de las pruebas realizadas con las implementaciones propias de algunos métodos de aprendizaje semisupervisado. Para evaluar la calidad de las implementaciones, se han utilizado algunos de los *dataset* más comunes en métodos de clasificación. En concreto, se han utilizado los que están disponibles en la librería Scikit-learn, que se muestran en la tabla 5.1. El parámetro n representa el número de instancias que contiene un determinado conjunto de datos, mientras que el parámetro m muestra el número de características que contiene cada una de esas instancias.

Co-forest

A diferencia del resto de algoritmos de semisupervisado, en el *co-forest* se van a realizar dos tipos de experimentaciones distintas. En un primer lugar, se ha probado cómo la inicialización del vector W afecta a la *accuracy* del algoritmo. Posteriormente, para comprobar la correctitud del algoritmo, se han realizado diversos experimentos. Por un lado, se ha evaluado el modelo en diversas situaciones de su ciclo de vida. Por otro, se ha realizado una comparativa contra la implementación proporcionada por KEEL.


Inicialización del vector W

Como se introdujo en la sección 31, el modo en que se inicialice el vector W durante la fase de entrenamiento tiene un efecto en el desempeño del

algoritmo. Debido a que en el pseudocódigo facilitado en la publicación [48] se inicializa a 0 (lo que, como ya se comentó anteriormente, lleva a una parada del algoritmo), se han decidido probar tres criterios distintos (línea 5 del pseudocódigo 1).

- **percentage_L**: este criterio consiste en inicializar el vector al mínimo entre la decima parte del tamaño de L y 100. Es decir, al $\min(\frac{1}{10}|L|, 100)$. Está basado en la tesis de Engelen [72], pero adaptado (en lugar de U se utiliza L).
- **confidence_L_all**: propuesto por César García-Osorio, consiste en inicializar la W de forma similar a la línea 20 del pseudocódigo 1, con la excepción de usar el conjunto L en lugar de U .
- **confidence_L_theta**: adaptación propuesta por la autora (basada en el funcionamiento normal del algoritmo), consiste en realizar lo expuesto en **confidence_L_all** pero únicamente sumando a $W_{i,t}$ aquellos valores cuyas confianzas sean mayores que θ .


Figura 5.1: Comparativa de la evolución de la *accuracy* durante las iteraciones del entrenamiento entre las distintas formas de inicialización del vector W para un *co-forest* formado por 6 árboles.



Los resultados se pueden observar en las gráficas 5.1 y 5.2. Estas muestran la evolución de la *accuracy* durante las distintas iteraciones del entrenamiento y han sido obtenidas realizando validación cruzada con 10 *folds*.

Como se ha comentado con anterioridad, el método de inicialización de W influye en el tamaño del primer subconjunto de U . En los experimentos realizados, se ha comprobado que **percentage_L** generalmente inicializa W a un tamaño bastante inferior que **confidence_L_all** y

Figura 5.2: Comparativa de la evolución de la *accuracy* durante las iteraciones del entrenamiento entre las distintas formas de inicialización del vector W para un *co-forest* formado por 20 árboles.



`confidence_L_thetha`, que rondan valores similares siendo ligeramente inferior `confidence_L_thetha` (ya que se excluyen las muestras con poca confianza). Cabe destacar que esto también depende del tamaño del *dataset*, pero ha ocurrido con todos los utilizados.

Es observable que los resultados obtenidos dependen no sólo de cada *dataset*, sino además del número de árboles utilizados durante la experimentación. Aparentemente, utilizando un menor número de árboles en el *ensemble*, es favorecedor utilizar criterios que inicialicen W a un mayor tamaño, mientras que si se utiliza un mayor número de árboles ocurre lo contrario. Puede ser que cuando se utiliza un *ensemble* de mayor tamaño los árboles sean capaces de trabajar con un subconjunto menor de U debido a que hay un mayor número de ellos y se compensa la votación por mayoría.

Sin embargo, es destacable que las conclusiones obtenidas han sido extraídas utilizando únicamente unos pocos *datasets*. Para realizar afirmaciones habría que ampliar el alcance de la experimentación.


Experimentación con el algoritmo

Los resultados se pueden observar en las gráficas 5.4, 5.5 y 5.6. Todas las experimentaciones se han realizado con el criterio `percentage_L`.

- **Fase de entrenamiento:** como se ha desarrollado en los conceptos teóricos, la fase de entrenamiento en el *co-forest* es iterativa, y finaliza cuando ningún árbol recibe nuevas pseudo-etiquetas que puedan cambiar su comportamiento (en la fase de re-entrenamiento).

Se ha querido estudiar la evolución del *score* (porcentaje de aciertos respecto al total de las predicciones) del algoritmo durante la fase de entrenamiento para los cuatro conjuntos de datos definidos en la tabla 5.1. Para ello, se ha realizado una gráfica ilustrando cómo evoluciona en función de la iteración en la que se encuentre.

Figura 5.3: Gráfica que representa la distribución de los datos.

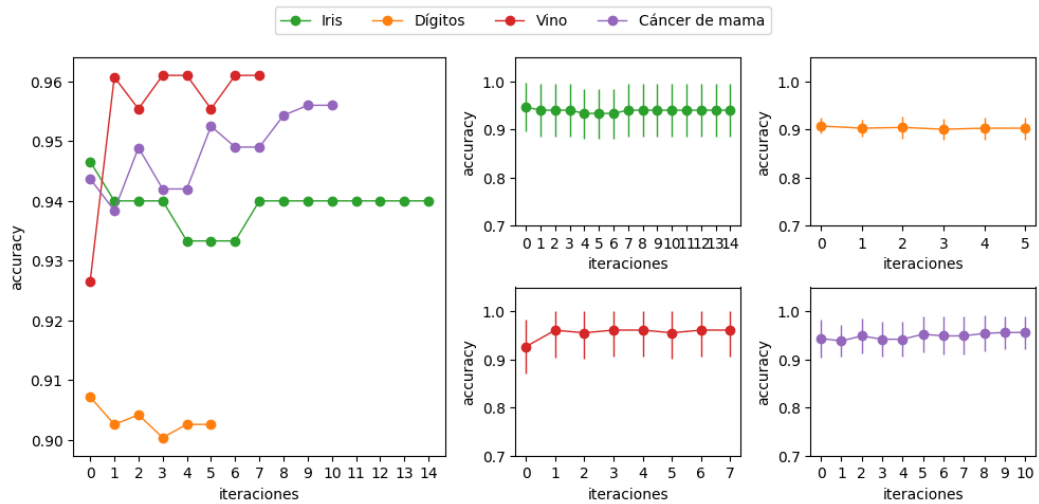


Para garantizar que los resultados obtenidos no son producto de una partición concreta de los datos, se ha realizado validación cruzada (con 10 particiones sin repetición). Por lo tanto, el porcentaje de datos utilizados para el entrenamiento es el 90 % del total (utilizando estratificación). Los datos de entrenamiento, a su vez, se dividen en etiquetados y no etiquetados. En este caso, el 20 % representa los datos etiquetados, y el 80 % los no etiquetados, como se puede observar en la imagen 5.3. Se han utilizado 20 árboles.

La exactitud media obtenida se puede ver representada en la gráfica 5.4. Es destacable que, dependiendo de los datos que se utilicen para entrenar el *co-forest*, puede variar el número de iteraciones que se necesiten (incluso dentro de un mismo *dataset*). Por ello, siempre se representa el número máximo de iteraciones realizadas, y para no deformar la media, se ha considerado que el valor de las iteraciones inexistentes es el mismo que el valor obtenido en la última iteración (ya que si, el algoritmo siguiese, el resultado devuelto sería igual debido a que no se volvería a entrenar ningún árbol).

Como se puede comprobar, el modelo mejora los resultados iniciales (exactitud obtenida en la iteración 0, cuando todavía no se ha realizado entrenamiento semi-supervisado y se cuenta con un *random forest* tradicional) en dos de los conjuntos de datos, mientras que en los otros dos empeora. Este comportamiento es lógico debido a que no todos los modelos son apropiados para todos los conjuntos de datos. Si se observa con más detenimiento cada conjunto de datos individualmente en el resto de los cuadrantes de la gráfica 5.4, se puede observar que la


Figura 5.4: Gráfica que muestra la evolución de la *accuracy* para cada *dataset* (además de su desviación) durante las iteraciones del entrenamiento del *co-forest*.



desviación típica varía considerablemente, por lo que se puede deducir que el modelo podría llegar a ser utilizable en la mayoría de los casos si la partición es la adecuada.

- **Tiempo de entrenamiento:** además, también se ha querido evaluar cómo varía el tiempo de entrenamiento en función del número de instancias utilizadas. Para ello, se ha trabajado con el *dataset* que contiene un mayor número de datos (Dígitos), y los resultados obtenidos se pueden observar en el primer cuadrante de la gráfica 5.5. Como se puede comprobar, sigue un crecimiento aproximadamente lineal. La velocidad, en este caso, es alta, pero cabe recordar que depende en gran medida del número de árboles utilizados y de las iteraciones que estos realicen. Se ha representado en la línea negra punteada, además, el resultado del modelo de regresión lineal.
- **Datos de entrenamiento:** En este apartado de la experimentación, se ha querido evaluar cómo se comporta el *co-forest* en función del porcentaje de datos que se utilice para el entrenamiento. Nuevamente, se han utilizado 20 árboles, y la división del conjunto de datos de entrenamiento se ha mantenido: 20 % etiquetados y 80 % no etiquetados. Los conjuntos están estratificados.

Figura 5.5: Gráfica que muestra el tiempo de entrenamiento requerido para el *co-forest* en función del número de instancias, además de la evolución del *score* (*accuracy*) en función del porcentaje total de datos destinado al entrenamiento.



Como se puede comprobar en el segundo cuadrante de la gráfica 5.5, sigue el comportamiento esperado, y por lo general a más instancias utilizadas para entrenar el modelo, mejor desempeño presenta. Nuevamente, recalcar que el resultado obtenido es la media de 10 experimentos realizados.


- **Número de árboles:** Hasta este momento, todos los resultados han sido realizados para $n = 20$. Es decir, utilizando 20 árboles. Sin embargo, el comportamiento del *co-forest* varía considerablemente en función del número de árboles contenidos en el *ensemble*, lo que motiva la realización del siguiente experimento. Nuevamente, se ha desarrollado utilizando cuatro conjuntos de datos y validación cruzada, por lo que se muestra la media en la exactitud para las 10 particiones.

Como se puede comprobar en la gráfica 5.6, en general, cuantos más árboles se utilicen, mejor *score* alcanza el *co-forest*. Es destacable que, evidentemente, a mayor n , mayor tiempo de procesamiento es requerido, como se ilustra en el segundo cuadrante de esa misma gráfica. Por lo tanto, se debería alcanzar un compromiso. Por lo general, los autores [48] utilizan valores de $n \geq 6$.

Comparativa contra KEEL

Para asegurar el correcto funcionamiento del algoritmo implementado, se ha decidido comparar contra la herramienta KEEL, creada por distintas

Figura 5.6: Gráfica que muestra la *accuracy* alcanzada por el *co-forest*, además del tiempo de entrenamiento requerido en función del número de árboles utilizados



Parámetro	Valor
n	6
θ	0.75
<i>Folds</i>	10
% etiquetados	10 % (en el conjunto de entrenamiento).
Comentarios	Para la comparativa se han utilizado los <i>data-sets</i> Iris y Vino, ambos estratificados.

Tabla 5.2: Tabla resumen con el diseño del experimento.

universidades españolas y financiada por el Ministerio de Educación y Ciencia.

En primer lugar y para tener más capacidad de «manipulación», se optó por descargar los ficheros fuentes de la última versión de Github [2] en lugar de utilizar la versión compilada que ofrecen los desarrolladores. Se puede consultar cómo en los anexos.

Para comparar los algoritmos en las condiciones más realistas posibles, se definieron las características mostradas en la tabla 5.2.

<i>Fold</i>	Iris		Vino	
	Propia	KEEL	Propia	KEEL
1	1.00	0.87	0.89	0.83
2	0.86	0.80	1.00	0.94
3	1.00	1.00	0.94	1.00
4	1.00	1.00	0.94	0.89
5	0.87	1.00	0.65	0.88
6	0.93	0.93	0.94	0.71
7	0.93	1.00	0.83	0.89
8	0.93	0.93	0.94	0.78
9	0.93	0.93	0.67	0.72
10	0.87	0.87	0.94	0.94
Media	0.93	0.93	0.88	0.86

Tabla 5.3: Comparativa entre la *accuracy* del *co-forest* de KEEL y la implementación propia sobre el conjunto de *test*.

Dentro de los ficheros fuente de KEEL, se pueden encontrar distintos conjuntos de datos con las particiones del *k-cross-validation* ya hechas y que son utilizadas en las ejecuciones de sus experimentos. Para comprobar ambos algoritmos en igualdad de condiciones, se convirtieron dichos archivos **.dat* en **.csv* y se importaron en la implementación propia mediante la librería Pandas. De esta manera, el único parámetro que no es idéntico entre ambas implementaciones es qué instancias de entre los datos etiquetados seleccionan los árboles para entrenarse en un primer momento (son aleatorios y generar las pequeñas diferencias observadas).

Los resultados obtenidos se pueden observar en la tabla 5.3. Como se puede comprobar, ambos algoritmos obtienen resultados prácticamente idénticos, siendo un poco superior el porcentaje de acierto logrado por la herramienta implementada propia en el caso del *dataset* Vino.

Tri-Training

Al igual que en los algoritmos anteriores, se ha decidido experimentar con distintas opciones a la hora de representar las gráficas, además de realizar una comparativa contra *sslearn*⁶ y *LAMDA*⁷ para validar la implementación.

⁶Disponible en <https://github.com/jlgarridol/sslearn>

⁷Disponible en <https://github.com/YGZWQZD/LAMDA-SSL>

Experimentación con el algoritmo

Los resultados se pueden observar en las gráficas 5.7 y 5.8.

Figura 5.7: Gráfica que muestra la evolución de la *accuracy* para cada *dataset* (además de su desviación) durante las iteraciones del entrenamiento del *tri-training*.





Figura 5.8: Gráfica que muestra el tiempo de entrenamiento requerido para el *tri-training*, además de la evolución del *score* en función del número de instancias.



- **Fase de entrenamiento:** se ha querido evaluar la evolución de la *accuracy* del modelo en función de la iteración del entrenamiento en la que se encuentre. En este caso, el *tri-training* utiliza como estimadores base un *naive-bayes* gaussiano, un árbol de decisión y un *kNN*. Al igual que en el *co-forest*, los resultados representados son

la media de 10 experimentos realizados mediante validación cruzada (10 «entrenamientos» distintos) y se pueden observar en la gráfica 5.7, donde el primer cuadrante compara todos los *datasets* y el resto representa la desviación entre las distintas fases de entrenamiento para cada *dataset*.

Como se puede comprobar, el modelo mejora los resultados iniciales (exactitud obtenida en la iteración 0, cuando todavía no se ha comenzado el algoritmo de entrenamiento semisupervisado), siendo especialmente notable en los *datasets* Vino y Dígitos. Por ello, se deduce que la incorporación del conjunto de datos no etiquetado durante el entrenamiento es útil y mejora la hipótesis aprendida en cada uno de los clasificadores base (y, por ello, la general del *ensemble*).

- **Tiempo de entrenamiento:** nuevamente se ha trabajado con el *dataset* que contiene un mayor número de datos y los resultados obtenidos se representan en el primer cuadrante de la gráfica 5.8. Como se puede observar, el tiempo crece de forma aproximadamente lineal con una alta velocidad (debido en parte a que este *dataset* no realiza un número elevado de iteraciones durante el entrenamiento).
- **Datos de entrenamiento:** en este caso, se quiere evaluar el desempeño del *tri-training* en función del porcentaje del *dataset* que se utilice para el entrenamiento (posteriormente este conjunto será dividido en L (20 %) y U (80 %)). Los resultados mostrados son la media de 10 experimentos y se observan en el segundo cuadrante de la gráfica 5.8. En este caso, un buen compromiso sería utilizar un 80 % de los datos, ya que por lo general a mayor número de instancias utilizadas durante el entrenamiento mejor resultado, no alcanzándose siempre la máxima exactitud cuando se usa el mayor porcentaje.


Comparativa contra sslearn y LAMDA

En el caso del *tri-training*, existen implementaciones en Python que, además, permiten que los estimadores base utilizados sean los disponibles en la librería Scikit-learn. Estas son sslearn, biblioteca de aprendizaje semisupervisado escrita por José Luis Garrido-Labrador y disponible en Github [29] y LAMDA, un *toolkit* [43] desarrollado por Lin-Han Jia (y su equipo) que se encuentra públicamente disponible para su uso [42].

Para la comparativa se ha realizado validación cruzada utilizando 10 *folds*. Evidentemente, ambos modelos han sido entrenados con el mismo conjunto de entrenamiento (más concretamente, idénticos L y U) y probados


con el mismo conjunto de *test*. Como estimadores base se ha utilizado el árbol de decisión disponible en la librería Scikit-learn.

Figura 5.9: Gráfica que representa la variación de la *accuracy* en cada *fold* y la media para la implementación del *tri-training* de LAMDA y la propia.



En el caso de la comparativa contra *sslearn*, el resultado se puede contemplar en la gráfica 5.10, mientras que el caso de LAMDA se observa en la gráfica 5.9. Como se puede comprobar, la media de la *accuracy* para ambos modelos es prácticamente idéntica. Hay algunas variaciones en la *score* para distintos *folds*, pero pueden deberse a detalles de implementación y selección de los conjuntos internamente. Por este motivo, la implementación se considera correcta.

Figura 5.10: Gráfica que representa la variación de la *accuracy* en cada *fold* y la media para la implementación del *tri-training* de *sslearn* y la propia.




Democratic-co Learning

En este algoritmo se facilitan las mismas experimentaciones previas, además de una comparativa contra *sslearn* [29].

Experimentación con el algoritmo

Los resultados se pueden observar en las gráficas 5.11 y 5.12.

Figura 5.11: Evolución de la *accuracy* para cada conjunto de datos y representación (para cada *dataset*) de la desviación estándar durante las iteraciones del entrenamiento del *democratic-co learning*.




- **Fase de entrenamiento:** como estimadores base para el *democratic-co learning* se han utilizado un *naive-bayes* gaussiano, un árbol de decisión y un *kNN* con $n = 3$. Nuevamente, los resultados representados han sido obtenidos mediante validación cruzada y se representan en la gráfica 5.11.

Como se puede observar, todos los *datasets* mejoran la *score* inicial excepto Dígitos. Habiendo depurado el algoritmo y comprobado cómo funciona internamente, se piensa que es debido a la gran cantidad de clases disponibles en el *dataset* (las etiquetas pueden adoptar un valor entre 0 y 9). En la fase del algoritmo en la que se escoge la etiqueta, puede ocurrir que no haya una mayoría entre la votación, lo que da lugar a un mayor error que en los *datasets* con menos etiquetas (por ejemplo, los binarios). Se piensa que una posible solución sería incrementar el número de estimadores base, pero también se dispararía el tiempo de entrenamiento, que es muy superior al resto de algoritmos

(compruébese que el número de iteraciones en este caso puede llegar a ser 200).

Figura 5.12: Tiempo de entrenamiento requerido para el *democratic-co* en función de número de datos utilizados durante el entrenamiento, además de la evolución del *score* en función del porcentaje total de instancias respecto a cada *dataset*.




- **Tiempo de entrenamiento:** los resultados se plasman en la gráfica 5.12. Como se puede comprobar, en este algoritmo el tiempo de entrenamiento requerido es muy superior a los anteriores y, aparentemente, no se asemeja a ninguna función estándar (los puntos están más dispersos que en otras ocasiones).
- **Datos de entrenamiento:** se muestra en la gráfica 5.12 (segundo cuadrante) la variación del *score* del *democratic-co* en función del porcentaje del conjunto de datos destinado al entrenamiento. En este caso la variación es menos notoria que en algoritmos anteriores para la mayoría de los *datasets*, lo que puede implicar que el número de instancias etiquetadas puede ser inferior sin afectar tanto el desempeño del algoritmo.

Comparativa contra sslearn

En el caso del *democratic-co*, se ha optado por comparar la implementación propia contra sslearn [29]. Nuevamente, los resultados mostrados son producto de experimentos realizados mediante validación cruzada con 10 *folds*, y ambos modelos han sido entrenados con los mismos L y U y probados con idénticos conjuntos de *test*.

Como estimadores base en ambos modelos se han utilizado un *naive-bayes* gaussiano, un árbol de decisión y un *kNN* con $n = 3$, cuya implementación se encuentra disponible en la librería Scikit-learn.

Figura 5.13: Comparativa contra sslearn para el *democratic-co*. Se representa la *accuracy* obtenida en cada *fold* y la media de los mismos para ambos modelos.



El resultado se puede contemplar en la gráfica 5.13, donde se muestra la *score* obtenida en cada *fold* y la media de los 10. En el caso de Iris, la *score* obtenida para cada *fold* es idéntica en ambas implementaciones y, por lo tanto, la media también. El caso del conjunto de datos Vno es el que menos se asemeja, pero igualmente se ha obtenido la misma exactitud en un 60 % de las ocasiones y la media se diferencia en apenas dos centésimas. En el último *dataset* binario se encuentra alguna pequeña variación en algunos *folds*, pero la media obtenida es la misma.

Debido a que las pequeñas variaciones se deben a cuestiones de implementación no definidas en el pseudocódigo de Zhou y Goldman [82] (por ejemplo, el tratamiento de instancias duplicadas de U en L_i), se considera que la comparativa es exitosa (el *score* obtenido es idéntico en dos de los *datasets* y muy similar en el otro) y el algoritmo ha sido implementado correctamente.

5.2. Detección de ataques en sistemas de recomendación

El objetivo de este apartado en el proyecto es probar nuevos métodos de aprendizaje semisupervisado aplicados a la detección de ataques en sistemas

de recomendación. Para lograr este fin, se decidió, en primer lugar, reproducir el artículo original [81], que utiliza el algoritmo *co-forest*. Como los autores no especifican detalles de implementación en su artículo (cómo construir perfiles de ataque, dónde encontrar bases de datos o código, etc.), se concluyó que comparar los resultados obtenidos contra los suyos es la mejor forma de determinar la correctitud del trabajo desarrollado. Para ello, se ha utilizado el *dataset* MovieLens10M.

MovieLens 10M

MovieLens10M [47] es un conjunto de datos utilizado típicamente en la investigación y desarrollo de sistemas de recomendación. Contiene 10 000 054 opiniones generadas por 71 567 usuarios acerca de 10 681 películas. Estas reseñas han sido recopiladas del servicio *online* de películas MovieLens⁸.

Los usuarios han sido seleccionados aleatoriamente entre los perfiles que tengan más de 20 películas valoradas y está documentado que todos son auténticos [81] y pertenecen a usuarios reales. Por lo tanto, los perfiles atacantes han de ser contruidos mediante programación.

Creación de reseñas atacantes

Se han incluido tres tipos de ataques distintos: *random*, *average* y *bandwagon*. En primer lugar, se han sintetizado las reseñas y posteriormente se han generado los vectores de características idénticamente a los perfiles verdaderos.

La metodología de construcción de las valoraciones sigue los modelos estadísticos expuestos en la sección 3.10. Sin embargo, se puede visualizar un resumen de los escogidos en la tabla 5.4.

Para construir las reseñas pertenecientes a un ataque del tipo *random*, se ha obtenido, en primer lugar, la media de la puntuación general para todas las películas del sistema y su desviación. Los ítems de relleno han sido seleccionados aleatoriamente entre toda la base de datos (excluyendo, evidentemente, los ítems objetivo), y se ha asignado a cada uno una puntuación aleatoria siguiendo una distribución normal parametrizada por la media y desviación «global» del sistema. Evidentemente, esta puntuación ha sido corregida para que se encuentre entre los rangos admitidos (por ejemplo, de 0 a 5 estrellas). Debido a que el método de detección utilizado no necesita fechas, el campo perteneciente a la *timestamp* no ha sido relleno.

⁸Disponible en <https://movielens.org/>

Modelo	I_s	Valoración I_f	Valoración I_t
Random	\emptyset	Aleatoria siguiendo una distribución $\mathcal{N}(\mu, \sigma)$.	máxima o mínima
Average	\emptyset	Aleatoria siguiendo una distribución $\mathcal{N}(\mu_i, \sigma_i)$.	máxima o mínima
Bandwagon (<i>random</i>)	k ítems más populares	Aleatoria siguiendo una distribución $\mathcal{N}(\mu, \sigma)$.	máxima o mínima

Tabla 5.4: Características estadísticas de los tipos de perfiles atacantes.

Posteriormente, se ha asignado la máxima puntuación a los ítems objetivo (*push attack*).

En el caso del ataque *average*, el procedimiento ha sido el mismo, solo que en este caso las puntuaciones de los ítems de relleno son más representativas. En lugar de seguir una normal parametrizada por las características del sistema a nivel global, se ha calculado para cada película su media y su desviación, y se ha asignado una valoración aleatoria que sigue esta distribución. Es decir, cada ítem de relleno recibe una puntuación aleatoria que sigue una distribución normal con media la correspondiente a ese ítem en concreto, y con su respectiva desviación. En caso de que se escoja una película nunca antes valorada, la media utilizada es la media del rango (por ejemplo, 2.5 estrellas) y la desviación es 0.

Por último, el ataque *bandwagon*. Este ataque se realiza exactamente igual que el *random* solo que, además, se añade un conjunto nuevo, los «ítems seleccionados» o I_s . En este caso, se escogen los k ítems más populares de la base de datos (se entiende por más «popular» aquel ítem que posea más valoraciones). Evidentemente, este conjunto se excluye (además de los ítems objetivo) a la hora de escoger los ítems de relleno. La valoración asignada a I_s ha sido o bien la máxima, o bien la mínima (en función de su nota media).

Generación del *dataset* y parámetros.

Para generar el conjunto de entrenamiento, se ha utilizado el mismo proceso que el descrito en el *paper* de Zhou y Duan [81]. La distribución de los datos utilizados se muestra en la tabla 5.5.

En primer lugar, se han seleccionado 1 000 perfiles aleatorios verdaderos y se han extraído sus vectores de características como se ha indicado pre-

Tipo	Número	Tamaño del relleno			
		1 %	3 %	5 %	10 %
Genuino	1000	-	-	-	-
<i>Random attack</i>	-	10	10	10	10
<i>Average attack</i>	-	10	10	10	10
<i>Bandwagon attack</i>	-	10	10	10	10

Tabla 5.5: Número y distribución del conjunto de entrenamiento.

viamente en la sección 3.10. Posteriormente, se han generado reseñas para perfiles de atacantes, y se han extraído sus vectores.

En cuanto al conjunto de test, se han generado 10 conjuntos distintos para garantizar que los resultados de los experimentos no son fruto de una partición concreta de los datos, sino media de una cantidad aceptable. Para ello, se han realizado ficheros `.csv` para distintos porcentajes de tamaño de ataque (1 %, 2 %, 5 % y 10 %) y tamaño de relleno (1 %, 3 %, 5 % y 10 %) de los atacantes. El número de perfiles verdaderos en cada conjunto de *test* equivale a 1000 (y son excluyentes entre ellos y respecto al conjunto de entrenamiento).

En cuanto a los parámetros del algoritmo, se han establecido los mismos que en el *paper* de Zhou y Duan [81]. El tamaño de ventana (J) se ha establecido a 40 y el porcentaje de etiquetas en el conjunto de entrenamiento (d) equivale al 30 %. Como el *paper* no indica qué hacer en el caso del *bandwagon*, se ha decidido que el número de ítems relevantes a evaluar (k) es 30. En cuanto al *co-forest*, el umbral de confianza θ se ha fijado a 0.75 y el número de árboles (n) utilizado es 6.

Cabe destacar que, debido a que es escaso el número de instancias positivas, se ha decidido utilizar como curva para calcular las AUC la curva *precision-recall* (en lugar de la curva ROC).

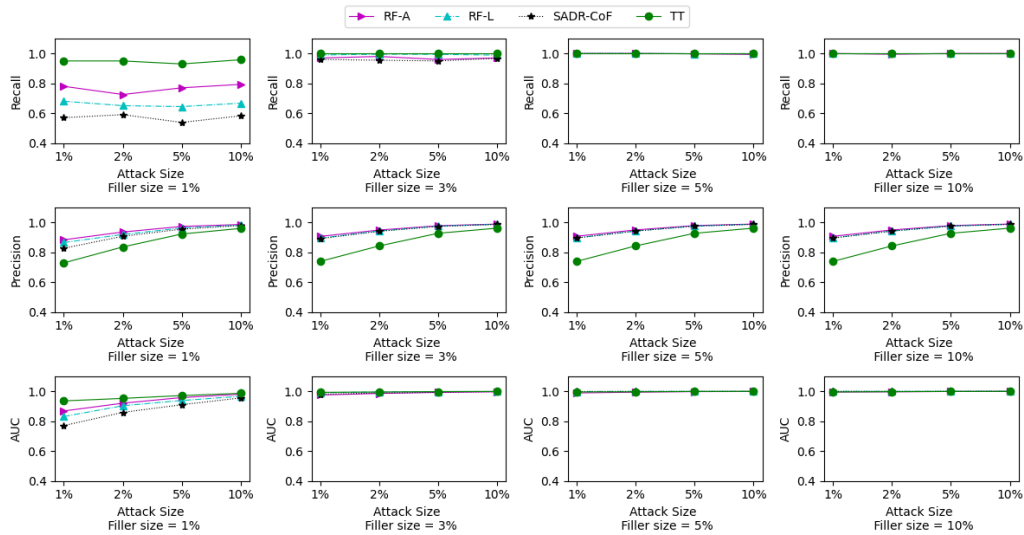
Resultados

Los resultados se han desglosado en función del tipo de perfiles atacantes inyectados. Se ilustran en las respectivas gráficas: *random attack* 5.14, *average attack* 5.15 y *bandwagon attack* 5.16.

En la leyenda se puede comprobar que se han utilizado distintos algoritmos de ML. Para comparar el *co-forest* con el *random forest*, se han utilizado

dos versiones de este mismo (etiquetadas como «RF-A» y «RF-L»). RF-A es un *random forest* que ha sido entrenado con el conjunto de entrenamiento al completo (es decir, con el 100 % de las etiquetas disponibles). RF-L también es un *random forest*, pero la diferencia reside en que, en este caso, únicamente se han utilizado un 30 % de las etiquetas disponibles en su entrenamiento (las mismas que se proporcionan al *co-forest*). Este *ensemble* permite deducir si el *co-forest* (algoritmo semisupervisado) resulta verdaderamente útil en una situación de escasez de etiquetas, o si por el contrario es mejor utilizar la versión supervisada. Por último, también se ha incluido un *tri-training* que utiliza como estimadores base un *naive-bayes* gaussiano, un árbol de decisión y un *kNN*.


Figura 5.14: Gráfica que representa la detección de perfiles que utilizan *random attack* en el *dataset* MovieLens10M.



Discusión de los resultados

Puede parecer que los resultados son muy satisfactorios debido a que, en situaciones en las que el *filler size* del atacante es mayor o igual que el 3 %, el *recall* (es decir, la cantidad de instancias positivas que se encuentran) para la mayoría de los algoritmos es muy alto y la precisión (de las instancias que se clasifican como positivas, cuántas lo son realmente) es generalmente buena (exceptuando tal vez, la del *tri-training*, lo que es lógico porque también posee un *recall* mayor).


Figura 5.15: Gráfica que representa la detección de perfiles que utilizan *average attack* en el *dataset* MovieLens10M.



Sin embargo, una de las fases del ciclo de vida del ML es el preanálisis de datos. Si se observa con detenimiento el *dataset*, se puede comprobar que la media del *filler size* de los usuarios genuinos es aproximadamente de un 1.34 % y que únicamente un 10 % de los usuarios tiene un *filler size* superior al 3 %. Por ello y teniendo en cuenta que para cada conjunto (ya sea de entrenamiento o de *test*) se selecciona aleatoriamente un 1.45 % del total los usuarios genuinos, es muy probable que esté formado por perfiles con un *filler size* inferior al 3 %. Por lo tanto, la única «columna» verdaderamente significativa es la primera, y como se puede comprobar los resultados no son buenos. En otras palabras, es muy probable que el *recall* sea tan bueno en la mayoría de los casos porque los perfiles inyectados tienen un número de valoraciones muy superior a los perfiles genuinos, no porque el método de extracción sea relevante y significativo.

Adicionalmente, se piensa que el método de extracción de vectores de características no es muy adecuado. El hecho de que se aplique directamente en bases de datos sin ningún tipo de ordenación implica que tiene que existir alguna relación subyacente en el orden «por defecto» de los datos y el comportamiento de los usuarios, lo que es una suposición que no puede extrapolarse a todos los conjuntos de datos. Si la base de datos estuviese, por ejemplo, ordenada por popularidad, sería natural que los usuarios votasen más en las primeras ventanas. Si estuviese ordenada por fechas, podría

Figura 5.16: Gráfica que representa la detección de perfiles que utilizan *bandwagon attack* en el *dataset* MovieLens10M.



existir una relación entre la edad del usuario y las ventanas en las que vota (películas de su «época»). Sin embargo, al no existir ningún tipo de orden, es una hipótesis demasiado general para ser asumida. Por ello, se decidió cerrar esta línea de investigación.

5.3. Detección de *phishing*

Se detalla a continuación el proceso seguido en las distintas fases relacionadas con la experimentación.

Extracción de las URL del *dataset*

Para extraer los vectores de características, en este caso, se necesita extraer el `html` de distintas páginas web (tanto verdaderas como de *phishing*) mediante peticiones de código (es decir, realizando *web scraping*⁹), por lo que se necesita conocer su dirección. Para garantizar el anonimato en las peticiones que se realizan a páginas de *phishing*, se han utilizado *proxies* con un protocolo `SOCKS5`. Para levantarlos, se ha utilizado un *script* de implementación propia descrito en la sección 4.2.

⁹ *Web scraping* es el proceso de recolectar datos desde la *web* (en este caso, de forma automática mediante *scripting*).

<i>Dataset</i>		Instancias en [41]	Instancias reales	Categoría
PhishTank	+	2 141	1 057	<i>Phishing</i>
OpenPhish				
Alexa		1 600	1 145	Genuino
Plataforma de pago		66	51	Genuino
Páginas de banca		252	37	Genuino
Total		4059	2290	

Tabla 5.6: *Dataset* de *phishing*.

Se ha intentado replicar el *dataset* (procedencia y número) utilizado en el *paper* de Jain y Gupta [41], pero muchos de los enlaces facilitados no están disponibles actualmente. Por ello, se han buscado alternativas y la comparativa entre el *dataset* original y el recopilado para los experimentos se muestra en la tabla 5.6.

En el caso de PhishTank, la base de datos sigue disponible y es accesible en su página web [67]. Debido a que se actualiza a diario, se recupera mediante una petición *get*, aunque se han tenido dificultades (solucionadas utilizando *proxies* y los *headers* adecuados) debido a que el sitio tiende a bloquear si se hacen unas pocas peticiones seguidas. También sigue accesible la base de OpenPhish [26], aunque en este caso el número máximo de instancias obtenibles gratuitamente está limitado a 500 y se puede encontrar en un fichero en su página web [25]. Debido a que también se actualiza periódicamente, este fichero se recupera mediante peticiones.

Los sitios legítimos se han extraído del *top* 1 millón páginas visitadas mediante Alexa¹⁰, del *top* de plataformas de pago disponibles y de algunos de los sitios de banca más populares. En el caso de los enlaces genuinos, ninguna de las direcciones facilitadas en el *paper* original está disponible. Por ello, los sitios más consultados en Alexa se han obtenido de Expired domains [23], las plataformas de pago más comunes de Shopify [64] y los sitios bancarios, al igual que en el *paper* original, de Similar Web [75] (solo que el número está limitado a 50). Debido a que los enlaces facilitados por estas plataformas no contienen protocolo, se ha generado un *script* auxiliar que encuentra el correspondiente y filtra aquellas páginas en inglés y español para garantizar compatibilidad con el TF-IDF utilizado para extraer palabras clave (no se

¹⁰ *Top* extraído de <https://www.expireddomains.net/alexa-top-websites/> debido a que Amazon está realizando reformas en el servicio.

ha utilizado el *header* para realizar esta tarea porque no se incluye en la librería de Python, por lo que se ha analizado el lenguaje).

Es muy destacable que se ha limitado el número de instancias de *phishing* utilizadas para que sea exactamente la mitad del *dataset*. Además, también es reseñable que las páginas de *phishing* son distintas a las utilizadas en el *paper* original debido a que PhishTank y OpenPhish actualizan sus bases de datos a diario. Para extraer los vectores de características, se ha seguido el procedimiento mostrado en la sección 3.11 (es necesario que las páginas estén levantadas).

Parámetros y clasificadores

Para realizar esta experimentación se han utilizado distintos modelos de aprendizaje. Es destacable que se ha incluido un algoritmo de aprendizaje supervisado para comparar los resultados del mismo contra otros algoritmos semisupervisados. Los algoritmos de aprendizaje supervisado han sido entrenados con el 100 % de los datos etiquetados disponibles, mientras que los algoritmos semisupervisados han sido entrenados con un 20 % de etiquetas y un 80 % de datos sin etiquetar. El motivo por el que se ha escogido el *random forest* como método de aprendizaje supervisado contra el que comparar, es porque es el clasificador que mejor rendimiento reportó en el *paper* utilizado de referencia [41]. Por lo tanto, sirve de «cota superior» del rendimiento para los algoritmos supervisados.


A continuación se va a especificar los algoritmos concretos utilizados. Respecto a los *ensembles* basados en árboles, por un lado, se dispone de un *random forest* y, por otro, dos *co-forests*. Uno de ellos ha sido entrenado utilizando $n = 6$ árboles y el criterio `confidence_L_theta`, mientras que el otro posee $n = 20$ y `percentage_L` (consultar sección 5.1). Por último, también se han incluido un *tri-training* y un *democratic-co* que utilizan como estimadores base un *naive-bayes* gaussiano, un árbol de decisión y un *kNN*.

Resultados generales

Los resultados generales de la propuesta se muestran en la imagen 5.17. Como se puede comprobar, la propuesta planteada es aceptable, teniendo el clasificador con mejor desempeño una *accuracy* del 88 % y, el peor, una equivalente al 84 %. Como se puede observar, el clasificador (*democratic-co*) con peor *recall* (el que menos instancias positivas «encuentra») también es el que posee una mayor precisión (de las que dice que son positivas, cuantas

lo son en realidad). Como es esperable, ambos *co-forest* se comportan de manera muy similar.

Figura 5.17: Resultados generales del método de detección de *phishing*.



Para obtener una visión más real de lo que está ocurriendo, se muestra en la imagen 5.18 la matriz de confusión correspondiente al *co-forest* de 20 árboles. Es destacable que la matriz mostrada es la suma de cada matriz de confusión obtenida en cada uno de los *folds* de la validación cruzada. Como se puede comprobar, en los casos de error, la situación es la peor de las posibles, ya que en general hay más instancias peligrosas (*phishing*) que se etiquetan como legítimas que el caso contrario. En este caso, la *accuracy* del clasificador es del 85.69 %.

Resultados grupales

A continuación, se va a evaluar el desempeño de cada grupo de características por separado. Para ello, se va a repetir la experimentación únicamente utilizando subconjuntos del total de atributos para entrenar y evaluar.

Características basadas en la URL

Este grupo está formado por las características que comprenden el intervalo f1-f8, ambas inclusive. Los resultados se muestran en la imagen 5.19.

Como se puede comprobar, aunque la *accuracy* obtenida es buena, en general, se encuentran pocas instancias de *phishing* utilizando este subconjunto. Aún así, es destacable la precisión de la aproximación, ya que aunque

Figura 5.18: Matriz de confusión correspondiente al clasificador CoF_PL.





Figura 5.19: Resultados de la evaluación utilizando únicamente las características basadas en la URL.



se encuentren pocas instancias, prácticamente todas las que se dice que son *phishing* lo son en realidad.



Observando la matriz de confusión correspondiente al *tri-training* (imagen 5.20), se puede observar como la situación es la misma que la anterior (es decir, hay más falsos negativos que falsos positivos).

Características basadas en la aparición del formulario de *login*

Este grupo está formado por la característica f9. Los resultados se muestran en la imagen 5.21.

Como se puede intuir, clasificar utilizando únicamente un atributo binario no da resultados especialmente satisfactorios. Además, se depende de que las páginas contengan formularios (no necesariamente tienen por qué contenerlas

Figura 5.20: Matriz de confusión correspondiente al clasificador TT.

Figura 5.21: Resultados de la evaluación utilizando únicamente la característica basada en la aparición del formulario de *login*.


todas, y menos en el índice). En este caso aparecen muchos falsos positivos (instancias legítimas clasificadas como estafas).

Características basadas en los hiperenlaces contenidos

Este grupo está formado por las características que comprenden el intervalo f_{10} – f_{15} , ambas inclusive. Los resultados se muestran en la imagen 5.22

Como se puede comprobar, los resultados son bastante satisfactorios. Para obtener una visión más real de lo que ocurre y qué atributos son más importantes, se ha dibujado un árbol de decisión (limitado a una altura máxima $h = 4$ (de un total de $h = 22$) para una correcta visualización) que se muestra en la imagen 5.23. Es destacable que el atributo $X[0]$ es en realidad el f_{10} (el resto siguen la misma sucesión).

Figura 5.22: Resultados de la evaluación utilizando únicamente las características basadas en los hiperenlaces contenidos.



Como se puede comprobar, el atributo que mejor divide el conjunto es el número de hiperenlaces contenidos, aunque también se utilizan otros como el ratio de enlaces externos, vacíos y redirecciones.

Características basadas en el fichero `css`

Este grupo está formado por la característica `f16`. Los resultados se muestran en la imagen 5.24

En general este atributo no es bueno. Hoy en día, muchas páginas legítimas también contienen ficheros `css` alojados en dominios externos, por lo que no es una característica que pueda dividir fielmente las instancias.

Características basadas en la identidad de la página `web`

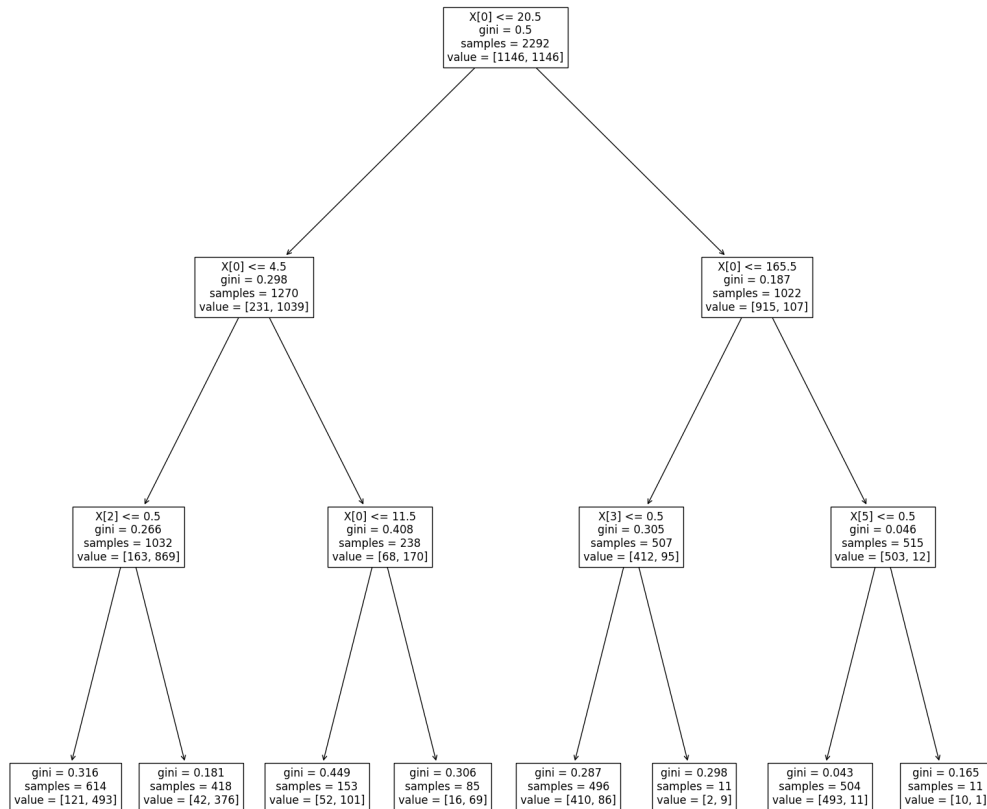
Este grupo está formado por las características que comprenden el intervalo `f17-f19`, ambas inclusive. Los resultados se muestran en la imagen 5.25.

En general, este subconjunto tiene un desempeño aceptable, aunque la precisión no es muy alta. Es destacable que los atributos 17 (*copyright*) y 18 (palabras clave) dependen del lenguaje, por lo que hay que entrenar correctamente los objetos TF-IDF (con documentos que posean cuerpos en el idioma a analizar) y pueden no ser atributos «adecuados para utilizarse en solitario».

Discusión de los resultados

En general se opina que el método de detección tiene unos resultados satisfactorios, aunque es destacable que se han obtenido peores resultados que en el *paper* utilizado como referencia [41]. Por ejemplo, en su experimentación

Figura 5.23: Atributos más importantes del subconjunto f10-f15 (inicio del árbol).



el *random forest* alcanza una *accuracy* del 99 %, mientras que en la mostrada en este trabajo se alcanza un 88 %.

Observando un árbol de decisión entrenado con el conjunto total de datos, se puede obtener una idea aproximada de los atributos más relevantes. Estos son el 10 (número de enlaces), el 2 (aparición de «@» y «-» en la URL), el 3 (longitud de la URL), el 15 (ratio de redirecciones) y el 18 (aparición de palabras clave en el dominio base). Cabe destacar que el árbol real contiene 23 alturas. Se opina que los subconjuntos de atributos no son

Figura 5.24: Resultados de la evaluación utilizando únicamente la característica basada en el fichero `css`.





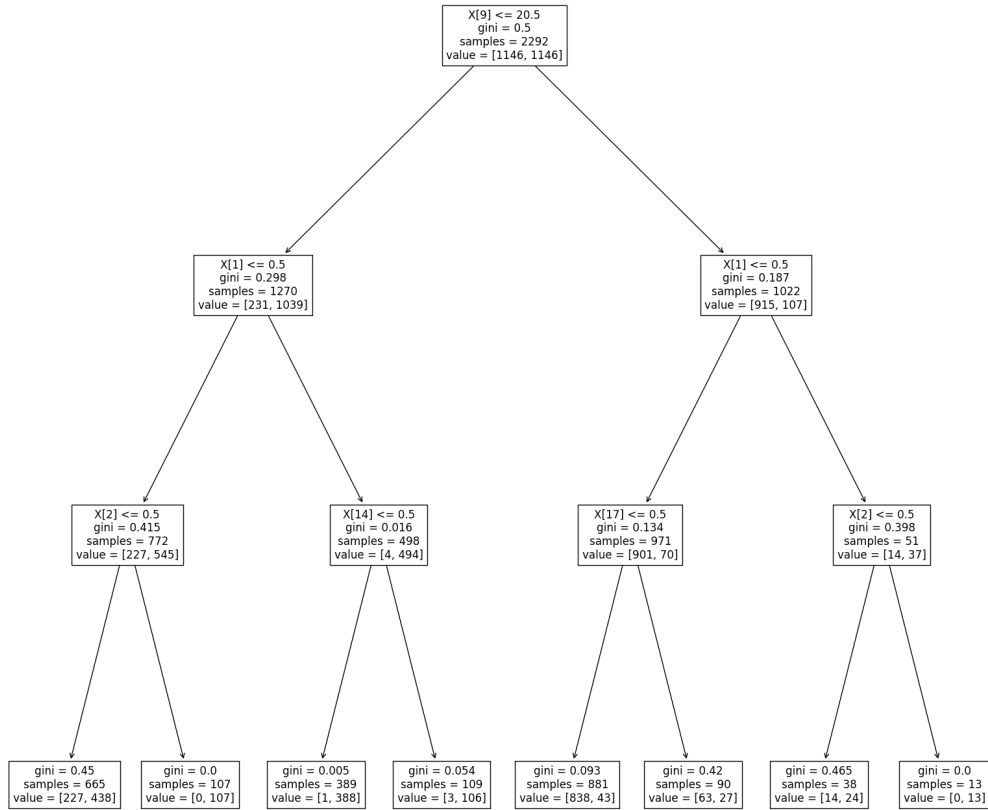
Figura 5.25: Resultados de la evaluación utilizando únicamente las características basadas en la identidad de la página `web`.



significantes por sí solos, pero que en conjunto modelan correctamente una página legítima o una de *phishing*.

Comparando los algoritmos de aprendizaje semisupervisados con el supervisado, se piensa que el resultado obtenido es muy bueno ya que los algoritmos de aprendizaje supervisado han sido entrenados con el 100 % de los datos etiquetados disponibles, mientras que los algoritmos semisupervisados han sido entrenados con un 20 % de etiquetas y un 80 % de datos sin etiquetar. A pesar de esto, comparando las *accuracys* entre clasificadores, el mejor clasificador (*random forest*) tiene una equivalente al 88 %, el peor (*democratic co*) una equivalente al 84 % y el resto se encuentra en ese intervalo (por ejemplo, el *co-forest* entrenado con el criterio `/textttpercentage_L` cuenta con un 86 %). Como se puede comprobar, la diferencia es mínima y, por lo tanto, la aproximación obtenida puede ser utilizada en una situación de escasez de etiquetas. Es destacable que el *democratic-co* tiene incluso una mejor precisión que el *random-forest*, y se recuerda que el *random-forest* es el algoritmo supervisado que mejor se comporta en la experimentación de [41], por lo que es una cota superior del desempeño esperado para los algoritmos supervisados.

Figura 5.26: Atributos más relevantes durante la clasificación (inicio del árbol).



Además, se opina que el método propuesto tiene muchas ventajas, como la independencia de herramientas externas (por ejemplo, consulta de autoridades certificadoras) y la extracción de los vectores desde el lado cliente.

Concluyendo, se piensa que el método mostrado puede ser muy útil para realizar filtrados masivos, pero teniendo en cuenta que cuando los clasificadores fallan, en la mayoría de los casos lo hacen calificando instancias de *phishing* como legítimas. Es destacable el buen desempeño de la aproximación aún contando con escasez de etiquetas.

6. Trabajos relacionados

Dentro de este proyecto se pueden diferenciar distintas líneas de investigación. Entre ellas se distinguen las dirigidas hacia el desarrollo y comprensión de los algoritmos de aprendizaje semisupervisado, las centradas en formalizar ataques a sistemas de recomendación y las dedicadas a la detección de *phishing* mediante algoritmos de *machine learning*.

Algoritmos de aprendizaje semisupervisado

El estudio de los algoritmos se ha basado principalmente en los artículos enumerados a continuación:

Co-Forest

A pesar de que el paper principal del proyecto (Zhou y Duan [81]) expone que se utiliza la versión original del *co-forest* [48], es destacable mencionar que ciertos aspectos de implementación no han sido contemplados en estos artículos. Por ello, la implementación propia se ha basado también en «*Semi-supervised ensemble learning. Master's thesis*», desarrollada por Engelen y Hoos [72].

Tri-Training

En este algoritmo únicamente se ha tenido en cuenta un trabajo de referencia, «*Tri-Training: Exploiting Unlabeled Data Using Three Classifiers*», de Zhi-Hua Zhou y Ming Li [83].

Democratic-co learning

Tanto la sección teórica como el pseudocódigo han sido realizados siguiendo el *paper* denominado «*Democratic Co-Learning*», de Yan Zhou y Sally Goldman [82].

Aprendizaje semisupervisado aplicado a la detección de ataques en sistemas de recomendación

Se enumeran a continuación algunos de los artículos más relevantes en el estudio de la materia:

***Co-Forest* aplicado a la detección de ataques [81]**

En esta sección, el artículo fundamental es «*Semi-supervised recommendation attack detection based on Co-Forest*» [81]. En este *paper*, se propone un método de detección basado en *co-forest* y se producen distintas comparativas con otros algoritmos para comprobar su eficacia, consiguiendo unos resultados muy aceptables. Partiendo de esta base nace el presente documento, que pretende explorar la solución propuesta por estos autores y expandirla.

***Naive Bayes* aplicado a la detección de ataques [78]**

También es muy relevante citar el trabajo expuesto en «*HySAD: A semi-supervised hybrid shilling attack detector for trustworthy product recommendation*» [78], puesto que propone una aproximación *Naive Bayes* para separar perfiles de atacantes de perfiles genuinos y además utiliza los tipos de *datasets* que son probados posteriormente por Zhou y Duan (Amazon, Netflix y MovieLens). Se trata de uno de los trabajos de referencia en el área.

Ataques en sistemas de recomendación

La importancia de proteger los sistemas de recomendación ha sido contemplada desde principio de siglo, siendo común la proposición de otros tipos de aprendizaje para detectar los ataques. Por ello, se muestra bibliografía relacionada con la investigación:

Recolección de los tipos de ataques y propuestas de reconocimiento [52]

Respecto a la descripción de los tipos de intrusión, la correcta definición formal (matemática) de sus parámetros y una recopilación de la gran mayoría de ataques existentes, es fundamental referenciar el artículo de Mingdan, Quingshan «*Shilling attacks against collaborative recommender systems: a review*» [52]. Se trata de una recopilación reciente (2018) de las principales investigaciones de los autores más populares en la materia que destaca por su completitud.

Definición de conceptos [77]

Previo a este documento, también es relevante contemplar otros trabajos, como la tesis de William y Mobasher «*Thesis: Profile injection attack detection for securing collaborative recommender systems*» [77]. En ella se introduce el concepto de inyección y se parametrizan características como el tamaño de ataque. Es destacable la autoridad de estos investigadores en la materia, siendo propietarios de muchos documentos de interés.

Primeras definiciones formales [54]

«*Collaborative recommendation: A robustness analysis*» [54], de O'Mahony y Hurley, es uno de los trabajos con más antigüedad pero mayor número de referencias que se encuentra. En él se definen los modelos de construcciones en base a conocimiento del sistema y pone a prueba la robustez de los recomendadores evaluando su estabilidad y precisión ante la presencia de perfiles inyectados (análisis matemático muy completo).

Detección de *phishing* mediante algoritmos de *machine learning*

El estudio de la aplicación de los algoritmos de aprendizaje dedicado a la detección de *phishing* se ha basado principalmente en los artículos enumerados a continuación:

Machine Learning aplicado a la detección de *phishing*

El artículo más destacable es «*Towards detection of phishing websites on client-side using machine learning based approach*» [41]. En este *paper*, se propone un método de detección muy destacable debido a que la detección se realiza en el lado del «cliente» y es independiente de terceras partes

(como herramientas de OSINT). Por este motivo, la generación de vectores de características es rápida y confiable.

7. Conclusiones y Líneas de trabajo futuras

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas. Además, resulta muy útil realizar un informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

- [1] Tim Adams. 100 most popular tlds by google index. <https://www.scoutdns.com/100-most-popular-tlds-by-google-index/>, 2022.
- [2] Jesús Alcalá, Alberto Fernández, Julián Luengo, Francisco Herrera, Joaquín Derrac, Salvador García, and Luciano Sánchez. Github: Keel. <https://github.com/SCI2SUGR/KEEL>, 2018.
- [3] Dana Angluin and Philip Laird. Learning from noisy examples. *Machine Learning*, 2:343–370, 1988.
- [4] Andrea Ardións. Cómo funciona tor y para qué deberíamos utilizarlo. <https://www.profesionalreview.com/2017/01/01/como-funciona-tor/>, 2017.
- [5] Atatus. Cross-site request forgery, a threat to open web applications. <https://www.atatus.com/blog/cross-site-request-forgery-a-threat-to-open-web-applications/>, 2022.
- [6] Atlassian. Flujo de trabajo de gitflow. <https://www.atlassian.com/es/git/tutorials/comparing-workflows/gitflow-workflow>, 2023.
- [7] Avast. Cifrado de datos: ¿en qué consiste? <https://www.avast.com/es-es/c-encryption>, 2022.
- [8] BBVA. ¿qué es el phishing y cuáles son sus consecuencias? <https://www.bbva.es/finanzas-vistazo/ciberseguridad/ataques-informaticos/que-es-el-phishing-y-cuales-son-sus-consecuencias.html>, 2023.

- [9] Marius Borcan. Tf-idf explained and python sklearn implementation. <https://towardsdatascience.com/tf-idf-explained-and-python-sklearn-implementation-b020c5e83275>, 2020.
- [10] Jason Brownlee. Roc curves and precision-recall curves for imbalanced classification. <https://machinelearningmastery.com/roc-curves-and-precision-recall-curves-for-imbalanced-classification/>, 2020.
- [11] Robin Burke, Michael P. O'Mahony, and Neil J. Hurley. *Robust Collaborative Recommendation*, pages 805–835. Springer US, Boston, MA, 2015.
- [12] Travis CI. Test and deploy with confidence. <https://www.travis-ci.com/>, 2023.
- [13] Conda. Conda. <https://docs.conda.io/en/latest/>, 2023.
- [14] Chris Coyier. Data uris. <https://css-tricks.com/data-uris/>, 2010.
- [15] Redacción de ComputerWorld. El 54 % del phishing' con éxito acaba en brechas de datos de los clientes. <https://cso.computerworld.es/cibercrimen/el-54-del-phishing-con-exito-acaba-en-brechas-de-datos-de-los-clientes>, 2022.
- [16] DeepSource. Deepsorce: The code health platform. <https://deepsource.io/>.
- [17] Delusionalinsanity. Tld 0.12.7. <https://pypi.org/project/tld/>, 2023.
- [18] Google Developers. Clasificación: Curva roc y auc. <https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc>, 2022.
- [19] Mozilla developers. <a>: El elemento ancla. <https://developer.mozilla.org/es/docs/Web/HTML/Element/a>, 2023.
- [20] Mozilla developers. Http headers. <https://developer.mozilla.org/es/docs/Web/HTTP/Headers>, 2023.
- [21] Mozilla developers. Http response status codes. <https://developer.mozilla.org/en-US/docs/Web/HTTP/Status>, 2023.

- [22] Juan José Rodríguez Diez. *Minería de datos: introducción*. 2023.
- [23] Expired Domains. Alexa top websites. <https://www.expireddomains.net/alexa-top-websites/>, 2023.
- [24] Jesper Engelen and Holger Hoos. A survey on semi-supervised learning. *Machine Learning*, 109, 02 2020.
- [25] Open Fish. Open fish feed file. <https://openphish.com/feed.txt>, 2023.
- [26] Open Fish. Openphish database. https://openphish.com/phishing_database.html, 2023.
- [27] Salvador García, Alberto Fernández, Mikel Galar, Ronaldo C. Prati, Bartosz Krawczyk, and Francisco Herrera. *Learning from Imbalanced Data Sets*. Springer International Publishing, 2018.
- [28] César García Osorio and Jose Francisco Diez Pastor. *Aprendizaje automático: introducción y problemas tipo*. 2022.
- [29] José Luis Garrido-Labrador. Github: sslearn. <https://github.com/jlgarridol/sslearn>, 2023.
- [30] Guang-Gang Geng, Yan-Ming Zhang, Xiao-Dong Lee, Wei Wang, and An-Lei Hu. A taxonomy of hyperlink hiding techniques. 03 2013.
- [31] Deepan Ghimiray. Avast: qué es tor, es seguro y cómo se usa. <https://www.avast.com/es-es/c-tor-dark-web-browser>, 2022.
- [32] Vivek Gite. How to check if port is in use on linux or unix. <https://www.cyberciti.biz/faq/unix-linux-check-if-port-is-in-use-command/>, 2023.
- [33] Github. Github. let's build from here. <https://github.com/>, 2023.
- [34] Git Guardian. Keep secrets out of your source code. <https://www.gitguardian.com/>, 2023.
- [35] Pablo Gómez. Qué es un ataque xss o cross site scripting. <https://www.icm.es/2022/05/11/cross-site-scripting-ataque-xss/>, 2022.
- [36] Red Hat. La integración y la distribución continuas (ci/cd). <https://www.redhat.com/es/topics/devops/what-is-ci-cd>, 2022.

- [37] Haibo He and Yunqian Ma. *Imbalanced Learning: Foundations, Algorithms, and Applications*. Wiley-IEEE Press, 1st edition, 2013.
- [38] IBM. ¿qué es el cifrado? definición de cifrado de datos. <https://www.ibm.com/es-es/topics/encryption>, 2022.
- [39] INCIBE. Ingeniería social: el engaño como arma del delito. <https://www.incibe.es/aprendeciberseguridad/ingenieria-social>, 2023.
- [40] IONOS. Los meta tags más importantes en html. <https://www.ionos.es/digitalguide/paginas-web/desarrollo-web/los-meta-tags-mas-importantes-y-su-funcion/>, 2022.
- [41] Ankit Kumar Jain and B. B. Gupta. Towards detection of phishing websites on client-side using machine learning based approach. *Telecommunication Systems: Modelling, Analysis, Design and Management*, 68(4):687–700, 2018.
- [42] Lin-Han Jia, Lan-Zhe Guo, Zhi Zhou, and Yu-Feng Li. Github: Lamda-ssl. <https://github.com/YGZWQZD/LAMDA-SSL>, 2022.
- [43] Lin-Han Jia, Lan-Zhe Guo, Zhi Zhou, and Yu-Feng Li. Lamda-ssl: Semi-supervised learning in python. *arXiv preprint arXiv:2208.04610*, 2022.
- [44] KeepCoding. ¿qué es el onion routing? <https://keepcoding.io/blog/que-es-el-onion-routing/>, 2022.
- [45] Grzegorz Kołaczek. *Cybersecurity: class notes*. 2021.
- [46] Scikit learn project. Tf-idf term weighting. https://scikit-learn.org/stable/modules/feature_extraction.html#tfidf-term-weighting, 2022.
- [47] Group Lens. Movielens datasets. <https://grouplens.org/datasets/>.
- [48] Ming Li and Zhi-Hua Zhou. Improve computer-aided diagnosis with machine learning techniques using undiagnosed samples. *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, 37(6):1088–1098, 2007.
- [49] Eduardo Lázaro. Data url: Qué es y cómo se utiliza. <https://www.neoguias.com/data-url/>, 2020.

- [50] Alex Martelli. How to extract top-level domain name (tld) from url. <https://stackoverflow.com/questions/1066933/how-to-extract-top-level-domain-name-tld-from-url>, 2009.
- [51] Microsoft. Los peligros de los correos electrónicos de phishing. <https://www.microsoft.com/es-es/security/business/security-101/what-is-phishing>, 2023.
- [52] Si Mingdan and Qingshan Li. Shilling attacks against collaborative recommender systems: a review. *Artificial Intelligence Review*, 53, 01 2018.
- [53] Tom M Mitchell. *Machine learning*, volume 1. McGraw-hill New York, 1997.
- [54] Michael O’Mahony, Neil Hurley, Nicholas Kushmerick, and Guénolé Silvestre. Collaborative recommendation: A robustness analysis. *ACM Trans. Internet Technol.*, 4(4):344–377, nov 2004.
- [55] Marta Palacio. *Scrum Master. Temario troncal 1*. 02 2022.
- [56] Phyton. El tutorial de python. <https://docs.python.org/es/3/tutorial/>, 2023.
- [57] Phyton. Entornos virtuales y paquetes. <https://docs.python.org/es/3/tutorial/venv.html>, 2023.
- [58] R. Polikar. Ensemble based systems in decision making. *IEEE Circuits and Systems Magazine*, 6(3):21–45, 2006.
- [59] Tor Project. I’m supposed to edit my torrc. what does that mean? <https://support.torproject.org/tbb/tbb-editing-torrc/>, 2022.
- [60] Tor Project. Socks5 / socks5. <https://support.torproject.org/es/glossary/socks5/>, 2022.
- [61] W3 Schools. Sql injection. https://www.w3schools.com/sql/sql_injection.asp, 2023.
- [62] Keeper Security. Qué es el phishing y cómo evitar las estafas. https://www.keepersecurity.com/es_ES/threats/what-is-phishing.html, 2023.
- [63] Selenium. Selenium: open source record and playback test automation for the web. <https://www.selenium.dev/selenium-ide/>, 2023.

- [64] Shopify. Payment gateways in spain. <https://www.shopify.com/payment-gateways/spain>, 2023.
- [65] SonarCloud. Clean code in your cloud workflow with sonarcloud. <https://www.sonarsource.com/products/sonarcloud/>.
- [66] Beautiful Soup. Beautiful soup documentation. <https://beautiful-soup-4.readthedocs.io/en/latest/>, 2023.
- [67] Phish Tank. Phish tank database. developer information. https://phishtank.org/developer_info.php, 2023.
- [68] Technocript. How to see and extract css of a website. <https://technocript.com/how-to-see-and-extract-css-of-a-website/>, 2022.
- [69] Natural Language Toolkit. Nltk documentation. <https://www.nltk.org/>, 2023.
- [70] Unity. ¿qué es ci/cd? <https://unity.com/es/solutions/what-is-ci-cd>, 2023.
- [71] Uniwebsidad. Enlaces relativos y absolutos. <https://uniwebsidad.com/libros/xhtml/capitulo-4/enlaces-relativos-y-absolutos>.
- [72] Jesper Van Engelen and Holger Hoos. Semi-supervised ensemble learning. master's thesis., 07 2018.
- [73] Wallarm. What is xss (cross site scripting)? <https://www.wallarm.com/what/what-is-xss-cross-site-scripting>, 2022.
- [74] Wallarm. Xss vs csrf. what is the difference? <https://www.wallarm.com/what/what-is-the-difference-between-csrf-and-xss>, 2022.
- [75] Similar Web. Clasificación de los mejores sitios web de créditos y préstamos bancarios en el mundo. <https://www.similarweb.com/es/top-websites/finance/banking-credit-and-lending/>, 2023.
- [76] Wikipedia. Validación cruzada. https://es.wikipedia.org/wiki/Validacion_cruzada, 2019.
- [77] Chad Williams, Research Advisor, and Bamshad Mobasher. Thesis: Profile injection attack detection for securing collaborative recommender systems, 2006.

- [78] Zhiang Wu, Junjie Wu, Jie Cao, and Dacheng Tao. Hysad: A semi-supervised hybrid shilling attack detector for trustworthy product recommendation. page 985–993, 2012.
- [79] Zenhub. Zenhub. the productivity platform for software teams. <https://www.zenhub.com/>, 2023.
- [80] Yue Zhang, Jason I. Hong, and Lorrie F. Cranor. Cantina: A content-based approach to detecting phishing web sites. page 639–648, New York, NY, USA, 2007. Association for Computing Machinery.
- [81] Quanqiang Zhou and Liangliang Duan. Semi-supervised recommendation attack detection based on co-forest. *Comput. Secur.*, 109(C), oct 2021.
- [82] Y. Zhou and S. Goldman. Democratic co-learning. pages 594–602, 2004.
- [83] Zhi-Hua Zhou and Ming Li. Tri-training: exploiting unlabeled data using three classifiers. *IEEE Transactions on Knowledge and Data Engineering*, 17(11):1529–1541, 2005.
- [84] Katie Zigelman. What is leet speak? <https://www.spectrumlabsai.com/the-blog/what-is-leet-speak>, 2020.